Universidade Federal de Juiz de Fora
INSTITUTO DE CIÊNCIAS EXATAS
Bacharelado em Ciência da Computação

Estudo comparativo de modelos para previsão horária de PM2,5

Daniel Fagundes Portes Fernandes

JUIZ DE FORA
DEZEMBRO, 2026

Estudo comparativo de modelos para previsão horária de PM2,5

Daniel Fagundes Portes Fernandes

Universidade Federal de Juiz de Fora
INSTITUTO DE CIÊNCIAS EXATAS
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
Bacharelado em Ciência da Computação

Orientador: Luciana Conceição Dias Campos

JUIZ DE FORA
DEZEMBRO, 2026

Estudo comparativo de modelos para previsão horária de PM2,5

Daniel Fagundes Portes Fernandes

MONOGRAFIA SUBMETIDA AO CORPO DOCENTE DO INSTITUTO DE CIÊNCIAS EXATAS DA UNIVERSIDADE FEDERAL DE JUIZ DE FORA, COMO PARTE INTEGRANTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE BACHAREL EM CIÊNCIA DA COMPUTAÇÃO.

Aprovada por:

Luciana Conceição Dias Campos
Doutora em Engenharia Elétrica PUC-Rio

JUIZ DE FORA
02 DE DEZEMBRO, 2026

Aos meus amigos e irmãos.

Aos meus pais, pelo apoio e sustento.

Agradecimentos

À minha família, pelo encorajamento e apoio.

À minha orientadora, pela orientação, amizade e, principalmente, pela paciência, sem a qual este trabalho não se realizaria.

Aos professores do Departamento de Ciência da Computação pelos seus ensinamentos e aos funcionários do curso, que durante esses anos, contribuíram de algum modo para o meu enriquecimento pessoal e profissional.

"Lembra que o sono é sagrado e alimenta de horizontes o tempo acordado de viver."

Beto Guedes (Amor de Índio)

Resumo

O Material Particulado Fino, fração do material particulado (PM, do inglês *particulate matter*) com diâmetro aerodinâmico de até 2,5 micrômetros (PM2,5), é associado a riscos de saúde e à degradação da qualidade do ar. Prever sua concentração com antecedência pode apoiar análises ambientais e ações preventivas. Porém, a previsão não é trivial porque os dados de monitoramento são ruidosos, apresentam lacunas e dependem de fatores meteorológicos, temporais e de emissão. Este trabalho compara diferentes modelos de aprendizado de máquina para previsão horária de PM2,5, usando como estudo de caso a estação Sapo, localizada em Conceição do Mato Dentro, Minas Gerais, com dados disponibilizados pela Fundação Estadual do Meio Ambiente de Minas Gerais. O objetivo é avaliar, sob um mesmo protocolo, como diferentes modelos se comportam em termos de erro médio, evolução ao longo do horizonte previsto e resposta a eventos de maior concentração. Foram comparados modelos baseados em *Long Short-Term Memory* (LSTM), arquiteturas sequência-para-sequência (*Sequence-to-Sequence*, Seq2Seq) com e sem atenção e *Extreme Gradient Boosting* (XGBoost), além de previsores simples e de uma regressão linear como referências. Os resultados, confirmados em um período de 2021 a 2023 não consultado durante o desenvolvimento, indicam que o XGBoost e a regressão linear obtiveram os menores erros médios, sem diferença estatística entre eles, e que as redes neurais tiveram erro até cerca de 8% maior. Todos os modelos subestimaram os picos de concentração. Conclui-se que, nesta série, a escolha do modelo altera pouco a qualidade da previsão. Assim, o trabalho reforça a importância de comparar modelos sob condições equivalentes e de avaliar não apenas métricas agregadas, mas também o comportamento das previsões em situações ambientalmente relevantes.

Palavras-chave: PM2,5, Previsão de Séries Temporais, Aprendizado Profundo, LSTM, Seq2Seq, XGBoost, Qualidade do Ar.

Abstract

Fine Particulate Matter, the fraction of particulate matter (PM) with an aerodynamic diameter of up to 2.5 micrometers (PM2.5), is associated with health risks and air-quality degradation. Forecasting its concentration in advance can support environmental analysis and preventive actions. However, forecasting is not trivial because monitoring data are noisy, contain gaps, and depend on meteorological, temporal, and emission-related factors. This work compares different machine-learning models for hourly PM2.5 forecasting, using the Sapo station, located in Conceição do Mato Dentro, Minas Gerais, Brazil, as a case study, with data provided by the Minas Gerais State Environmental Foundation. The goal is to evaluate, under a single protocol, how different models behave in terms of average error, evolution across the forecast horizon, and response to higher-concentration events. The comparison includes Long Short-Term Memory (LSTM)-based models, Sequence-to-Sequence (Seq2Seq) architectures with and without attention, and Extreme Gradient Boosting (XGBoost), with simple forecasters and a linear regression as references. The results, confirmed on a 2021–2023 period that was not consulted during development, indicate that XGBoost and the linear regression obtained the lowest average errors, with no statistical difference between them, and that the neural networks had errors up to about 8% higher. All models underestimated concentration peaks. It is concluded that, for this series, the choice of model changes forecast quality little. The work thus reinforces the importance of comparing models under equivalent conditions and of evaluating not only aggregate metrics, but also the behavior of the forecasts in environmentally relevant situations.

Keywords: PM2.5, Time Series Forecasting, Deep Learning, LSTM, Seq2Seq, XGBoost, Air Quality.

Conteúdo

Lista de Figuras **7**

Lista de Tabelas **9**

Lista de Abreviações **1**

1 Introdução **2**
1.1 Motivação . . . 3
1.2 Objetivos . . . 3
1.3 Cronograma . . . 4
1.4 Organização do Trabalho . . . 4

2 Fundamentação Teórica **6**
2.1 Séries Temporais . . . 6
2.2 Janelas e Variáveis Exógenas . . . 7
2.3 Previsão Multi-Horizonte . . . 9
2.4 Validação Temporal . . . 10
2.5 Dados Faltantes, Imputação e Vazamento Temporal . . . 11
2.5.1 Dados faltantes . . . 11
2.5.2 Imputação . . . 11
2.5.3 Vazamento temporal . . . 12
2.6 Redes Neurais e Aprendizado Profundo . . . 12
2.7 Redes Neurais Recorrentes e *Long Short-Term Memory* . . . 14
2.8 *Sequence-to-Sequence* e Atenção . . . 16
2.9 Decodificador Autorregressivo e *Teacher Forcing* . . . 19
2.10 Impulsionamento por Gradiente e XGBoost . . . 20
2.11 Treinamento, Perda e Hiperparâmetros . . . 21
2.12 Métricas de Avaliação . . . 23
2.13 Comparação Estatística de Previsões . . . 25

3 Trabalhos Relacionados **27**
3.1 Previsão de PM2,5 com Aprendizado de Máquina e Aprendizado Profundo 27
3.2 Estudos que Comparam Vários Modelos . . . 28
3.3 Modelos de Sequência e Atenção em Séries Temporais . . . 29
3.4 Referências Simples, Dados Faltantes e Avaliação . . . 30
3.5 Posicionamento deste Trabalho . . . 30

4 Materiais e Métodos **32**
4.1 Dados . . . 32
4.1.1 Escolha da Estação . . . 33
4.1.2 Cobertura e Lacunas . . . 34
4.1.3 Padrões Temporais . . . 35
4.2 Formulação da Tarefa . . . 36
4.2.1 Divisão Temporal e Período de Confirmação . . . 37
4.3 Pré-processamento . . . 38

4.4 Variáveis . . . 39
4.5 Modelos . . . 40
4.5.1 Redes Recorrentes e Seq2Seq . . . 40
4.5.2 Previsores de Referência . . . 41
4.5.3 XGBoost e Regressão Ridge por Horizonte . . . 42
4.5.4 Fatores Estudados . . . 42
4.5.5 O Que É Igual e O Que Muda Entre os Modelos . . . 43
4.6 Treinamento e Busca de Hiperparâmetros . . . 45
4.7 Métricas de Avaliação . . . 46
4.8 Inferência Estatística . . . 49
4.9 Verificações de Sensibilidade . . . 49
4.10 Diagnóstico da Atenção . . . 50
4.11 Reprodutibilidade . . . 50

5 Resultados e Discussão **52**
5.1 Comparação Principal . . . 52
5.2 Referências Simples e Regressão Linear . . . 54
5.3 Erro por Horizonte . . . 55
5.4 Picos, Cauda e Suavização . . . 56
5.4.1 Dinâmica Horária . . . 58
5.5 Efeito da Função de Perda . . . 59
5.6 Fatores Adicionais e Desenho do Seq2Seq . . . 60
5.7 Variáveis Derivadas do PM10 . . . 61
5.8 Interpretação da Atenção . . . 62
5.9 Sensibilidades . . . 63
5.9.1 Janela de Entrada . . . 63
5.9.2 Alvos Preenchidos, Busca de Hiperparâmetros e Vencedores . . . 64
5.10 O Que Limita a Qualidade da Previsão . . . 65
5.11 Ameaças à Validade . . . 66

6 Conclusão **67**
6.1 Principais Resultados . . . 67
6.2 Contribuições . . . 68
6.3 Limitações . . . 69
6.4 Trabalhos Futuros . . . 69

A Tabelas Complementares **71**
A.1 Comparação Principal . . . 71
A.2 Picos, Cauda e Dinâmica . . . 73
A.3 Fatores de Projeto . . . 76
A.4 Sensibilidades e Vencedores por Critério . . . 78

Bibliografia **79**

Lista de Figuras

2.1 Janela deslizante sobre uma série, com $L = 3$ valores de entrada e $H = 2$ valores de saída. A cada amostra a janela avança um instante. Elaboração própria. 8
2.2 Validação por janela expansiva com três partições. Em cada partição, o treino usa apenas dados anteriores à validação, e o bloco final fica reservado para o teste. Elaboração própria, com base em Tashman (2000), Bergmeir e Benitez (2012) e Hyndman e Athanasopoulos (2021). 10
2.3 Neurônio biológico e neurônio artificial 13
2.4 Rede recorrente desdobrada em três instantes. A seta horizontal transporta o estado interno de um passo para o seguinte. Elaboração própria. 14
2.5 Estrutura interna de uma célula LSTM 16
2.6 *Sequence-to-Sequence* com atenção. Os estados do codificador $\mathbf{h}_j$ são combinados, com pesos $\alpha_{k,j}$, no contexto $\mathbf{c}_k$, que alimenta o decodificador no passo k. A seta tracejada indica que o estado anterior do decodificador $\mathbf{s}_{k-1}$ participa do cálculo dos pesos. Adaptado de Bahdanau, Cho e Bengio (2014). 18
2.7 Duas formas de alimentar o decodificador no treinamento. Em *teacher forcing* (azul), a entrada do passo seguinte é o valor real anterior; em *free running* (verde), é a previsão anterior do modelo. Elaboração própria, com base em Bengio et al. (2015). 19
2.8 Previsão do impulsionamento por gradiente como soma de K árvores. Cada círculo é uma pergunta sobre um atributo e cada quadrado (folha) guarda um valor. Elaboração própria, com base em Chen e Guestrin (2016). 21

4.1 Classificação preliminar das estações por previsibilidade de PM2,5 com o contexto de PM10, obtida na análise exploratória. 33
4.2 Cobertura mensal de PM2,5 e maiores lacunas na série da estação Sapo no período de desenvolvimento (2017 a 2020). 34
4.3 Série de PM2,5 da estação Sapo e sua decomposição em tendência, componente diária e resíduo. Elaboração própria, com base em Hyndman e Athanasopoulos (2021). 35
4.4 Formulação da tarefa: as 48 horas até o instante de emissão t são a entrada, e as 24 horas seguintes são a previsão. 37
4.5 Linha do tempo da divisão cronológica. A escala é aproximada. Val.: validação; Teste hist.: teste histórico. 37

5.1 MAE por horizonte no período de confirmação (média das sementes). Linhas tracejadas: previsores de referência e regressão Ridge. 55
5.2 Previsões (média das sementes) em torno do maior evento do período de confirmação, em painéis separados por modelo e com escala comum. Observe que a linha tracejada horizontal marca 35 μg/m^3 e que as lacunas da série observada aparecem como quebras na linha. 57

A.1 MAE por horizonte no teste histórico (média das sementes). Linhas tracejadas: previsores de referência e regressão Ridge. 74

A.2 Previsões (média das sementes) em torno do maior evento do teste histórico, em painéis separados por modelo e com escala comum. 75

Lista de Tabelas

1.1 Cronograma do TCC no segundo semestre letivo de 2026. 5

3.1 Exemplos de configurações usadas em estudos de previsão de PM2,5. . . . 28

4.1 Blocos cronológicos do conjunto de dados 35
4.2 Padrões temporais observados de PM2,5 e PM10 na estação Sapo (2017 a 2020). 36
4.3 Divisão cronológica dos dados da estação Sapo. 37
4.4 Variáveis utilizadas pelos modelos. 39
4.5 Modelos e referências avaliados. 40
4.6 Elementos do protocolo idênticos para todos os modelos 44
4.7 Casos experimentais e o que muda entre eles 44
4.8 Espaço de busca de hiperparâmetros. 46
4.9 Hiperparâmetros selecionados pela busca com validação em janela expansiva 47

5.1 Métricas de erro no período de confirmação (2021–2023) 53
5.2 Diferença de MAE em relação à referência, com IC de 95% (bootstrap em blocos): período de confirmação (2021–2023) 53
5.3 Ensemble das sementes (média das previsões): período de confirmação (2021–2023) 54
5.4 Métricas de cauda e amplitude no período de confirmação (2021–2023) . . 56
5.5 Desempenho nos eventos de pico: período de confirmação (2021–2023) . . . 58
5.6 Diferença de MAE por evento em relação à referência: período de confirmação (2021–2023) 58
5.7 Dinâmica horária: período de confirmação (2021–2023) 59
5.8 Efeito da perda por arquitetura (L1 ponderada - Huber): período de confirmação (2021–2023) 59
5.9 Fatores (perda, resíduo e evento), métricas de cauda: período de confirmação (2021–2023) 60
5.10 Efeito isolado de fatores adicionais: período de confirmação (2021–2023) . . 60
5.11 Ablação de cada elemento do desenho do Seq2Seq adaptado: período de confirmação (2021–2023) 61
5.12 Ablação das variáveis de PM10: período de confirmação (2021–2023) . . . 62
5.13 Diagnóstico da atenção aprendida frente a pesos uniformes (Seq2Seq atenção adaptado (Huber)) 62
5.14 Contraprova da atenção (Seq2Seq atenção adaptado (Huber)) 63
5.15 Sensibilidade à janela de entrada (MAE de validação, horizonte fixo de 24 h) 64
5.16 Sensibilidade às métricas com alvos imputados: período de confirmação (2021–2023) 64
5.17 Efeito de refazer a busca de hiperparâmetros para a perda ponderada: período de confirmação (2021–2023) 65
5.18 Melhor modelo por critério: período de confirmação (2021–2023) 65

A.1 Métricas de erro no teste histórico (jun.–dez./2020) 71
A.2 Ensemble das sementes (média das previsões): teste histórico (jun.–dez./2020) 71

A.3 Diferença de MAE em relação à referência, com IC de 95% (bootstrap em blocos): teste histórico (jun.–dez./2020) 72
A.4 Diferença de MAE entre todos os pares de modelos: período de confirmação (2021–2023) 72
A.5 Diferença de MAE entre todos os pares de modelos: teste histórico (jun.–dez./2020) 72
A.6 Métricas de cauda e amplitude no teste histórico (jun.–dez./2020) 73
A.7 Desempenho nos eventos de pico: teste histórico (jun.–dez./2020) 73
A.8 Diferença de MAE por evento em relação à referência: teste histórico (jun.–dez./2020) 74
A.9 Dinâmica horária: teste histórico (jun.–dez./2020) 74
A.10 Fatores (perda, resíduo e evento), métricas de erro: período de confirmação (2021–2023) 76
A.11 Fatores (perda, resíduo e evento), métricas de erro: teste histórico (jun.–dez./2020) 76
A.12 Fatores (perda, resíduo e evento), métricas de cauda: teste histórico (jun.–dez./2020) 77
A.13 Efeito da perda por arquitetura (L1 ponderada - Huber): teste histórico (jun.–dez./2020) 77
A.14 Efeito isolado de fatores adicionais: teste histórico (jun.–dez./2020) 77
A.15 Ablação de cada elemento do desenho do Seq2Seq adaptado: teste histórico (jun.–dez./2020) 77
A.16 Ablação das variáveis de PM10: teste histórico (jun.–dez./2020) 77
A.17 Sensibilidade às métricas com alvos imputados: teste histórico (jun.–dez./2020) 78
A.18 Efeito de refazer a busca de hiperparâmetros para a perda ponderada: teste histórico (jun.–dez./2020) 78
A.19 Melhor modelo por critério: teste histórico (jun.–dez./2020) 78

Lista de Abreviações

CMD	Conceição do Mato Dentro
CONAMA	Conselho Nacional do Meio Ambiente
CV	*Cross-Validation* (validação cruzada)
DA-RNN	*Dual-stage Attention-based Recurrent Neural Network*
DM	Diebold-Mariano (teste estatístico)
FEAM	Fundação Estadual do Meio Ambiente de Minas Gerais
GRU	*Gated Recurrent Unit* (unidade recorrente com portões)
HPO	*Hyperparameter Optimization* (busca de hiperparâmetros)
IC	Intervalo de confiança
LSTM	*Long Short-Term Memory* (memória de curto e longo prazo)
MAE	*Mean Absolute Error* (erro médio absoluto)
MAPE	*Mean Absolute Percentage Error* (erro percentual médio absoluto)
MBE	*Mean Bias Error* (viés médio)
MICE	*Multivariate Imputation by Chained Equations*
MQ-RNN	*Multi-horizon Quantile Recurrent Neural Network*
PM	*Particulate Matter* (material particulado)
PM10	Material particulado com diâmetro aerodinâmico de até 10 micrômetros
PM2,5	Material particulado fino, com diâmetro aerodinâmico de até 2,5 micrômetros
R^2	Coeficiente de determinação
RMSE	*Root Mean Squared Error* (raiz do erro quadrático médio)
RNN	*Recurrent Neural Network* (rede neural recorrente)
Seq2Seq	*Sequence-to-Sequence* (sequência para sequência)
sMAPE	MAPE simétrico
TCC	Trabalho de Conclusão de Curso
TPE	*Tree-structured Parzen Estimator*
UFJF	Universidade Federal de Juiz de Fora
WAPE	*Weighted Absolute Percentage Error* (erro percentual absoluto ponderado)
XGBoost	*Extreme Gradient Boosting*

1 Introdução

A poluição atmosférica por material particulado fino é um problema relevante para a saúde. O Material Particulado (PM, do inglês *particulate matter*) é uma mistura de partículas sólidas e líquidas suspensas no ar, e sua fração fina, com diâmetro aerodinâmico de até 2,5 micrômetros, é denominada PM2,5. Por serem muito pequenas, essas partículas podem permanecer suspensas no ar, ser inaladas e alcançar regiões profundas do sistema respiratório. A literatura associa a exposição a PM2,5 a agravos respiratórios, efeitos cardiovasculares, aumento de internações e mortalidade (World Health Organization, 2021; POPE; DOCKERY, 2006; BROOK et al., 2010). Por isso, monitorar sua concentração e antecipar períodos de maior risco é importante para apoiar ações de prevenção, alertas e gestão da qualidade do ar. No Brasil, estudos sobre episódios de poluição associados a queimadas também relacionam PM2,5 a impactos mensuráveis sobre internações e mortalidade (REQUIA et al., 2021; REQUIA et al., 2022).

As diretrizes globais da Organização Mundial da Saúde tratam PM2,5 e material particulado inalável, formado por partículas com diâmetro aerodinâmico de até 10 micrômetros (PM10), como poluentes prioritários para avaliação de qualidade do ar (World Health Organization, 2021). Em redes de monitoramento, sensores registram concentrações de poluentes em intervalos regulares e formam séries temporais. Neste trabalho, a variável de interesse é a concentração horária de PM2,5.

Prever PM2,5, entretanto, não é uma tarefa simples. Essas séries podem apresentar lacunas, ruído de medição, mudanças de comportamento e picos pouco frequentes. Além disso, a concentração de PM2,5 depende de fatores como condições meteorológicas, emissão de poluentes, dispersão no ar e relação com outros poluentes, o que nem sempre está disponível de forma completa no momento em que a previsão precisa ser feita.

A literatura tem usado diferentes modelos para previsão de séries ambientais e de qualidade do ar, incluindo redes recorrentes, redes de memória de curto e longo prazo (*Long Short-Term Memory*, LSTM) e arquiteturas de aprendizado profundo com codificador, decodificador e atenção (YANG et al., 2023; ZHAO et al., 2021; ZHANG;

MA; YAN, 2021). Esses modelos são promissores por aprenderem relações temporais e não lineares.

Diante desse contexto, este Trabalho de Conclusão de Curso (TCC) desenvolve um estudo comparativo para previsão horária de curto prazo de PM2,5, utilizando diferentes modelos e arquiteturas, incluindo LSTM, modelos sequência-para-sequência (*Sequence-to-Sequence*, Seq2Seq) e *Extreme Gradient Boosting* (XGBoost). O estudo busca responder não apenas qual modelo produz menor erro de predição, mas também em quais condições cada abordagem se mostra mais adequada e quanto a escolha do modelo importa diante das informações disponíveis. Ele usa como caso principal uma série da estação Sapo, em Conceição do Mato Dentro, obtida a partir de dados de monitoramento da qualidade do ar disponibilizados pela Fundação Estadual do Meio Ambiente de Minas Gerais (FEAM) (Fundação Estadual do Meio Ambiente de Minas Gerais, 2026).

1.1 Motivação

A série de PM2,5 da estação Sapo é complexa, pois apresenta lacunas, ruído de medição e picos pouco frequentes, e a estação dispõe de poucas variáveis para apoiar a previsão. A literatura tem empregado estruturas cada vez mais variadas para a previsão de séries temporais, de redes LSTM simples a modelos recentes com atenção, mas uma estrutura mais complexa nem sempre traz melhor desempenho (ZENG et al., 2023; MAKRIDAKIS; SPILIOTIS; ASSIMAKOPOULOS, 2018). Isso motivou a realização deste trabalho: comparar diferentes arquiteturas nesta série, sob o mesmo tratamento dos dados, para verificar o que cada uma acrescenta à previsão horária de curto prazo de PM2,5.

1.2 Objetivos

O objetivo geral deste trabalho é comparar diferentes modelos de aprendizado de máquina para previsão horária de curto prazo de PM2,5, com horizonte de 24 horas, avaliando desempenho médio, comportamento ao longo do horizonte previsto e adequação a eventos de maior concentração.

Os objetivos específicos são:

1. Definir um protocolo rastreável de previsão horária de PM2,5 para a estação Sapo.
2. Consolidar uma preparação comum dos dados, preservando a ordem temporal e critérios rastreáveis de tratamento de lacunas.
3. Comparar modelos LSTM, Seq2Seq e XGBoost sob o mesmo conjunto de teste e a mesma preparação dos dados.
4. Avaliar os modelos por erro médio, erro por horizonte e comportamento em eventos de maior concentração.
5. Discutir as condições em que cada modelo se mostrou mais ou menos adequado para a tarefa analisada.

1.3 Cronograma

O cronograma do TCC considera o segundo semestre letivo de 2026, iniciado em 17 de agosto de 2026 e encerrado em 16 de dezembro de 2026. As atividades foram organizadas de modo a respeitar os marcos institucionais de matrícula, entrega do projeto, entrega do texto para defesa, realização da banca e envio da versão final. A Tabela 1.1 apresenta as atividades e os marcos de cada período.

1.4 Organização do Trabalho

Este documento está estruturado em seis capítulos. O Capítulo 1 apresenta o contexto, a motivação, os objetivos e o cronograma do trabalho. O Capítulo 2 reúne os conceitos necessários para compreender o problema de previsão e os modelos utilizados. O Capítulo 3 revisa trabalhos da literatura e situa o estudo desenvolvido. O Capítulo 4 descreve a metodologia, incluindo a base de dados, o protocolo de avaliação e os modelos comparados. O Capítulo 5 apresenta e discute os resultados dos experimentos. Por fim, o Capítulo 6 sintetiza as conclusões, limitações e possibilidades de continuidade. O Apêndice A reúne as tabelas complementares.

Tabela 1.1: Cronograma do TCC no segundo semestre letivo de 2026.

Período ou data	**Atividade**	**Marco**
17/08/2026	Primeiro dia letivo do segundo semestre de 2026 e início formal do planejamento do TCC.	Início do semestre
17/08/2026 a 31/08/2026	Ajuste de matrícula na disciplina de Monografia Final em Computação e confirmação da orientação.	Matrícula
01/09/2026 a 15/09/2026	Definição do escopo, alinhamento com a orientadora e consolidação do tema e dos objetivos.	Preparação inicial
16/09/2026 a 24/09/2026	Revisão e fechamento do projeto de TCC, incluindo metodologia, cronograma e referências principais.	Elaboração do projeto
25/09/2026	Envio do projeto de TCC.	Data limite
26/09/2026 a 31/10/2026	Execução dos experimentos, organização dos resultados e atualização dos capítulos técnicos do relatório.	Desenvolvimento
01/11/2026 a 17/11/2026	Consolidação do texto, revisão do relatório e preparação dos documentos necessários para a defesa.	Fechamento do texto
18/11/2026	Entrega do texto do TCC, marcação da defesa e informação da composição da banca.	Data limite
19/11/2026 a 01/12/2026	Ajustes finais antes da defesa e preparação da apresentação.	Preparação da defesa
02/12/2026	Realização da defesa do TCC.	Data limite
03/12/2026 a 08/12/2026	Correções pós-defesa, revisão final do documento e organização da ata da defesa.	Versão final
09/12/2026	Envio da versão final do TCC juntamente com a ata da defesa.	Data limite

2 Fundamentação Teórica

Este capítulo apresenta os conceitos necessários para compreender o restante do trabalho. Ele parte da noção de série temporal e explica como uma série é transformada em exemplos de entrada e saída para os modelos. Em seguida, descreve como separar os dados para treinar e avaliar os modelos sem que informação do futuro influencie o resultado, como tratar valores ausentes, como funcionam os modelos utilizados e como medir e comparar a qualidade das previsões.

2.1 Séries Temporais

Uma série temporal é uma sequência de observações ordenadas no tempo. Neste trabalho, o instante de cada observação é indicado por t, e o valor observado da grandeza de interesse nesse instante é indicado por y_t. Quando a série registra uma única grandeza, ela é chamada de *univariada*: por exemplo, apenas a concentração horária de PM2,5. Quando várias grandezas são registradas nos mesmos instantes, como PM2,5, PM10 e a hora do dia, a série é chamada de *multivariada*. Nesse caso, o conjunto das d grandezas observadas no instante t é organizado em um vetor $\mathbf{x}_t \in \mathbb{R}^d$, e o modelo pode usar, além do histórico da grandeza que se deseja prever, o histórico das demais.

Em qualidade do ar, a concentração de um poluente costuma apresentar ciclos diários e semanais, mudanças de comportamento ao longo dos anos, ruído de medição e episódios de concentração elevada. Hyndman e Athanasopoulos (2021) descrevem esses padrões como tendência, sazonalidade e variações restantes. Em uma decomposição aditiva simples, o valor observado no instante t é a soma desses componentes, como mostra a Equação 2.1.

$$y_t = T_t + S_t + R_t \tag{2.1}$$

Na Equação 2.1, T_t é a tendência, isto é, o nível médio da série que varia lentamente; S_t é a sazonalidade, um padrão que se repete em intervalos fixos, como a cada 24

horas; e R_t é o restante, que inclui o ruído, as mudanças abruptas e os eventos raros.

Outra medida útil é a autocorrelação, que indica o quanto os valores da série se parecem com os valores anteriores. Para um atraso de ℓ instantes, a autocorrelação amostral de uma série com T observações é dada pela Equação 2.2.

$$\rho(\ell) = \frac{\sum_{t=\ell+1}^{T}(y_t - \bar{y})(y_{t-\ell} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2} \tag{2.2}$$

Na Equação 2.2, $y_{t-\ell}$ é o valor observado ℓ instantes antes de t e $\bar{y}$ é a média de todos os valores da série. Em uma série horária, $\rho(1)$ alto indica que o valor de uma hora é parecido com o da hora anterior, $\rho(24)$ alto indica repetição diária e $\rho(168)$ alto indica repetição semanal.

2.2 Janelas e Variáveis Exógenas

Os modelos de aprendizado de máquina aprendem a partir de exemplos, cada um formado por uma entrada e pela saída que se espera obter dela. Uma série temporal, porém, é uma única sequência contínua. Para usá-la, ela é dividida em exemplos por meio de uma *janela deslizante* (janelamento): a janela de entrada reúne os L valores mais recentes até o instante t, e a saída desejada reúne os H valores seguintes, de $t+1$ a $t+H$. O número L é o comprimento da janela de entrada, e H é o horizonte de previsão, isto é, quantos instantes à frente se deseja prever. Ao avançar a janela um instante de cada vez, obtém-se um novo exemplo a cada passo.

A Figura 2.1 ilustra o procedimento com $L = 3$ e $H = 2$. Observe que cada linha é a mesma série, e que as caixas azuis mostram a entrada e as caixas laranja mostram a saída desejada. Na amostra 1, a entrada é formada por y_1, y_2 e y_3, e a saída desejada por y_4 e y_5. Na amostra 2, a janela avança uma posição: a entrada passa a ser y_2, y_3 e y_4, e a saída desejada, y_5 e y_6. Como as janelas se sobrepõem, o mesmo valor aparece em vários exemplos, ora como entrada, ora como saída.

Formalmente, seja $\mathbf{x}_t \in \mathbb{R}^d$ o vetor das variáveis observadas no instante t e y_t o valor de interesse nesse mesmo instante. Alguns atributos, além disso, são conhecidos de antemão para os instantes futuros, como a hora do dia; eles formam o vetor $\mathbf{z}_{t+k}$, com

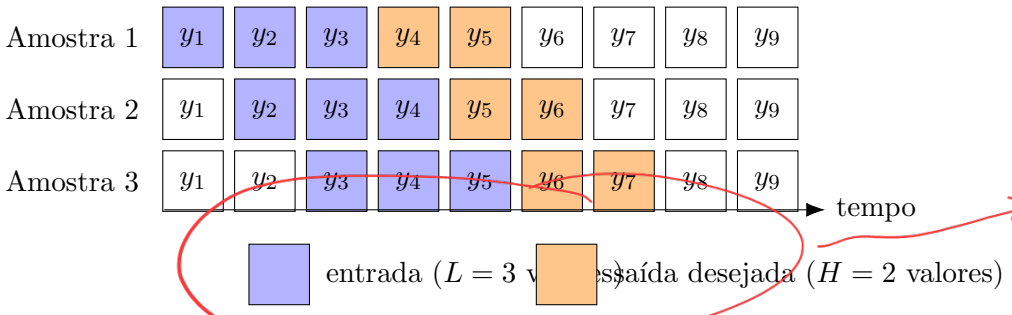


Figura 2.1: Janela deslizante sobre uma série, com $L = 3$ valores de entrada e $H = 2$ valores de saída. A cada amostra a janela avança um instante. Elaboração própria.

$k = 1, \ldots, H$. Um modelo f_θ, cujos parâmetros são reunidos em θ, transforma uma janela de entrada em uma previsão, conforme a Equação 2.3.

$$\hat{\mathbf{y}}_{t+1:t+H} = f_\theta\left(\mathbf{x}_{t-L+1:t}, \mathbf{z}_{t+1:t+H}\right) \tag{2.3}$$

Na Equação 2.3, $\mathbf{x}_{t-L+1:t}$ é a janela de entrada, formada pelos vetores dos instantes $t - L + 1$ até t; $\mathbf{z}_{t+1:t+H}$ reúne os atributos conhecidos de antemão para o horizonte; e $\hat{\mathbf{y}}_{t+1:t+H} = (\hat{y}_{t+1}, \ldots, \hat{y}_{t+H})$ é a sequência prevista. O acento circunflexo indica que o valor é uma previsão, e não uma observação. O treinamento consiste em ajustar θ para que $\hat{\mathbf{y}}$ se aproxime dos valores observados.

Algumas definições completam essa formulação. *Defasagem* é o uso de um valor passado de uma variável como atributo, como a concentração observada 24 horas antes. *Variável exógena* é uma variável externa ao valor que se quer prever, como o PM10 ou a temperatura, quando usadas para prever o PM2,5. *Atributos de calendário* descrevem o instante de forma conhecida com antecedência, como a hora do dia, o dia da semana e o mês. *Termos periódicos* representam um ciclo por meio de funções seno e cosseno, como mostra a Equação 2.4, para um período P (por exemplo, $P = 24$ horas).

$$s(t) = \sin\left(\frac{2\pi t}{P}\right), \qquad c(t) = \cos\left(\frac{2\pi t}{P}\right) \tag{2.4}$$

Na Equação 2.4, $s(t)$ e $c(t)$ variam continuamente ao longo do ciclo e voltam ao mesmo valor a cada P instantes. Com isso, as 23 horas e a 0 hora, que são vizinhas no relógio, também ficam próximas na representação numérica, o que não ocorreria se a hora fosse usada como número de 0 a 23.

Uma variável só pode servir de atributo para um instante futuro se seu valor já for conhecido no momento em que a previsão é emitida. Calendário e termos periódicos satisfazem essa condição. O PM10 medido em $t + 5$, por exemplo, não a satisfaz: usá-lo daria ao modelo uma informação que não existiria na prática. Esse problema é discutido na Seção 2.5.

2.3 Previsão Multi-Horizonte

Na previsão multi-horizonte, o modelo estima vários instantes futuros a partir do mesmo instante de emissão t, e não apenas o próximo (LIM; ZOHREN, 2021; BENIDIS et al., 2022). Três estratégias são usadas para isso.

- **Recursiva:** o modelo aprende a prever apenas um instante à frente, $\hat{y}_{t+1} = g_\theta(\mathbf{x}_{t-L+1:t})$, e a previsão obtida é reinserida na entrada para se obter $\hat{y}_{t+2}$, e assim por diante até $\hat{y}_{t+H}$. Essa estratégia é usada, por exemplo, pelo DeepAR (SALINAS et al., 2020). Sua desvantagem é que o erro de uma previsão se propaga para as seguintes.

- **Direta:** o modelo produz cada horizonte sem depender das previsões anteriores. Isso pode ser feito com um modelo independente para cada horizonte, $\hat{y}_{t+h} = g_\theta^{(h)}(\mathbf{x}_{t-L+1:t})$, ou com um único modelo de H saídas (TAIEB et al., 2012). Um exemplo é o MQ-RNN (*Multi-horizon Quantile Recurrent Neural Network*) (WEN et al., 2017), que produz os vários horizontes de uma só vez.

- **Codificador-decodificador:** uma parte do modelo, o codificador, resume a janela de entrada; outra parte, o decodificador, gera a sequência prevista a partir desse resumo. O *Temporal Fusion Transformer* (LIM et al., 2021), por exemplo, contém uma camada desse tipo. Esta arquitetura é detalhada na Seção 2.8.

Nenhuma estratégia é superior em todos os casos: a literatura de previsão não indica uma arquitetura dominante, e revisões de redes recorrentes para séries temporais afirmam que não há solução universal (HEWAMALAGE; BERGMEIR; BANDARA, 2021). Por isso, a escolha precisa ser verificada em cada problema.

2.4 Validação Temporal

Para saber se um modelo prevê bem, é preciso avaliá-lo em dados que ele não viu durante o treinamento. Por isso, os dados são divididos em três conjuntos. O conjunto de *treino* é usado para ajustar os parâmetros do modelo. O conjunto de *validação* é usado para comparar configurações do modelo e escolher a melhor, sem alterar os parâmetros. O conjunto de *teste* é reservado desde o início e usado apenas no final, para estimar a qualidade da previsão em dados novos.

Em séries temporais, essa divisão deve respeitar a ordem cronológica: o treino vem antes da validação, e esta, antes do teste. Uma divisão aleatória misturaria instantes de períodos diferentes, e o modelo poderia aprender com valores posteriores aos que precisa prever, o que dá uma estimativa otimista demais da qualidade (HYNDMAN; ATHANASOPOULOS, 2021; TASHMAN, 2000; BERGMEIR; BENITEZ, 2012).

A validação cruzada tradicional repete a avaliação em várias divisões dos dados e faz a média dos resultados, mas supõe exemplos independentes entre si, o que não vale para observações vizinhas de uma série. Uma adaptação usual é a validação por janela expansiva (*walk-forward*). A Figura 2.2 ilustra o procedimento com três partições. Observe que, na partição 1, o treino ocupa o bloco 1 e a validação ocupa o bloco 2. Na partição 2, o treino passa a ocupar os blocos 1 e 2, e a validação, o bloco 3. Na partição 3, o treino ocupa os blocos 1 a 3, e a validação, o bloco 4. Em todas as partições, a validação vem depois do treino, e o bloco final, em verde, permanece separado como conjunto de teste, sem participar de nenhuma escolha.

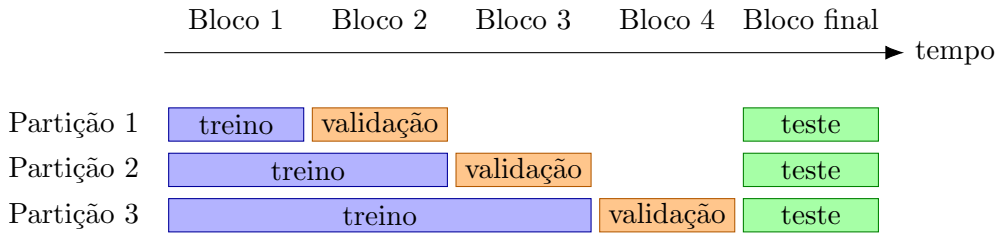


Figura 2.2: Validação por janela expansiva com três partições. Em cada partição, o treino usa apenas dados anteriores à validação, e o bloco final fica reservado para o teste. Elaboração própria, com base em Tashman (2000), Bergmeir e Benitez (2012) e Hyndman e Athanasopoulos (2021).

Para K partições, o resultado usado para comparar configurações é a média das

medidas de erro obtidas na validação de cada partição, como mostra a Equação 2.5.

$$\mathcal{L}_{CV} = \frac{1}{K} \sum_{k=1}^{K} \mathcal{L}_{val}^{(k)} \tag{2.5}$$

Na Equação 2.5, $\mathcal{L}_{val}^{(k)}$ é a medida de erro obtida na validação da partição k, e $\mathcal{L}_{CV}$ é a média entre as K partições (o índice CV vem de *cross-validation*, validação cruzada).

2.5 Dados Faltantes, Imputação e Vazamento Temporal

2.5.1 Dados faltantes

Dados ambientais reais frequentemente apresentam lacunas, isto é, instantes em que a medição esperada não foi registrada. As causas incluem falhas do sensor, manutenção, problemas de comunicação e descarte de leituras inconsistentes. Little e Rubin (2019) distinguem os casos conforme o motivo da ausência: ela pode ser independente dos valores (por exemplo, uma queda de energia), depender de outras variáveis observadas, ou depender do próprio valor que deixou de ser medido (por exemplo, um sensor que falha justamente quando a concentração é alta). No último caso, a ausência carrega informação sobre o valor perdido e é mais difícil de tratar.

2.5.2 Imputação

Imputação é o preenchimento das lacunas com valores estimados, o que permite formar janelas completas para o modelo. Os métodos mais simples repetem o último valor observado ou fazem uma interpolação linear entre o valor anterior e o posterior à lacuna. Métodos multivariados, como a imputação multivariada por equações encadeadas (*Multivariate Imputation by Chained Equations*, MICE) e o MissForest, estimam o valor faltante a partir das demais variáveis (BUUREN; GROOTHUIS-OUDSHOORN, 2011; STEKHOVEN; BUHLMANN, 2012). Um valor imputado é uma estimativa e não uma medição. Uma forma de manter essa distinção é acrescentar ao modelo um indicador de ausência, uma variável que vale 1 quando o valor original estava faltando e 0 quando foi medido

(CHE et al., 2018).

2.5.3 Vazamento temporal

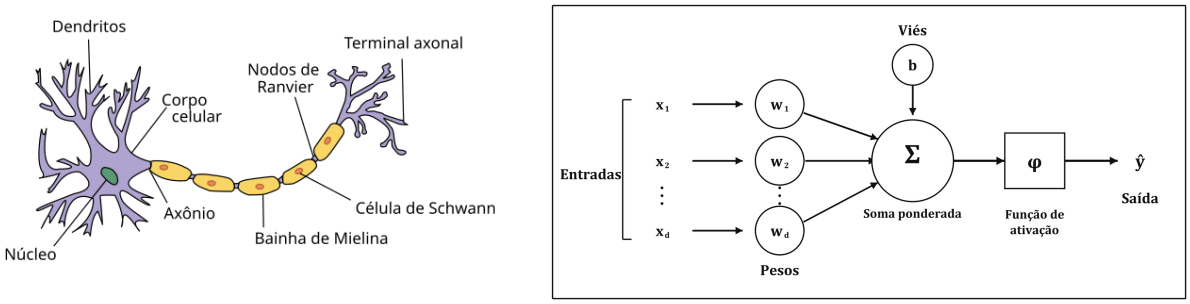
Vazamento temporal ocorre quando uma etapa de preparação dos dados usa informação que não estaria disponível no instante real da previsão. Três exemplos ilustram o problema. No primeiro, a média e o desvio-padrão usados para normalizar a série (colocar as variáveis em escala comparável) são calculados com todos os dados, inclusive os de validação e de teste, de modo que estatísticas do futuro influenciam o treinamento. No segundo, uma lacuna na validação é preenchida por interpolação linear usando uma medição posterior à origem da previsão. No terceiro, um atributo como a média das últimas 24 horas é calculado incluindo horas posteriores ao instante de emissão.

Para evitar o vazamento, a normalização, a imputação e a criação de atributos devem ser ajustadas apenas com dados anteriores ao período que será avaliado. Em uma validação por janela expansiva, por exemplo, a média e o desvio-padrão são calculados no bloco de treino de cada partição e depois aplicados ao bloco de validação; e as lacunas da validação não podem ser preenchidas com medições posteriores ao instante em que a previsão seria feita. Variáveis futuras só podem ser usadas quando forem conhecidas antes da previsão, como o calendário.

2.6 Redes Neurais e Aprendizado Profundo

Redes neurais artificiais são modelos formados por unidades simples, chamadas neurônios, conectadas por pesos. A inspiração histórica vem de modelos matemáticos do neurônio biológico, como o de McCulloch e Pitts (1943) e o perceptron de Rosenblatt (1958). Trata-se de uma analogia: as redes usadas em aprendizado de máquina não reproduzem a fisiologia dos neurônios reais, apenas a ideia de combinar entradas, ponderá-las e produzir uma saída. Em um neurônio biológico, os dendritos recebem sinais, o corpo celular integra parte deles e o axônio transmite o resultado a outras células; o neurônio artificial mantém a ideia de entradas ponderadas, soma e resposta (Figura 2.3).

Na Figura 2.3b, observe que cada entrada x_j é multiplicada por um peso w_j, que



(a) Neurônio biológico. (b) Neurônio artificial.

Figura 2.3: Comparação entre o neurônio biológico e o neurônio artificial. A imagem do neurônio biológico, com rótulos em português, foi obtida de Napvasconcelos e Vasconcelos (2008); a representação do neurônio artificial é elaboração própria, adaptada de Tzanis e Alimissis (2021).

os produtos são somados junto com o viés b (um valor constante que desloca o resultado) e que a soma passa por uma função de ativação ϕ, que produz a saída $\hat{y}$. A Equação 2.6 expressa exatamente essas operações.

$$a = \sum_{j=1}^{d} w_j x_j + b, \qquad \hat{y} = \phi(a) \tag{2.6}$$

Na Equação 2.6, d é o número de entradas, a é a soma ponderada e ϕ é a função de ativação, que introduz não linearidade e permite à rede representar relações que não são retas. Exemplos de função de ativação são a sigmoide, $\sigma(a) = 1/(1+e^{-a})$, que devolve valores entre 0 e 1, e a tangente hiperbólica, $\tanh(a)$, que devolve valores entre -1 e 1. Neste texto, $\hat{y}$ é sempre a previsão produzida pela camada final da rede, e $\mathbf{h}$ é o vetor de saídas de uma camada intermediária.

Uma rede neural organiza vários neurônios em camadas: as saídas de uma camada são as entradas da camada seguinte. A camada de índice ℓ é descrita pela Equação 2.7.

$$\mathbf{h}^{(\ell)} = \phi\left(W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right) \tag{2.7}$$

Na Equação 2.7, $\mathbf{h}^{(\ell-1)}$ é o vetor de saídas da camada anterior (na primeira camada, é a própria entrada), $W^{(\ell)}$ é a matriz cujos elementos são os pesos da camada ℓ, $\mathbf{b}^{(\ell)}$ é o vetor de vieses e $\mathbf{h}^{(\ell)}$ é a saída da camada. O treinamento ajusta pesos e vieses para reduzir a *perda*, um número que mede a distância entre as previsões e os valores observados. Para isso, calcula-se o gradiente da perda, isto é, a derivada da perda em

relação a cada parâmetro, que indica em que direção e com que intensidade alterá-lo para reduzir a perda; a retropropagação é o procedimento que calcula esses gradientes camada por camada, da saída para a entrada (GOODFELLOW; BENGIO; COURVILLE, 2016).

Aprendizado profundo (*deep learning*) é o treinamento de redes neurais com várias camadas, em que cada camada produz uma representação mais elaborada dos dados (GOODFELLOW; BENGIO; COURVILLE, 2016; LECUN; BENGIO; HINTON, 2015). Ele é um caso particular do aprendizado de máquina.

2.7 Redes Neurais Recorrentes e *Long Short-Term Memory*

Redes neurais recorrentes (*Recurrent Neural Networks*, RNNs) são projetadas para sequências. Elas leem a sequência um instante de cada vez e mantêm um *estado interno*, um vetor $\mathbf{h}_t$ que resume o que foi lido até o instante t e é repassado ao passo seguinte. Esse estado também é chamado de estado oculto. Em uma RNN simples, ele é calculado pela Equação 2.8.

$$\mathbf{h}_t = \tanh\left(W\mathbf{x}_t + U\mathbf{h}_{t-1} + \mathbf{b}\right) \tag{2.8}$$

Na Equação 2.8, $\mathbf{x}_t$ é a entrada no instante t, $\mathbf{h}_{t-1}$ é o estado do passo anterior, W e U são matrizes de pesos e $\mathbf{b}$ é o vetor de vieses. A Figura 2.4 mostra a mesma rede repetida em três instantes: observe que o estado $\mathbf{h}_t$ depende da entrada $\mathbf{x}_t$ e do estado anterior, de modo que a informação dos primeiros instantes chega aos últimos por uma cadeia de cálculos.

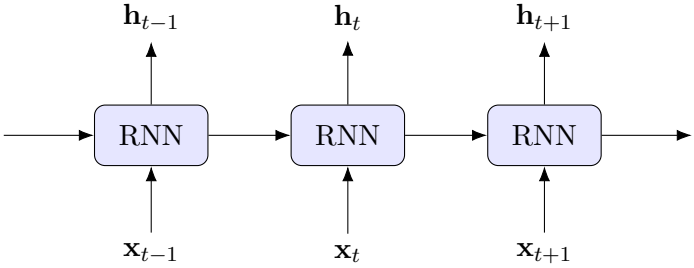


Figura 2.4: Rede recorrente desdobrada em três instantes. A seta horizontal transporta o estado interno de um passo para o seguinte. Elaboração própria.

Em RNNs simples, o treinamento sofre com o desaparecimento ou a explosão de gradientes. Como o gradiente em um instante inicial é obtido multiplicando muitos fatores, um por passo de tempo, ele tende a ficar muito pequeno quando esses fatores são menores que 1 (desaparecimento) ou muito grande quando são maiores que 1 (explosão). No primeiro caso, o modelo praticamente deixa de aprender com o início da sequência, o que dificulta capturar dependências longas.

A rede de memória de curto e longo prazo (*Long Short-Term Memory*, LSTM) foi proposta para reduzir esse problema (HOCHREITER; SCHMIDHUBER, 1997). Ela acrescenta uma célula de memória, um vetor $\mathbf{c}_t$ que atravessa a sequência com poucas alterações, e três *portões* (*gates*). Cada portão é um vetor de valores entre 0 e 1, obtido com a função sigmoide, que multiplica outro vetor elemento a elemento e funciona como uma válvula: valores próximos de 0 bloqueiam a informação, e valores próximos de 1 a deixam passar. O portão de esquecimento decide quanto da memória anterior é mantido; o portão de entrada decide quanto do novo conteúdo é gravado; e o portão de saída decide quanto da memória é exposto como estado oculto.

A Figura 2.5 mostra a estrutura de uma célula no instante t. Observe a linha superior, que carrega a memória de $\mathbf{c}_{t-1}$ para $\mathbf{c}_t$, e a linha inferior, que recebe a entrada atual $\mathbf{x}_t$ e o estado oculto anterior $\mathbf{h}_{t-1}$. O primeiro bloco sigmoide é o portão de esquecimento (F_t na figura, $\mathbf{f}_t$ na Equação 2.9). O segundo bloco sigmoide é o portão de entrada (I_t na figura, $\mathbf{i}_t$ na equação), e o bloco tanh ao lado produz o conteúdo candidato $\tilde{\mathbf{c}}_t$. O bloco sigmoide à direita é o portão de saída (O_t na figura, $\mathbf{o}_t$ na equação). Os círculos rosa da figura, o_{t-1}, o_t e o_{t+1}, são as saídas da rede em cada instante e, nesta equação, correspondem ao estado oculto $\mathbf{h}_t$; eles não são o portão de saída.

A célula LSTM é descrita pela Equação 2.9.

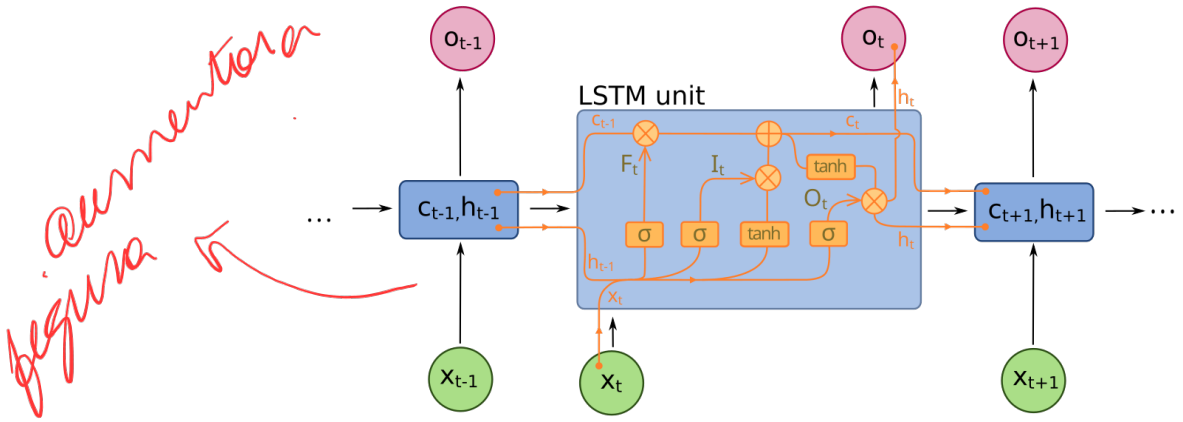


Figura 2.5: Estrutura interna de uma célula LSTM, com memória, estado oculto, portões e operações elemento a elemento. Fonte: Fdeloche (2017).

$$
\begin{aligned}
\mathbf{f}_t &= \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f), \\
\mathbf{i}_t &= \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i), \\
\tilde{\mathbf{c}}_t &= \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c), \\
\mathbf{o}_t &= \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o), \\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t).
\end{aligned}
\tag{2.9}
$$

Na Equação 2.9, σ é a função sigmoide, tanh é a tangente hiperbólica e $\odot$ indica multiplicação elemento a elemento. As matrizes W e U e os vetores $\mathbf{b}$ são parâmetros aprendidos no treinamento. As quatro primeiras linhas calculam os três portões e o conteúdo candidato. A quinta linha atualiza a memória: o portão de esquecimento $\mathbf{f}_t$ mantém parte da memória anterior e o portão de entrada $\mathbf{i}_t$ grava parte do conteúdo candidato. A última linha produz o estado oculto $\mathbf{h}_t$, com a parcela da memória que o portão de saída $\mathbf{o}_t$ deixa passar.

2.8 *Sequence-to-Sequence* e Atenção

Os modelos sequência-para-sequência (*Sequence-to-Sequence*, Seq2Seq) foram propostos para transformar uma sequência de entrada em uma sequência de saída de outro comprimento (SUTSKEVER; VINYALS; LE, 2014). Eles têm duas partes: O codificador é uma rede recorrente que lê a entrada e produz uma sequência de estados $\mathbf{h}_1, \ldots, \mathbf{h}_L$,

como mostra a Equação 2.10. O decodificador é outra rede recorrente que gera a saída um elemento por vez. Na previsão, a janela de entrada é a sequência de entrada, e o horizonte previsto é a sequência de saída.

$$\mathbf{h}_j = \mathrm{Enc}_\theta(\mathbf{x}_{t-L+j}, \mathbf{h}_{j-1}), \qquad j = 1, \ldots, L \tag{2.10}$$

Na Equação 2.10, Enc_θ é a rede recorrente do codificador (por exemplo, uma LSTM), $\mathbf{x}_{t-L+j}$ é a entrada do passo j da janela e $\mathbf{h}_{j-1}$ é o estado do passo anterior. Na versão original, o decodificador recebe apenas o último estado do codificador, que precisa resumir toda a janela em um único vetor. Esse vetor único é um gargalo, e Bahdanau, Cho e Bengio (2014) propuseram a atenção para reduzi-lo: a cada passo de saída k, o decodificador calcula uma média ponderada de todos os estados do codificador, em que os pesos indicam quais instantes da entrada são mais importantes para aquele passo.

A Figura 2.6 apresenta esse esquema, adaptado da figura original de Bahdanau, Cho e Bengio (2014). Observe que, na parte inferior, o codificador produz um estado $\mathbf{h}_j$ para cada entrada $\mathbf{x}_j$. Cada estado é multiplicado por um peso de atenção $\alpha_{k,j}$, e a soma ponderada forma o contexto $\mathbf{c}_k$, que entra no decodificador junto com seu estado anterior $\mathbf{s}_{k-1}$ para produzir o novo estado $\mathbf{s}_k$ e a previsão $\hat{y}_{t+k}$.

A Equação 2.11 formaliza o cálculo dos pesos na forma aditiva de Bahdanau, Cho e Bengio (2014).

$$\begin{aligned} e_{k,j} &= \mathbf{v}_a^\top \tanh(W_s \mathbf{s}_{k-1} + W_h \mathbf{h}_j + \mathbf{b}_a), \\ \alpha_{k,j} &= \frac{\exp(e_{k,j})}{\sum_{m=1}^{L} \exp(e_{k,m})}, \\ \mathbf{c}_k &= \sum_{j=1}^{L} \alpha_{k,j} \mathbf{h}_j. \end{aligned} \tag{2.11}$$

Na Equação 2.11, $e_{k,j}$ é o escore que mede a relevância do estado $\mathbf{h}_j$ do codificador para o passo k; W_s, W_h, $\mathbf{v}_a$ e $\mathbf{b}_a$ são parâmetros aprendidos. A segunda linha aplica a função *softmax*, que transforma os escores em pesos $\alpha_{k,j}$ positivos e de soma igual a 1, e a terceira linha forma o contexto $\mathbf{c}_k$ como a média ponderada dos estados.

O decodificador atualiza seu estado e produz a previsão conforme a Equação 2.12.

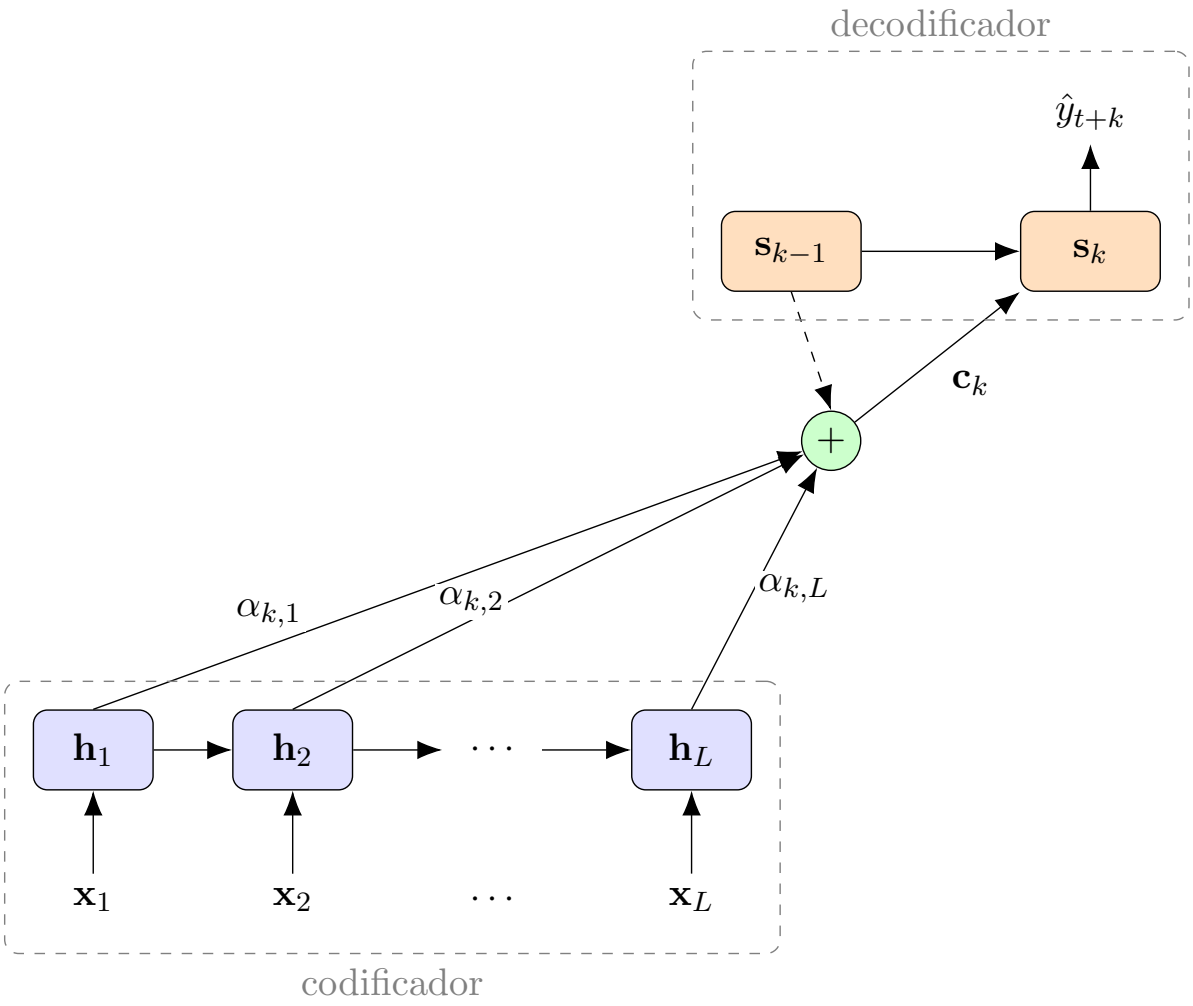


Figura 2.6: *Sequence-to-Sequence* com atenção. Os estados do codificador $\mathbf{h}_j$ são combinados, com pesos $\alpha_{k,j}$, no contexto $\mathbf{c}_k$, que alimenta o decodificador no passo k. A seta tracejada indica que o estado anterior do decodificador $\mathbf{s}_{k-1}$ participa do cálculo dos pesos. Adaptado de Bahdanau, Cho e Bengio (2014).

↳ Na fundamentação teórica acho importante você pegar a definição da literatura e colocar de forma didática no seu texto. Eu acho que ainda está confuso entender esse modulo!

$$\mathbf{s}_k = \mathrm{Dec}_\theta(\mathbf{s}_{k-1}, \tilde{y}_{t+k-1}, \mathbf{z}_{t+k}, \mathbf{c}_k),$$
$$\hat{y}_{t+k} = g_\theta(\mathbf{s}_k, \mathbf{c}_k, \mathbf{z}_{t+k}). \tag{2.12}$$

Na Equação 2.12, Dec_θ é a rede recorrente do decodificador, $\tilde{y}_{t+k-1}$ é o valor do passo anterior fornecido como entrada (definido na Seção 2.9), $\mathbf{z}_{t+k}$ são os atributos conhecidos de antemão para o passo k e g_θ é a camada que converte o estado em previsão.

2.9 Decodificador Autorregressivo e *Teacher Forcing*

Um decodificador é *autorregressivo* quando usa, como entrada do passo k, o valor produzido no passo $k-1$. Durante o uso real, esse valor só pode ser a previsão anterior do próprio modelo, porque o valor verdadeiro ainda não existe. Durante o treinamento, porém, o valor verdadeiro está disponível, e há duas possibilidades. Na *teacher forcing*, a entrada é o valor verdadeiro anterior; na *free running*, é a previsão anterior do modelo. A Figura 2.7 compara os dois modos.

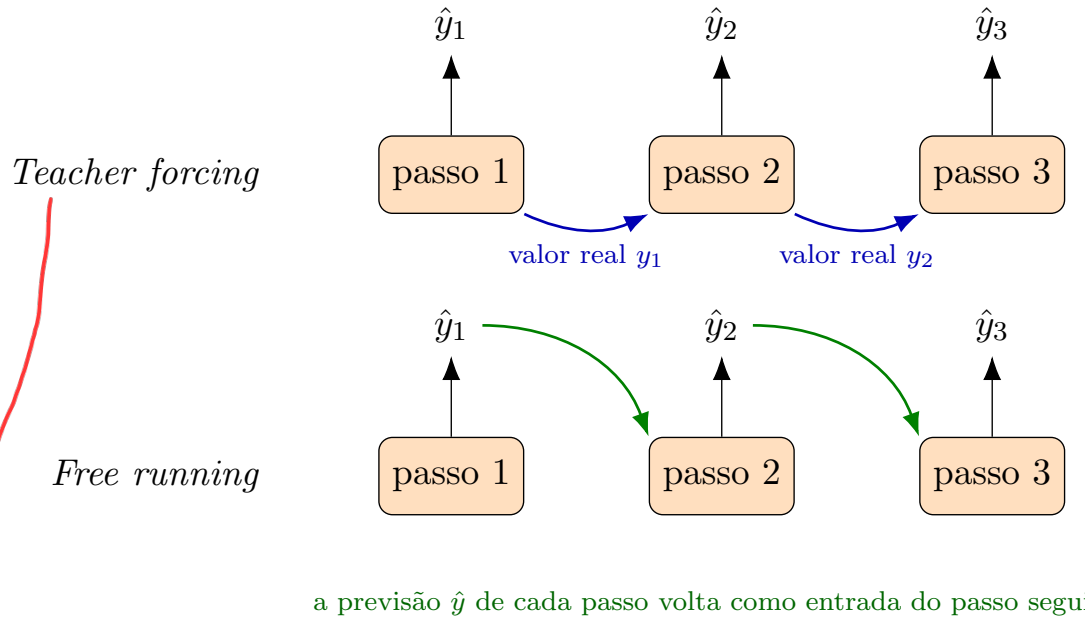


Figura 2.7: Duas formas de alimentar o decodificador no treinamento. Em *teacher forcing* (azul), a entrada do passo seguinte é o valor real anterior; em *free running* (verde), é a previsão anterior do modelo. Elaboração própria, com base em Bengio et al. (2015).

Considere um exemplo: se o valor real em uma hora foi 12 e o modelo previu 11, o passo seguinte recebe 12 em *teacher forcing* e 11 em *free running*. O *teacher forcing*

costuma acelerar o treinamento, mas cria uma diferença entre o treino, em que o decodificador só vê entradas corretas, e o uso real, em que vê as próprias previsões, com seus erros (BENGIO et al., 2015). Uma alternativa intermediária é o *scheduled sampling*, que sorteia, a cada passo, qual das duas entradas usar, com probabilidade de usar o valor real reduzida ao longo do treinamento (BENGIO et al., 2015). Existem ainda decodificadores que dispensam a realimentação, isto é, não recebem a previsão anterior como entrada; a Seção 4.5 descreve os que são usados neste trabalho.

2.10 Impulsionamento por Gradiente e XGBoost

Uma árvore de decisão é um modelo que divide os exemplos por uma sequência de perguntas sobre os atributos (por exemplo, "a concentração de 24 horas atrás é maior que 20?") e associa um valor de previsão a cada grupo final, chamado de folha. Uma única árvore é simples, mas limitada. O impulsionamento (*boosting*) combina muitas árvores pequenas em uma soma. No impulsionamento por gradiente (*gradient boosting*), as árvores são adicionadas uma de cada vez, e cada nova árvore é ajustada para corrigir os erros que restaram da soma das anteriores. O XGBoost (*Extreme Gradient Boosting*) é uma implementação eficiente desse método, com regularização e recursos para grandes conjuntos de dados (CHEN; GUESTRIN, 2016). Assim, o XGBoost é um tipo de impulsionamento por gradiente, e não uma técnica distinta.

Como qualquer modelo supervisionado, o XGBoost recebe cada exemplo como um vetor de atributos. A janela de entrada da Seção 2.2 é convertida em um vetor $\mathbf{u}_i$ para cada exemplo i, listando lado a lado os valores de todas as variáveis em todos os instantes da janela, e a saída é o valor a prever. A previsão depois de K árvores é a soma das respostas delas, como mostra a Equação 2.13 e a Figura 2.8.

$$\hat{y}_i^{(K)} = \sum_{k=1}^{K} f_k(\mathbf{u}_i), \qquad f_k \in \mathcal{F} \tag{2.13}$$

Na Equação 2.13, f_k é a árvore adicionada na etapa k e $\mathcal{F}$ é o conjunto de todas as árvores possíveis. O treinamento minimiza o objetivo regularizado da Equação 2.14.

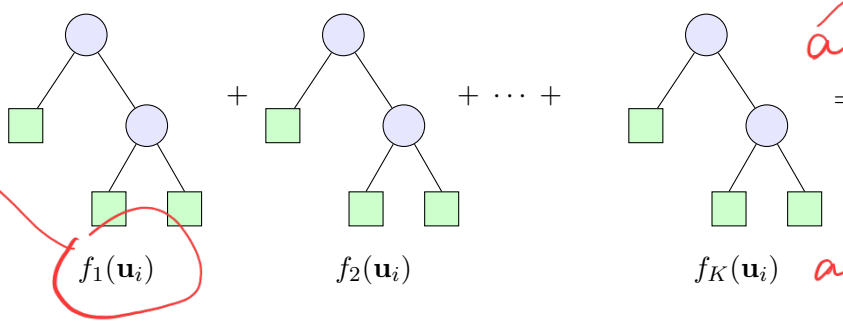


Figura 2.8: Previsão do impulsionamento por gradiente como soma de K árvores. Cada círculo é uma pergunta sobre um atributo e cada quadrado (folha) guarda um valor. Elaboração própria, com base em Chen e Guestrin (2016).

$$\mathcal{L}^{(K)} = \sum_i \ell(y_i, \hat{y}_i^{(K)}) + \sum_{k=1}^{K} \Omega(f_k), \qquad \Omega(f_k) = \gamma T_k + \frac{1}{2}\lambda \|\mathbf{w}_k\|_2^2 \tag{2.14}$$

Na Equação 2.14, ℓ é a função de perda que compara o valor observado y_i com a previsão, T_k é o número de folhas da árvore k, $\mathbf{w}_k$ é o vetor de valores das folhas, γ penaliza árvores com muitas folhas e λ penaliza valores grandes nas folhas. Esses termos de regularização evitam árvores excessivamente complexas, que ajustariam ruído em vez de padrões.

2.11 Treinamento, Perda e Hiperparâmetros

Os *parâmetros* de um modelo, como os pesos de uma rede, são aprendidos no treinamento. Os *hiperparâmetros* são escolhas feitas antes do treinamento, como a taxa de aprendizado, o número de camadas, o tamanho do estado oculto e a profundidade das árvores. O treinamento de uma rede percorre os dados várias vezes; cada passagem completa é uma *época*. O *dropout* desliga aleatoriamente uma fração das unidades da rede a cada passo de treinamento, o que reduz a dependência excessiva de poucas unidades e ajuda a evitar o sobreajuste, isto é, a memorização do treino em vez do aprendizado de padrões gerais (SRIVASTAVA et al., 2014). O decaimento de pesos (*weight decay*) penaliza pesos grandes com o mesmo objetivo. A parada antecipada interrompe o treinamento quando a medida de erro na validação deixa de melhorar por um número de épocas.

Redes neurais são treinadas com otimizadores baseados em gradiente, como o

Adam e o AdamW (KINGMA; BA, 2014; LOSHCHILOV; HUTTER, 2019), que atualizam os parâmetros na direção que reduz a perda. A *taxa de aprendizado* controla o tamanho de cada atualização. Ela pode ser constante ou seguir uma *agenda*, isto é, um plano que a altera ao longo das épocas. Uma agenda comum combina aquecimento linear, em que a taxa cresce no início, e decaimento cosseno, em que ela diminui suavemente depois (GOYAL et al., 2017; LOSHCHILOV; HUTTER, 2017). Com E_w épocas de aquecimento, E épocas no total, taxa máxima $\eta_{\max}$ e taxa mínima $\eta_{\min}$, a taxa na época t é dada pela Equação 2.15.

$$\eta_t = \begin{cases} \eta_{\max}\left(10^{-5} + (1-10^{-5})\frac{t}{E_w}\right), & 0 \le t \le E_w, \\ \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\left[1 + \cos\left(\pi \frac{t-E_w}{E-E_w}\right)\right], & E_w < t \le E. \end{cases} \tag{2.15}$$

Na Equação 2.15, a primeira linha descreve o aquecimento, em que a taxa cresce de um valor próximo de zero até $\eta_{\max}$; a segunda descreve o decaimento, em que ela cai suavemente de $\eta_{\max}$ até $\eta_{\min}$. A validação não altera os pesos: apenas mede o erro ao fim de cada época.

A escolha da função de perda define o que o modelo procura minimizar. A perda de Huber combina o comportamento quadrático para erros pequenos e linear para erros grandes, o que a torna menos sensível a valores extremos do que a perda quadrática (HUBER, 1964). Para o erro $e = y - \hat{y}$, ela é definida pela Equação 2.16.

$$\ell_\delta(e) = \begin{cases} \frac{1}{2}e^2, & \text{se } |e| \le \delta, \\ \delta\left(|e| - \frac{1}{2}\delta\right), & \text{caso contrário.} \end{cases} \tag{2.16}$$

Na Equação 2.16, δ é o limite a partir do qual o erro deixa de ser tratado de forma quadrática. Cada perda tem um valor de previsão que a minimiza: a perda quadrática é minimizada pela média condicional, a perda absoluta pela mediana condicional e a perda de Huber por um valor intermediário (GNEITING, 2011). Como a mediana de uma distribuição assimétrica à direita fica abaixo da média, modelos treinados com perda absoluta ou de Huber tendem a subestimar valores altos. A perda também pode ser

ponderada, atribuindo peso maior a determinados exemplos, na linha do aprendizado sensível ao custo (ELKAN, 2001).

A busca de hiperparâmetros (*Hyperparameter Optimization*, HPO) automatiza a escolha desses valores. Ajustá-los à mão é trabalhoso, porque muitos interagem entre si e cada teste exige um treinamento completo. Seja $\kappa \in \mathcal{K}$ uma configuração de hiperparâmetros dentro do espaço de busca $\mathcal{K}$, e $A(D_{treino}; \kappa)$ o modelo treinado com essa configuração. Em uma validação simples, busca-se a configuração de menor erro de validação, como na Equação 2.17.

$$\kappa^* = \arg\min_{\kappa \in \mathcal{K}} \mathcal{L}_{val}\left(A(D_{treino}; \kappa), D_{val}\right) \tag{2.17}$$

Na Equação 2.17, D_{treino} e D_{val} são os dados de treino e de validação, e κ^* é a configuração escolhida. Em séries temporais, o erro de validação é substituído pela média entre as partições, $\mathcal{L}_{CV}$, da Equação 2.5. O Optuna é uma ferramenta que realiza essa busca (AKIBA et al., 2019). Cada *tentativa* (*trial*) testa uma configuração e devolve seu erro; o amostrador *Tree-structured Parzen Estimator* (TPE) usa as tentativas anteriores para propor configurações promissoras (BERGSTRA et al., 2011; Optuna Contributors, 2026b). A poda interrompe cedo as tentativas pouco promissoras, poupando tempo: o *Hyperband* distribui o orçamento de treinamento entre muitas configurações e descarta as piores em etapas sucessivas (LI et al., 2018). Uma busca com orçamento limitado não garante encontrar o melhor conjunto possível.

2.12 Métricas de Avaliação

Nas equações desta seção, N é o número de previsões avaliadas, y_i é o valor observado, $\hat{y}_i$ é o valor previsto e $\bar{y}$ é a média dos valores observados. Como a previsão de PM2,5 é uma tarefa de regressão, a qualidade da previsão é medida por meio de erros. O erro médio absoluto (*Mean Absolute Error*, MAE) é a média das diferenças absolutas, como mostra a Equação 2.18, e tem a mesma unidade da grandeza prevista.

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}_i| \tag{2.18}$$

A raiz do erro quadrático médio (*Root Mean Squared Error*, RMSE), na Equação 2.19, eleva os erros ao quadrado antes da média e, por isso, dá mais peso aos erros grandes.

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} \tag{2.19}$$

O MAE e o RMSE respondem a perguntas diferentes, e reportar os dois evita depender de uma única medida (WILLMOTT; MATSUURA, 2005; CHAI; DRAXLER, 2014). O erro percentual médio absoluto (*Mean Absolute Percentage Error*, MAPE), na Equação 2.20, expressa o erro em relação ao valor observado.

$$\mathrm{MAPE} = \frac{100}{N}\sum_{i=1}^{N}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \tag{2.20}$$

Como y_i aparece no denominador, o MAPE cresce muito quando os valores observados são pequenos. Duas medidas percentuais menos sensíveis a isso são o erro percentual absoluto ponderado (*Weighted Absolute Percentage Error*, WAPE) e o MAPE simétrico (sMAPE) (HYNDMAN; KOEHLER, 2006), definidos na Equação 2.21.

$$\mathrm{WAPE} = 100\,\frac{\sum_{i=1}^{N}|y_i - \hat{y}_i|}{\sum_{i=1}^{N}|y_i|}, \qquad \mathrm{sMAPE} = \frac{100}{N}\sum_{i=1}^{N}\frac{2\,|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \tag{2.21}$$

Na Equação 2.21, o WAPE é o erro absoluto total dividido pelo total observado, ou seja, o MAE em relação à média das observações; no sMAPE, o termo da soma é considerado zero quando $y_i = \hat{y}_i = 0$. O coeficiente de determinação, R^2, compara o erro do modelo com a variabilidade do próprio alvo, conforme a Equação 2.22; valores próximos de 1 indicam que o modelo explica boa parte da variação, e valores próximos de 0, que ele não supera a previsão constante igual à média.

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2} \tag{2.22}$$

Duas medidas complementares completam o conjunto. O viés médio (*Mean Bias Error*, MBE) é a média de $\hat{y}_i - y_i$; valores negativos indicam subestimação sistemática. A habilidade (*skill score*) em relação a uma previsão de referência é $1 - \mathrm{MAE}/\mathrm{MAE}_{\mathrm{ref}}$, que é positiva quando o modelo tem erro menor que a referência.

Por fim, o MAE pode ser calculado separadamente para cada horizonte $h = 1, \ldots, H$, como na Equação 2.23.

$$\mathrm{MAE}_h = \frac{1}{N_h} \sum_{i=1}^{N_h} |y_{i,h} - \hat{y}_{i,h}| \tag{2.23}$$

Na Equação 2.23, N_h é o número de previsões avaliadas para o horizonte h, $y_{i,h}$ é o valor observado h instantes após a emissão da previsão i e $\hat{y}_{i,h}$ é o valor previsto correspondente. Com isso, é possível ver como o erro cresce à medida que a previsão se afasta do instante de emissão, o que uma média global esconderia.

2.13 Comparação Estatística de Previsões

Dois modelos com MAE parecidos podem diferir apenas por acaso da amostra de teste. Para decidir se a diferença é real, é necessário quantificar a incerteza, mas os erros de uma série temporal não são independentes: erros de horas vizinhas tendem a ser parecidos, e as janelas de previsão se sobrepõem. Tratar os erros como independentes subestima a incerteza e produz intervalos estreitos demais.

O *bootstrap em blocos* lida com isso (KÜNSCH, 1989; POLITIS; ROMANO, 1992). Ele repete muitas vezes o seguinte procedimento: sorteia, com reposição, blocos de instantes consecutivos do período de teste (em vez de instantes isolados, o que preserva a dependência dentro de cada bloco) e recalcula a diferença de erro entre os dois modelos, usando os mesmos blocos para ambos. As diferenças obtidas formam uma distribuição, e os percentis 2,5% e 97,5% dessa distribuição delimitam um intervalo de confiança de 95% para a diferença. Se o intervalo contém o zero, não há evidência estatística de que um modelo seja melhor que o outro.

O teste de Diebold-Mariano (DIEBOLD; MARIANO, 1995) é uma alternativa que compara diretamente as perdas. Sendo d_o a diferença entre a perda do modelo A e a do modelo B na previsão o, a estatística do teste é a média das diferenças dividida pelo seu erro-padrão, como na Equação 2.24.

$$DM = \frac{\bar{d}}{\sqrt{\widehat{V}(\bar{d})}} \tag{2.24}$$

Na Equação 2.24, $\bar{d}$ é a média das diferenças de perda, e $\widehat{V}(\bar{d})$ é uma estimativa da variância dessa média que leva em conta a autocorrelação das diferenças, como a de Newey e West (1987). A correção de Harvey, Leybourne e Newbold (1997) ajusta o teste para amostras finitas. Valores de DM distantes de zero (valor-p pequeno) indicam que as previsões têm qualidade diferente. O bootstrap fornece o intervalo na unidade da métrica, e o teste fornece um valor-p sob suposições assintóticas; por isso, os dois se complementam.

3 Trabalhos Relacionados

Este capítulo apresenta trabalhos da literatura sobre a previsão de PM2,5 e sobre os modelos de séries temporais utilizados neste estudo. O objetivo é mostrar o que já foi feito, em que condições e com quais resultados, e situar o presente trabalho em relação a eles.

3.1 Previsão de PM2,5 com Aprendizado de Máquina e Aprendizado Profundo

A previsão de PM2,5 é estudada com modelos estatísticos, com modelos de aprendizado de máquina baseados em árvores e, mais recentemente, com redes neurais profundas. Uma revisão de 2024 sobre arquiteturas de aprendizado profundo para PM2,5 examinou as semelhanças e as diferenças entre esses modelos e concluiu que falta um referencial unificado e padronizado para avaliar o desempenho deles; os autores propõem um esquema de avaliação que considera o conjunto de dados, o método e o experimento (ZHOU et al., 2024).

Entre os modelos recorrentes, Ayturan et al. (2020) compararam LSTM, redes recorrentes simples e unidades recorrentes com portões (*Gated Recurrent Unit*, GRU) para prever o PM2,5 em 1, 2 e 3 horas, com dados meteorológicos e de poluentes de uma estação de Ancara. Tran et al. (2023) estudaram a previsão horária com uma LSTM otimizada, e Zhao et al. (2021) combinaram a decomposição por modos empíricos com uma LSTM. Modelos com atenção também aparecem: Yang et al. (2023) propuseram uma LSTM com atenção para a concentração horária, e Li et al. (2020) combinaram redes convolucionais, LSTM e atenção para o PM2,5 urbano. Outras arquiteturas híbridas com redes convolucionais e LSTM foram aplicadas por Li, Hua e Wu (2020) e Su et al. (2023), este último para a região de Pequim, Tianjin e Hebei. Também há modelos que incorporam informação espacial entre várias estações (CHEN et al., 2024; FENG et al.,

2024) ou dados de sistemas de navegação por satélite (ZHANG et al., 2025).

No Brasil, Chaves et al. (2024) previram o PM2,5 em Curitiba com florestas aleatórias (*Random Forest*) e LSTM, usando dados meteorológicos e de fluxo de veículos, e compararam os resultados com uma regressão linear múltipla e com uma previsão ingênua. Os autores relatam que a altura da camada limite planetária foi a variável mais importante para as florestas aleatórias, o que indica o peso da meteorologia na previsão.

3.2 Estudos que Comparam Vários Modelos

Alguns trabalhos comparam vários modelos na mesma tarefa, como o presente estudo. He e Guo (2024) compararam oito modelos de aprendizado profundo para a previsão mensal de PM2,5 em Dezhou, na China, com dados de 2014 a 2023, e relataram que o modelo que combina redes convolucionais, GRU e LSTM teve o melhor desempenho. Zeng et al. (2026) avaliam modelos de séries temporais de aprendizado profundo para o PM2,5 em diferentes horizontes, e Qamar, Munir e Waseem (2025) comparam modelos de aprendizado profundo com abordagens tradicionais de séries temporais.

Esses estudos usam configurações distintas: a Tabela 3.1 resume três exemplos cujo resumo informa essas características. O horizonte de previsão varia de 1 hora a um mês, o número de estações e as variáveis de entrada mudam, e a frequência dos dados também. Cada estudo compara os seus próprios modelos entre si; já os valores absolutos de erro dependem do horizonte, das variáveis e da estação, de modo que não podem ser usados para comparar estudos diferentes.

Tabela 3.1: Exemplos de configurações usadas em estudos de previsão de PM2,5.

Estudo	**Modelos**	**Horizonte**	**Variáveis de entrada**
Ayturan et al. (2020)	LSTM, RNN e GRU	1, 2 e 3 horas	Meteorologia e poluentes de uma estação
Chaves et al. (2024)	Floresta aleatória e LSTM	Escalas horária e diária	Meteorologia e fluxo de veículos
He e Guo (2024)	Oito modelos de aprendizado profundo	Mensal	Dados de qualidade do ar de uma cidade, de 2014 a 2023

3.3 Modelos de Sequência e Atenção em Séries Temporais

Os modelos codificador-decodificador e a atenção foram propostos para tradução automática (SUTSKEVER; VINYALS; LE, 2014; BAHDANAU; CHO; BENGIO, 2014; LUONG; PHAM; MANNING, 2015). Sua estrutura, que transforma uma sequência de entrada em uma sequência de saída, corresponde à previsão multi-horizonte, e a literatura de séries temporais os adotou. Wen et al. (2017) propõem um previsor recorrente que gera vários horizontes de uma vez, Salinas et al. (2020) usam uma rede recorrente autorregressiva para prever muitas séries relacionadas de forma probabilística, e Lim et al. (2021) propõem o *Temporal Fusion Transformer*, que distingue entradas estáticas, entradas observadas apenas no passado e entradas futuras conhecidas. Qin et al. (2017) usam atenção duas vezes, primeiro para escolher quais variáveis de entrada são relevantes e depois para escolher quais instantes são relevantes. Cinar et al. (2017) observam que a atenção de Bahdanau, Cho e Bengio (2014), criada para tradução, não considera por si só a sazonalidade de uma série temporal, e propõem incluir a posição no cálculo da atenção.

Arquiteturas baseadas em Transformers, como o Informer, o Autoformer e o PatchTST, são adaptações para séries longas (ZHOU et al., 2021; WU et al., 2021; NIE et al., 2023). Sua vantagem, porém, não é automática: Zeng et al. (2023) mostram que um modelo linear simples pode ser competitivo com Transformers em previsão de longo prazo. Hewamalage, Bergmeir e Bandara (2021), em um estudo empírico sobre redes recorrentes para previsão, concluem que elas são alternativas competitivas em muitas situações, mas não uma solução universal. Já Benidis et al. (2022) descrevem os métodos de aprendizado profundo como os preferidos em muitas aplicações de previsão.

Sobre o uso dos pesos de atenção para interpretar o modelo, Jain e Wallace (2019) argumentam que eles nem sempre indicam a importância de cada entrada. Serrano e Smith (2019) e Wiegreffe e Pinter (2019) discutem em que condições os pesos podem ou não servir como explicação. Por isso, o presente estudo mede o efeito da atenção sobre o erro, em vez de interpretar os pesos diretamente (Seção 4.10).

3.4 Referências Simples, Dados Faltantes e Avaliação

Uma parte da literatura de previsão defende comparar os modelos com referências simples. Makridakis, Spiliotis e Assimakopoulos (2018) mostram, em 1045 séries mensais da competição M3, que métodos estatísticos tradicionais tiveram erro menor que os métodos de aprendizado de máquina populares na época. O trabalho de Curitiba citado acima também usa uma previsão ingênua como referência (CHAVES et al., 2024). As previsões ingênuas são descritas por Hyndman e Athanasopoulos (2021).

Quanto aos valores ausentes, Che et al. (2018) propõem tratar a ausência como informação de entrada em uma rede recorrente, por meio de indicadores de ausência. Li et al. (2018), em um problema de previsão de tráfego com dados faltantes, calculam o erro apenas nos pontos que foram de fato medidos. Não encontramos trabalho de previsão de PM2,5 que discuta explicitamente essa escolha.

Para comparar previsões, Diebold e Mariano (1995) propõem um teste estatístico da igualdade de qualidade preditiva, que Harvey, Leybourne e Newbold (1997) adaptam para amostras pequenas. Gneiting (2011) mostram que a medida de erro deve ser coerente com o objetivo da previsão.

3.5 Posicionamento deste Trabalho

Os estudos citados mostram que há muitos modelos propostos para prever o PM2,5 e que os resultados dependem do horizonte, das variáveis e da estação. Alguns trabalhos comparam vários modelos em um mesmo conjunto de dados, mas, entre os que consultamos, poucos combinam três aspectos: o uso de uma série com lacunas e sem variáveis meteorológicas, a comparação com referências simples e com uma regressão linear sob o mesmo tratamento dos dados, e a quantificação estatística das diferenças com um período de confirmação separado do desenvolvimento.

Este trabalho se ocupa desse conjunto. Ele compara redes LSTM, modelos Seq2Seq com e sem atenção e o XGBoost sobre a série de uma estação, com o mesmo tratamento dos dados e o mesmo treinamento para todos, e testa se as diferenças entre eles são estatisticamente distinguíveis. A contribuição não é uma nova arquitetura, mas

a comparação controlada e a avaliação do quanto a escolha do modelo altera a qualidade da previsão.

No cap. 3 tem que ter 2 seções:

3.1. Trabalhos relacionados sobre previsão de PM2,5 – trazer o que foi feito, quais modelos usados, variáveis usadas e horizontes e locais e dizer qual modelo foi melhor.

3.2. Trabalhos relacionados à imputação de dados ausentes em séries temporais – para dizer quais métodos são empregados. (Só vi um 2 de relevante).

4 Materiais e Métodos

Este capítulo descreve os dados, os modelos e o procedimento de avaliação. O procedimento foi definido para que todos os modelos recebam os mesmos dados, o mesmo tratamento e o mesmo treinamento, de modo que as diferenças observadas possam ser atribuídas aos modelos. Ele também preserva a ordem cronológica dos dados, para evitar que informação do futuro influencie o treinamento ou a avaliação.

4.1 Dados

O estudo utiliza medições horárias da estação Sapo, localizada em Conceição do Mato Dentro (CMD), Minas Gerais, que fazem parte do monitoramento contínuo da qualidade do ar disponibilizado pela Fundação Estadual do Meio Ambiente de Minas Gerais (FEAM) (Fundação Estadual do Meio Ambiente de Minas Gerais, 2026). A grandeza a ser prevista é a concentração de PM2,5. O principal poluente auxiliar é o PM10, o material particulado com diâmetro aerodinâmico de até 10 micrômetros. As colunas de gases e de variáveis meteorológicas do arquivo da estação (monóxido de carbono, ozônio, óxidos de nitrogênio e de enxofre, temperatura, umidade, vento, precipitação, radiação, pressão e compostos orgânicos) estão inteiramente vazias para a estação Sapo: nenhuma delas contém uma única medição. A única outra coluna com cobertura relevante é a de partículas totais em suspensão (86% de cobertura), que não foi incluída, pois seu uso seria uma nova hipótese, e não parte da comparação.

O arquivo cobre de 1º de janeiro de 2017 a 31 de dezembro de 2023. O conjunto usado nos resultados contém 61.271 registros horários, de 4 de janeiro de 2017 a 31 de dezembro de 2023; os três primeiros dias foram descartados porque as variáveis defasadas em 24 horas e a janela de entrada de 48 horas exigem histórico anterior. Os primeiros 34.992 registros (até 31 de dezembro de 2020) foram usados em etapas exploratórias anteriores a este estudo, que orientaram algumas escolhas de projeto; os anos de 2021 a 2023 não foram usados em nenhuma etapa do desenvolvimento e formam o período de

confirmação (*holdout*), descrito na Seção 4.2.1.

4.1.1 Escolha da Estação

A estação Sapo foi escolhida após uma análise exploratória de 38 estações com medições de PM2,5, que considerou a cobertura do alvo, a continuidade temporal, a disponibilidade de PM10 no mesmo horário, a frequência de eventos de alta concentração e o equilíbrio entre os períodos cronológicos. O objetivo dessa triagem foi selecionar uma série com volume suficiente, uma variável auxiliar útil e um número mínimo de eventos altos para a análise, e não a estação mais previsível da rede. Sapo ficou em segundo lugar tanto na classificação por PM2,5 quanto na que inclui o PM10 (Figura 4.1). A estação em primeiro lugar, Rio Doce, teve pontuação ligeiramente maior, mas apenas 0,19% de horas com PM2,5 acima de 35 μg/m^3, contra 1,16% em Sapo, e não pertence ao mesmo município. Sapo tem 83,47% de cobertura de PM2,5 e 74,27% de horas com PM2,5 e PM10 medidos juntos, com correlação de 0,58 entre os dois poluentes. A generalização para outras estações permanece uma limitação.

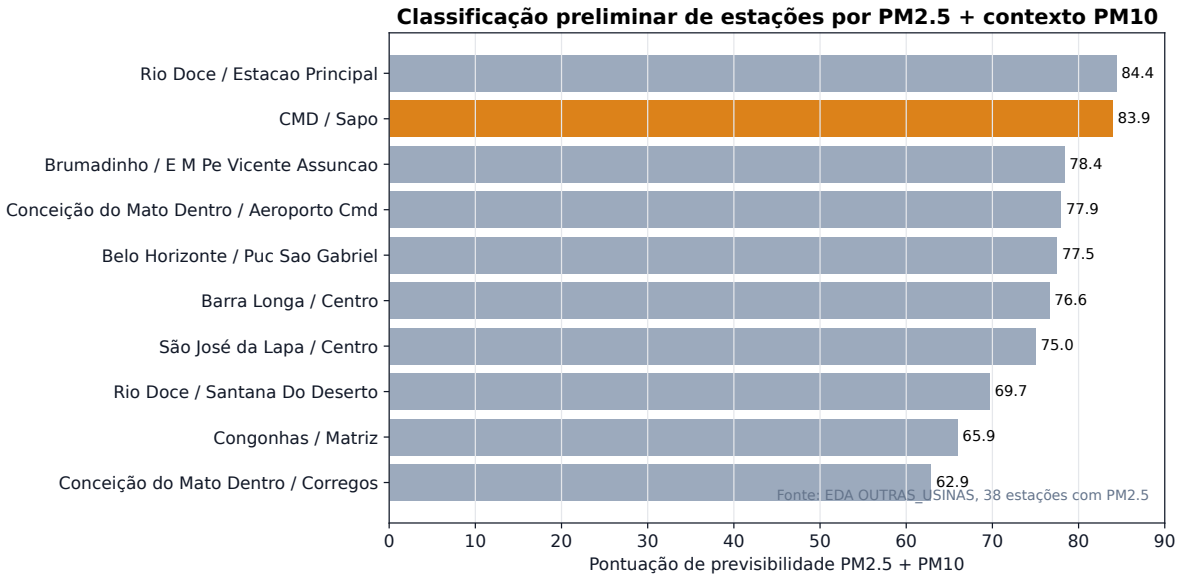


Figura 4.1: Classificação preliminar das estações por previsibilidade de PM2,5 com o contexto de PM10, obtida na análise exploratória.

4.1.2 Cobertura e Lacunas

A Figura 4.2 mostra que a série não é contínua: há meses com boa cobertura e lacunas longas, sobretudo na validação. A maior lacuna de PM2,5 vai de 11 de dezembro de 2019 a 28 de janeiro de 2020, com 48,25 dias. Os maiores trechos contínuos de dados medidos têm cerca de 8,5 dias. Por isso, é necessário preencher as lacunas para formar as janelas, e manter registro de quais valores foram preenchidos (Seção 4.3).

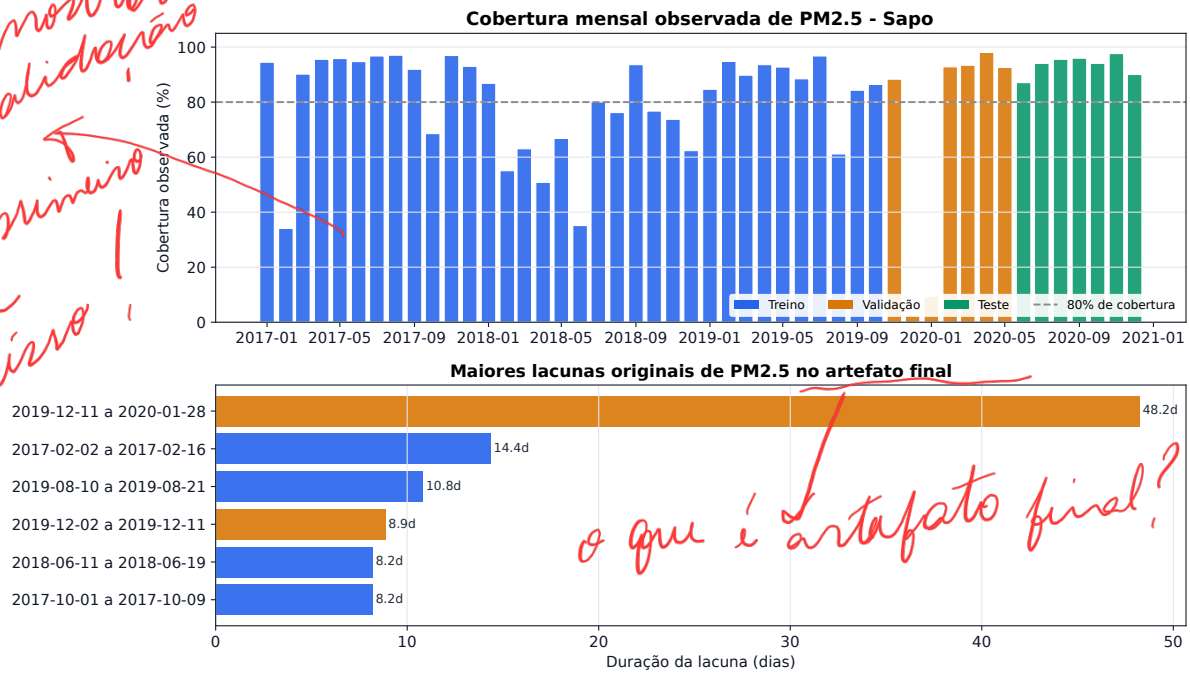


Figura 4.2: Cobertura mensal de PM2,5 e maiores lacunas na série da estação Sapo no período de desenvolvimento (2017 a 2020).

A Tabela 4.1 resume cada bloco cronológico (definidos na Seção 4.2.1). A validação concentra a maior proporção de ausências (31,73%) e o teste histórico tem a menor (6,63%). A coluna "Entrada propagada" informa a fração de horas dentro de lacunas de 24 horas ou mais, em que a entrada do modelo vem da repetição do último valor medido, e não de dados novos. Os eventos de concentração alta são raros: apenas entre 0,8% e 1,6% das horas medidas têm PM2,5 acima de 35 $\mu g/m^3$, o que justifica avaliar os picos separadamente, pois o erro médio é dominado pelas horas de concentração baixa.

A média anual de PM2,5 varia bastante entre os anos (por exemplo, 6,9 $\mu g/m^3$ em 2018, 16,5 em 2019 e 6,0 em 2023). Isso indica mudanças de comportamento da série, seja por variação climática entre anos, seja por alterações no instrumento, e essas variações não são tratadas aqui como ciclo regular, pois o conjunto cobre apenas sete anos.

Tabela 4.1: Blocos cronológicos do conjunto de dados

Bloco	Início	Fim	Horas	PM2,5 ausente (%)	Média obs.	DP obs.	Horas ≥35	Maior lacuna (h)	Entrada propagada (%)
treino	04/01/2017	21/10/2019	24495	19,30	10,95	8,07	311	345	8,21
validação	21/10/2019	27/05/2020	5248	31,73	13,69	5,85	52	1158	27,12
teste histórico	27/05/2020	31/12/2020	5249	6,63	13,61	5,50	47	53	1,01
holdout	01/01/2021	31/12/2023	26279	12,87	11,05	6,79	183	538	5,61

4.1.3 Padrões Temporais

Os padrões descritos nesta seção foram calculados apenas com os pontos medidos do período de desenvolvimento (2017 a 2020). A Figura 4.3 apresenta a decomposição aditiva do PM2,5 (Equação 2.1): observe a tendência que varia devagar, o perfil que se repete a cada dia e o resíduo com picos abruptos.

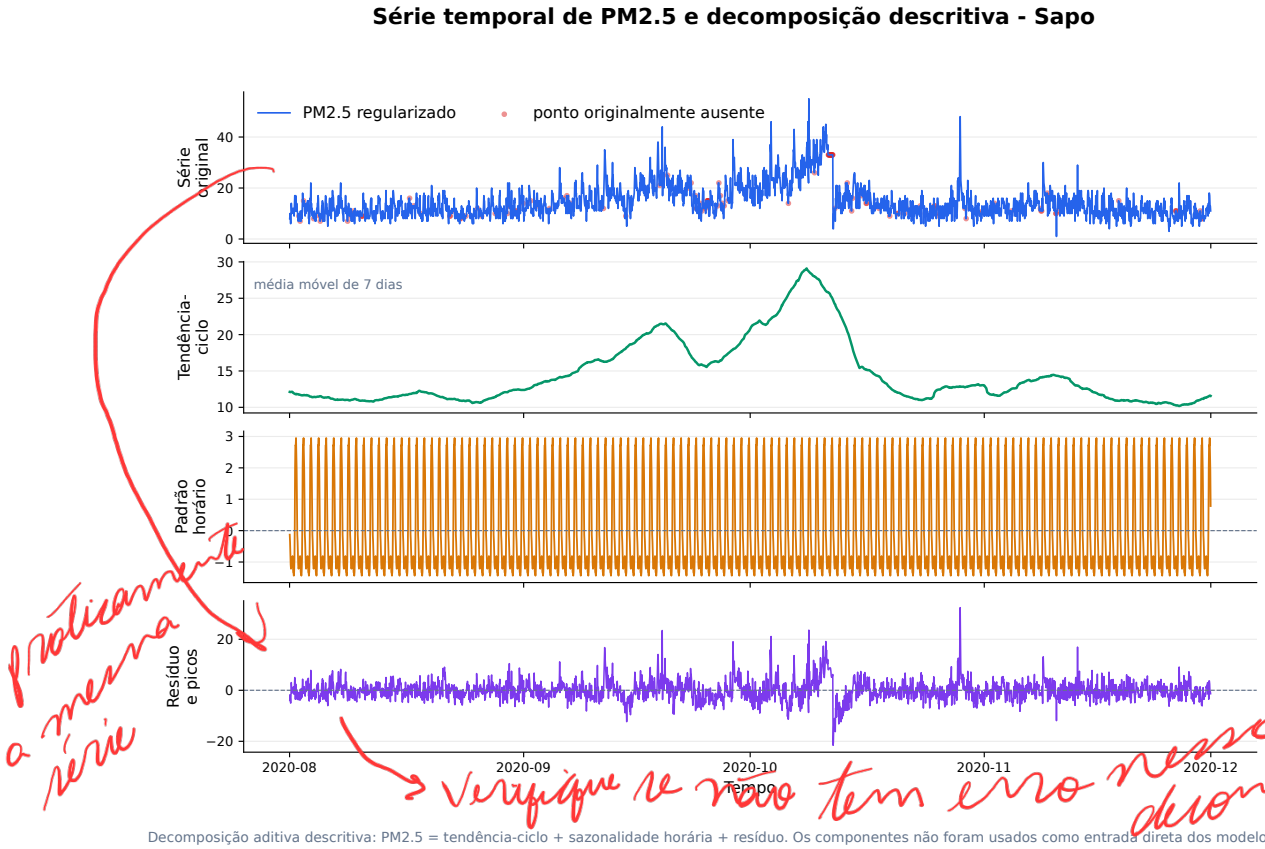


Figura 4.3: Série de PM2,5 da estação Sapo e sua decomposição em tendência, componente diária e resíduo. Elaboração própria, com base em Hyndman e Athanasopoulos (2021).

A Tabela 4.2 apresenta as autocorrelações (Equação 2.2). Para o PM2,5, a autocorrelação em 1 hora é 0,813 e em 24 horas é 0,681, o que indica forte persistência de curto prazo e repetição diária; a semanal é mais fraca (0,461). O perfil horário mostra as menores médias entre a madrugada e o início da tarde (mínimo de cerca de 10,3 μg/m^3 às 13 h) e as maiores no fim da tarde (máximo de cerca de 14,8 às 18 h). O PM10 tem

comportamento parecido, com amplitude horária maior. A correlação de Pearson entre PM2,5 e PM10 medidos no mesmo horário é 0,597; portanto, o PM10 é informativo, mas não determina o PM2,5. Há elevação de ambos em setembro e outubro; contudo, a autocorrelação anual do PM2,5 é baixa (cerca de 0,04), de modo que a repetição de ano para ano é menos estável do que a diária.

Tabela 4.2: Padrões temporais observados de PM2,5 e PM10 na estação Sapo (2017 a 2020).

Diagnóstico	PM2,5	PM10	Leitura
Autocorrelação em 1 h	0,813	0,734	Forte persistência de curto prazo nos dois poluentes.
Autocorrelação em 24 h	0,681	0,564	Repetição diária relevante.
Autocorrelação em 168 h	0,461	0,360	Repetição semanal mais fraca que a diária.
Amplitude média por hora do dia	4,48	11,14	Ciclo diário claro, mais intenso no PM10.
Amplitude média por dia da semana	0,70	3,68	Variação semanal pequena.
Amplitude média por mês	8,52	12,95	Variação mensal forte, com elevação em setembro e outubro.

4.2 Formulação da Tarefa

A tarefa é uma previsão multi-horizonte (Seção 2.3). Para cada instante de emissão t, o modelo recebe as 48 horas anteriores ($L = 48$, de $t - 47$ a t) e prevê a concentração de PM2,5 para as 24 horas seguintes ($H = 24$, de $t + 1$ a $t + 24$), como mostra a Figura 4.4. O horizonte de 24 horas corresponde a uma previsão para o dia seguinte e à escala do padrão de qualidade do ar de 24 horas da Resolução nº 491/2018 do Conselho Nacional do Meio Ambiente (CONAMA) (Conselho Nacional do Meio Ambiente, 2018). A escolha de $L = 48$ é uma decisão de projeto: ela cobre dois ciclos diários e contém as defasagens de 24 e de 48 horas usadas pelas referências simples (Seção 4.5.2). Como a autocorrelação de PM2,5 é alta em 1 hora (0,813), ainda relevante em 24 horas (0,681) e moderada em 48 horas (0,598), a janela contém o ciclo diário completo. Para verificar que as conclusões não dependem dessa escolha, a janela foi variada em 24, 48, 72 e 96 horas (Seção 5.9.1).

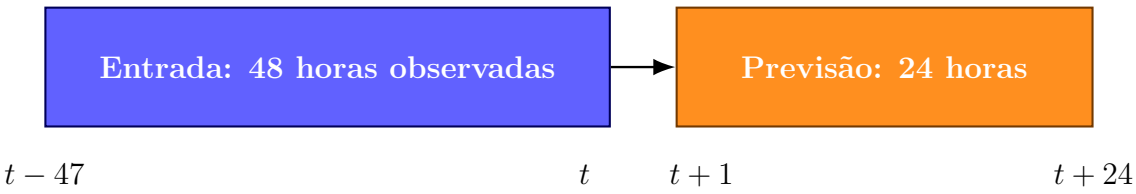


Figura 4.4: Formulação da tarefa: as 48 horas até o instante de emissão t são a entrada, e as 24 horas seguintes são a previsão.

4.2.1 Divisão Temporal e Período de Confirmação

Os dados são divididos por datas em quatro blocos cronológicos (Tabela 4.3 e Figura 4.5). O treino ajusta os parâmetros dos modelos e as estatísticas de normalização. A validação serve para a parada antecipada, para a escolha do melhor ponto do treinamento e para a busca de hiperparâmetros (Seção 4.6). O treino e a validação preservam os limites de etapas exploratórias anteriores (70% e 15% do período de 2017 a 2020).

O *teste histórico* (27 de maio a 31 de dezembro de 2020) foi consultado nessas etapas exploratórias, quando algumas escolhas de projeto foram feitas olhando seus resultados. Por isso, ele **não** é tratado como teste independente: seus resultados são apresentados, mas a evidência confirmatória vem do *período de confirmação* (*holdout*, 2021 a 2023), que nenhuma decisão de projeto observou antes da execução final. Todas as métricas são reportadas separadamente nos dois períodos, atribuindo cada previsão ao instante previsto.

Tabela 4.3: Divisão cronológica dos dados da estação Sapo.

Bloco	Horas	Intervalo	Papel
Treino	24.495	04/01/2017 a 21/10/2019	Ajuste dos pesos e da normalização
Validação	5.248	21/10/2019 a 27/05/2020	Parada antecipada, ponto de controle e hiperparâmetros
Teste histórico	5.249	27/05/2020 a 31/12/2020	Já consultado no desenvolvimento
Período de confirmação	26.279	01/01/2021 a 31/12/2023	Avaliação confirmatória

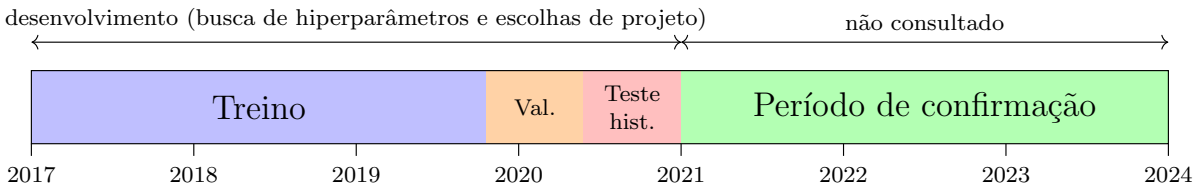


Figura 4.5: Linha do tempo da divisão cronológica. A escala é aproximada. Val.: validação; Teste hist.: teste histórico.

4.3 Pré-processamento

O pré-processamento foi desenhado para evitar vazamento temporal (Seção 2.5). Os valores ausentes são preenchidos por interpolação linear no tempo apenas dentro do trecho de treino. Depois do fim do treino, não se usam medições futuras: a transformação apenas repete o último valor disponível até que uma nova medição apareça. Para cada variável preenchida, mantém-se um indicador de ausência, uma variável que vale 1 nos instantes em que o valor original estava faltando. O conjunto de dados é uma função determinística do arquivo original e da data de corte do treino, o que permite recriá-lo com qualquer corte.

Essa propriedade é essencial para a busca de hiperparâmetros. Em etapas exploratórias anteriores, o arquivo já preenchido era reutilizado antes de formar as partições da validação, de modo que a interpolação podia consultar valores posteriores ao corte de uma partição. Na comparação final, cada partição da validação por janela expansiva recria o conjunto a partir do arquivo original cortado no fim do seu próprio treino, com o preenchimento ajustado até esse ponto. Testes automatizados verificam que alterar valores originais posteriores ao corte não muda nenhuma linha anterior a ele.

A imputação tem duas consequências. Primeiro, em lacunas longas posteriores ao corte, a entrada do modelo fica constante (por exemplo, na lacuna de 48 dias da validação); isso reproduz o que ocorreria em operação, mas significa que parte das janelas contém valores repetidos, e sua fração é informada na Tabela 4.1. Segundo, a interpolação linear dentro do treino usa valores posteriores do próprio treino, enquanto na inferência só é possível repetir o último valor; os indicadores de ausência atenuam essa diferença, mas não a eliminam.

A normalização coloca cada variável em escala comparável, subtraindo a média e dividindo pelo desvio-padrão, conforme a Equação 4.1.

$$\tilde{x}_t = \frac{x_t - \mu_{\text{treino}}}{\sigma_{\text{treino}}} \tag{4.1}$$

Na Equação 4.1, μ_{treino} e σ_{treino} são a média e o desvio-padrão da variável, calculados somente com o bloco de treino e aplicados igualmente aos blocos de validação e de

teste.

4.4 Variáveis

O conjunto de variáveis foi mantido enxuto, pois só o PM2,5, o PM10 e as partículas totais em suspensão têm medições (Seção 4.1). O codificador (ou a entrada, nos modelos sem codificador) recebe o PM2,5, o PM10, seus indicadores de ausência e atributos de calendário. Os modelos que aceitam entradas para o horizonte futuro recebem apenas variáveis cujo valor pode ser determinado no instante de emissão: termos periódicos e duas variáveis derivadas do PM10. A Tabela 4.4 resume os grupos.

Tabela 4.4: Variáveis utilizadas pelos modelos.

Grupo	**Variáveis**	**Uso**
Alvo e histórico	PM2,5	Entrada histórica e valor a prever
Poluente auxiliar	PM10	Entrada histórica
Ausência	Indicadores de ausência do PM2,5 e do PM10	Informar quais valores foram preenchidos
Calendário	Hora do dia, dia da semana e mês	Ciclos discretos
Termos periódicos	Seno e cosseno com períodos de 6, 12, 24, 168 e 8760 horas	Ciclos contínuos
PM10 do dia anterior	PM10 na mesma hora, 24 horas antes	Informação sobre o PM10 conhecida no instante de emissão
Tendência do PM10	PM10 24 horas antes menos PM10 27 horas antes	Direção recente do PM10, também conhecida no instante de emissão

As duas variáveis derivadas do PM10 usam valores defasados de 24 e 27 horas em relação ao instante previsto. Como a previsão é emitida em t e o instante previsto está no máximo em $t + 24$, essas defasagens são sempre anteriores a t, e não pressupõem conhecer o PM10 futuro.

Distinguem-se dois papéis das variáveis. As *covariáveis do passado* são conhecidas apenas até o instante de emissão t: PM2,5, PM10, seus indicadores, o calendário e os termos periódicos das 48 horas anteriores. As *covariáveis futuras conhecidas* têm valor determinável em t para cada hora do horizonte: os 20 termos periódicos (seno e cosseno) e as duas variáveis derivadas do PM10. Nenhum valor observado depois de t entra em nenhum modelo. O conjunto de variáveis, a janela de 48 horas e a lista de covariáveis futuras são idênticos para todos os modelos; o que difere é a forma de consumi-los. A LSTM e o Seq2Seq recebem a janela como sequência, e as covariáveis futuras separadamente. O XGBoost e a regressão Ridge recebem a janela em uma única linha (48×30 valores, contando um identificador constante da estação) concatenada às 23 covariáveis futuras de cada uma das 24 horas, o que totaliza 1.992 atributos. Um teste automatizado verifica que a lista de covariáveis futuras é a mesma em todos os modelos.

4.5 Modelos

Foram comparadas cinco redes neurais e um modelo baseado em árvores, além de referências simples e de uma regressão linear (Tabela 4.5). Nos nomes, "padrão" e "adaptado" referem-se às duas versões do Seq2Seq com atenção descritas adiante.

Tabela 4.5: Modelos e referências avaliados.

Modelo	**Descrição**	**Papel na comparação**
LSTM recursiva	Prevê uma hora por vez e reinsere a previsão como entrada	Estratégia recursiva
LSTM direta	Produz as 24 horas de uma vez a partir do estado final da janela	Estratégia direta
Seq2Seq básico	Codificador e decodificador recorrentes, sem atenção	Codificador-decodificador mínimo
Seq2Seq atenção padrão	Codificador-decodificador com atenção aditiva sobre as 48 posições	Atenção como proposta na literatura
Seq2Seq atenção adaptado	Seq2Seq com atenção com quatro modificações (descritas adiante)	Variante desenhada para esta série
XGBoost por horizonte	Um modelo de árvores impulsionadas para cada uma das 24 horas	Modelo baseado em árvores
Previsores ingênuos	Repetição de valores passados (definidos adiante)	Piso de desempenho
Regressão Ridge	Regressão linear regularizada, um modelo por horizonte	Referência linear

4.5.1 Redes Recorrentes e Seq2Seq

A **LSTM direta** lê a janela de 48 horas e agrega os estados da sequência (pelo último estado, pela média ou por atenção, o que é escolhido na busca de hiperparâmetros) em um vetor, do qual uma camada final produz as 24 previsões de uma vez, junto com as covariáveis futuras conhecidas. A **LSTM recursiva** prevê apenas uma hora à frente e realimenta a previsão para obter as horas seguintes, mantendo as covariáveis futuras conhecidas de cada hora. O **Seq2Seq básico** usa um codificador LSTM e um decodificador LSTM autorregressivo sem atenção; durante o treinamento, o decodificador recebe o valor real anterior (*teacher forcing*, Seção 2.9).

O **Seq2Seq com atenção padrão** usa o codificador LSTM, o decodificador LSTM e a atenção aditiva de Bahdanau, Cho e Bengio (2014) (Equação 2.11) sobre as 48 posições da janela, com a entrada do passo anterior fornecida ao decodificador (*input feeding*, Luong, Pham e Manning (2015)). Em ambas as versões com atenção, o decodificador é *semidireto*: em vez da previsão ou do valor real do passo anterior, ele recebe em todos os passos o último valor observado em t, as covariáveis futuras conhecidas do horizonte e o contexto de atenção. Assim, cada horizonte depende apenas dessas entradas e do estado do codificador, e o modelo se comporta como um preditor direto, sem realimentação de previsões, o que elimina o acúmulo de erros e torna o *teacher forcing* irrelevante para elas. O codificador também inclui uma seleção contextual das variáveis de

entrada, inspirada na atenção de entrada do modelo DA-RNN (*Dual-stage Attention-based Recurrent Neural Network*) (QIN et al., 2017), e uma camada linear que liga diretamente as entradas do passo à saída (CHENG et al., 2016).

O **Seq2Seq com atenção adaptado** altera quatro pontos do padrão. Primeiro, o estado do decodificador é reiniciado a cada horizonte, de modo que cada hora é prevista de forma independente das demais. Segundo, não usa *input feeding*. Terceiro, a consulta de atenção é condicionada ao número do horizonte e às covariáveis futuras. Quarto, a atenção é calculada sobre seis faixas de defasagem, e não sobre as 48 posições: a última hora, as últimas 6 horas, as últimas 24 horas, o mesmo horário do dia anterior, o mesmo horário de dois dias antes e o restante da janela, cada faixa resumida pela média dos estados do codificador naquelas posições. Essas quatro alterações são decisões de projeto, motivadas pela estrutura diária da série, e não métodos estabelecidos na literatura; por isso são avaliadas uma a uma (Seção 4.5.4).

4.5.2 Previsores de Referência

Sem referências simples, um erro isolado não indica se o modelo agrega valor (MAKRIDAKIS; SPILIOTIS; ASSIMAKOPOULOS, 2018). Foram usados cinco previsores ingênuos clássicos (HYNDMAN; ATHANASOPOULOS, 2021). Seja $y(t)$ o valor mais recente da série no instante de emissão t e $\hat{y}(t+h)$ a previsão para o horizonte $h = 1, \ldots, 24$:

- **Persistência:** $\hat{y}(t+h) = y(t)$, isto é, repete o último valor;
- **Sazonal de 24 horas:** $\hat{y}(t+h) = y(t+h-24)$, o valor da mesma hora no dia anterior;
- **Sazonal de 48 horas:** $\hat{y}(t+h) = y(t+h-48)$;
- **Média móvel de 6 horas:** $\hat{y}(t+h) = \frac{1}{6}\sum_{k=0}^{5} y(t-k)$;
- **Média móvel de 24 horas:** $\hat{y}(t+h) = \frac{1}{24}\sum_{k=0}^{23} y(t-k)$.

Os valores $y(\cdot)$ vêm da série já preenchida, como nos modelos. Além disso, a regressão Ridge (HOERL; KENNARD, 1970), uma regressão linear com penalização dos coeficientes, usa o mesmo vetor de 1.992 atributos do XGBoost, padronizado com

as estatísticas do treino, com o coeficiente de penalização escolhido na validação entre $\{0{,}1;\ 1;\ 10;\ 10^2;\ 10^3;\ 10^4\}$. Ela mede quanto do desempenho é explicado por uma relação linear nesses atributos. A habilidade (Seção 2.12) usa a média móvel de 24 horas como referência, por ser o melhor previsor ingênuo em etapas exploratórias anteriores.

4.5.3 XGBoost e Regressão Ridge por Horizonte

O XGBoost e a regressão Ridge seguem a estratégia direta (TAIEB et al., 2012): um modelo para cada horizonte, todos com os mesmos hiperparâmetros. Cada modelo é treinado com todas as janelas cujo alvo, *naquele horizonte*, foi medido; as linhas restantes recebem peso zero. Essa é a mesma regra das redes, em que apenas os pontos sem medição ficam fora da perda. Uma versão anterior treinava um único modelo com as 24 saídas e exigia as 24 medidas na mesma janela, o que descartava cerca de 70% das janelas de treino e esgotava a memória de uma placa de vídeo de 8 GB; ela foi abandonada por criar uma desvantagem de dados para o XGBoost. O objetivo de treinamento do XGBoost é o erro absoluto, consistente com o MAE (GNEITING, 2011).

4.5.4 Fatores Estudados

Para que as diferenças entre modelos possam ser atribuídas à sua causa, quatro fatores que variavam juntos em etapas anteriores foram separados. Cada um é alterado sozinho em relação a um caso base.

1. **Arquitetura**, comparada com a perda de Huber e sem aprendizado residual em todas as redes (comparação principal).

2. **Função de perda:** perda de Huber contra uma perda absoluta ponderada, aplicada a todas as arquiteturas. A perda ponderada multiplica o erro absoluto por pesos maiores quando o valor observado excede 15 e 35 μg/m^3, e por um fator adicional quando a previsão fica abaixo de um valor alto (Equação 4.2). Os pesos são uma decisão de projeto, fixos e motivados pelo aprendizado sensível ao custo (ELKAN, 2001) e pela ideia de penalizar de forma assimétrica os erros de subestimação, como nas perdas quantílicas (KOENKER; BASSETT, 1978).

3. **Aprendizado residual:** a rede prevê a correção sobre uma previsão de base, $\hat{y}_{t+k} = b_{t+k} + g_\theta(\cdot)$, em que b_{t+k} é a média entre o último valor observado e os valores de 24 e 48 horas antes do instante previsto, uma composição de previsores ingênuos. Está disponível para a LSTM direta e para o Seq2Seq adaptado.

4. **Perda auxiliar de evento:** uma saída adicional do Seq2Seq adaptado prevê, durante o treinamento, se haverá concentração acima de 25 e de 35 μg/m^3, segundo a lógica de aprendizado com várias tarefas (CARUANA, 1997).

$$\mathcal{J}_w = \frac{\sum_{(i,k)\in\mathcal{O}} w_{i,k}\,|y_{i,k} - \hat{y}_{i,k}|}{\sum_{(i,k)\in\mathcal{O}} w_{i,k}} \tag{4.2}$$

Na Equação 4.2, $\mathcal{O}$ é o conjunto de pares (exemplo i, horizonte k) cujo valor foi efetivamente medido, $y_{i,k}$ é o valor observado, $\hat{y}_{i,k}$ é a previsão e $w_{i,k}$ é o peso definido acima. Esta é uma perda absoluta ponderada sobre as previsões, e não uma regularização dos parâmetros.

Além disso, cada uma das quatro alterações do Seq2Seq adaptado é removida individualmente, mantendo os hiperparâmetros do modelo completo, para medir sua contribuição. E as variáveis do PM10 são removidas em dois cenários: mantendo o PM10 apenas no histórico (sem as duas variáveis derivadas para o futuro) e removendo o PM10 por completo, para a LSTM direta e para o XGBoost, cada cenário com sua própria busca de hiperparâmetros.

4.5.5 O Que É Igual e O Que Muda Entre os Modelos

A Tabela 4.6 lista o que é idêntico para todos os modelos e a Tabela 4.7 lista, caso a caso, o que muda. Três diferenças não podem ser eliminadas: (i) o XGBoost não tem épocas nem agenda de taxa de aprendizado, usa a parada antecipada própria e não aceita a perda ponderada; (ii) a LSTM recursiva realimenta a própria previsão e, por isso, não tem versão com aprendizado residual; (iii) os casos que alteram apenas a perda, o aprendizado residual ou o desenho reaproveitam os hiperparâmetros encontrados para o caso de Huber da mesma arquitetura, o que isola o efeito do fator, ao custo de possivelmente subestimar cada variante. O efeito desse reaproveitamento é verificado refazendo a busca para a perda

ponderada em duas arquiteturas (Seção 4.9).

Tabela 4.6: Elementos do protocolo idênticos para todos os modelos

Elemento	Definição
Dados e variáveis	Mesma série da estação Sapo e mesmas variáveis (PM2,5, PM10, indicadores de ausência, calendário e PM10 defasado em 24 h); entrada de 48 h e saída de 24 h
Divisão cronológica	Treino até 21/10/2019 14:30; validação até 27/05/2020 06:30; teste histórico até 31/12/2020; holdout de 2021 a 2023
Imputação	Interpolação linear dentro do treino; depois do corte, propaga-se o último valor; refeita em cada partição da busca
Normalização	Média e desvio-padrão calculados no treino
Alvo na perda e nas métricas	Somente medições observadas de PM2,5
Busca de hiperparâmetros	24 tentativas avaliadas em 3 partições com janela expansiva; até 18 épocas por tentativa nas redes
Passo entre janelas	4 h na busca; 2 h no treino final; 1 h na avaliação
Treino final	AdamW; 3 épocas de aquecimento e decaimento cosseno; até 40 épocas; parada antecipada com paciência de 8; escolha do ponto de controle pelo MAE de validação
Sementes	42, 7, 21 e 123 na comparação principal; as três primeiras nos demais grupos

Tabela 4.7: Casos experimentais e o que muda entre eles

Caso	Grupo	Perda	Aprend. residual	Perda de evento	Variáveis	Busca própria
LSTM direta (Huber)	comparação principal	Huber	não	não	todas	sim
LSTM recursiva (Huber)	comparação principal	Huber	não	não	todas	sim
Seq2Seq básico (Huber)	comparação principal	Huber	não	não	todas	sim
Seq2Seq atenção padrão (Huber)	comparação principal	Huber	não	não	todas	sim
Seq2Seq atenção adaptado (Huber)	comparação principal	Huber	não	não	todas	sim
XGBoost (erro abs.)	comparação principal	erro absoluto	não	não	todas	sim
LSTM direta (L1 pond.)	função de perda	L1 ponderada	não	não	todas	não
LSTM recursiva (L1 pond.)	função de perda	L1 ponderada	não	não	todas	não
Seq2Seq básico (L1 pond.)	função de perda	L1 ponderada	não	não	todas	não
Seq2Seq atenção padrão (L1 pond.)	função de perda	L1 ponderada	não	não	todas	não
Seq2Seq atenção adaptado (L1 pond.)	função de perda	L1 ponderada	não	não	todas	não
Seq2Seq atenção adaptado (L1 pond. + evento)	fatores adicionais	L1 ponderada	não	sim	todas	não
LSTM direta (Huber + resíduo)	fatores adicionais	Huber	sim	não	todas	não
Seq2Seq atenção adaptado (Huber + resíduo)	fatores adicionais	Huber	sim	não	todas	não
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	fatores adicionais	L1 ponderada	sim	sim	todas	não
Seq2Seq atenção adaptado (sem reinício por horizonte)	desenho do Seq2Seq	Huber	não	não	todas	não
Seq2Seq atenção adaptado (com input feeding)	desenho do Seq2Seq	Huber	não	não	todas	não
Seq2Seq atenção adaptado (sem faixas de defasagem)	desenho do Seq2Seq	Huber	não	não	todas	não
Seq2Seq atenção adaptado (consulta sem horizonte/exógenas)	desenho do Seq2Seq	Huber	não	não	todas	não
LSTM direta (Huber) [PM10 só no histórico]	variáveis de PM10	Huber	não	não	PM10 só no histórico	sim
XGBoost (erro abs.) [PM10 só no histórico]	variáveis de PM10	erro absoluto	não	não	PM10 só no histórico	sim
LSTM direta (Huber) [só PM2,5 e tempo]	variáveis de PM10	Huber	não	não	só PM2,5 e tempo	sim
XGBoost (erro abs.) [só PM2,5 e tempo]	variáveis de PM10	erro absoluto	não	não	só PM2,5 e tempo	sim
LSTM direta (L1 pond., HPO própria)	verificação da busca	L1 ponderada	não	não	todas	sim
Seq2Seq atenção adaptado (L1 pond., HPO própria)	verificação da busca	L1 ponderada	não	não	todas	sim

Transformers para séries temporais, como o *Temporal Fusion Transformer*, o Informer, o Autoformer e o PatchTST (LIM et al., 2021; ZHOU et al., 2021; WU et al., 2021; NIE et al., 2023), não foram incluídos: uma comparação justa exigiria outro espaço

de hiperparâmetros, um orçamento de busca equivalente e várias sementes. Além disso, a literatura não indica que eles superem automaticamente os demais modelos (ZENG et al., 2023). O recorte deste estudo é comparar redes recorrentes, modelos baseados em árvores e referências simples sob o mesmo tratamento dos dados.

4.6 Treinamento e Busca de Hiperparâmetros

Todos os modelos passam pelo mesmo procedimento (Tabela 4.6). Os hiperparâmetros de cada arquitetura são escolhidos por validação por janela expansiva com três partições (Seção 2.4), dentro dos blocos de treino e validação e sem acesso ao teste histórico nem ao período de confirmação. Cada partição recria a série preenchida a partir do arquivo original cortado no seu fim, e o critério de escolha é o MAE médio das partições, calculado apenas em alvos medidos. O orçamento é o mesmo para todas as famílias: 24 tentativas por arquitetura, com até 18 épocas por tentativa nas redes e a parada antecipada própria no XGBoost. Durante a busca, as janelas de treino avançam de 4 em 4 horas por custo computacional; o treino final avança de 2 em 2 horas e a avaliação, de 1 em 1 hora, para todos os modelos.

Nas redes, o estudo do Optuna usa o amostrador TPE com semente fixa e a poda *Hyperband*, que exige um mínimo de 4 épocas antes de podar uma tentativa (as 3 primeiras épocas são de aquecimento da taxa de aprendizado, em que o erro ainda não é representativo), com no máximo 18 épocas e fator de redução 3 (AKIBA et al., 2019; LI et al., 2018). Como o recurso é a época, só a primeira partição informa valores intermediários e pode podar a tentativa; a métrica da tentativa continua sendo a média das partições. No XGBoost, a busca minimiza o MAE médio das partições com TPE e poda pela mediana (Optuna Contributors, 2026a; CHEN; GUESTRIN, 2016). Os 24 modelos por horizonte do XGBoost são treinados na placa de vídeo, sem retorno automático ao processador: uma configuração que esgotasse a memória seria podada e contada, mas isso não ocorreu, e o pico medido foi de cerca de 1,4 GB entre os 8 GB disponíveis. As Tabelas 4.8 e 4.9 apresentam, respectivamente, o espaço de busca e a configuração escolhida.

O treino final usa o AdamW (LOSHCHILOV; HUTTER, 2019). A taxa de aprendizado tem três épocas de aquecimento linear, de $10^{-5}\eta_{\max}$ a $\eta_{\max}$, seguidas de decaimento

cosseno até $0{,}01\,\eta_{\max}$ no fim das 40 épocas (GOYAL et al., 2017; LOSHCHILOV; HUTTER, 2017). A validação, ao fim de cada época, mede o MAE e serve à parada antecipada (paciência de 8 épocas) e à escolha do melhor ponto do treinamento. Cada modelo é treinado com várias *sementes*, isto é, várias inicializações aleatórias dos pesos: quatro (42, 7, 21 e 123) na comparação principal e as três primeiras nos demais grupos, que respondem a perguntas sobre o efeito de um fator e não à classificação entre modelos. A média das previsões das sementes forma um *ensemble*, reportado à parte (LAKSHMINARAYANAN; PRITZEL; BLUNDELL, 2017).

Tabela 4.8: Espaço de busca de hiperparâmetros.

Grupo	**Hiperparâmetro**	**Valores avaliados**
Redes neurais	Taxa de aprendizado	0,0004; 0,0008; 0,0012; 0,0018; 0,0025; 0,0035; 0,005; 0,007
Redes neurais	Decaimento de pesos	0; 10^{-6}; 5×10^{-6}; 10^{-5}; 5×10^{-5}; 10^{-4}
Redes neurais	*Dropout* e camadas	*dropout* de 0,05 a 0,30 (passo 0,05); 1, 2 ou 3 camadas
Redes neurais (Huber)	δ da perda de Huber	0,5; 1,0; 1,5; 2,0
LSTM direta	Arquitetura	unidades ocultas de 64 a 320; agregação por último estado, média ou atenção
LSTM recursiva	Arquitetura	unidades ocultas de 64 a 320
Seq2Seq básico	Arquitetura	unidades ocultas de 64 a 256
Seq2Seq com atenção	Arquitetura	codificador com 64 a 160 unidades; decodificador com 64 a 192; atenção com 64 a 128; representação do horizonte com 8, 16, 24 ou 32 dimensões
XGBoost	Árvores e profundidade	160, 240, 320 ou 480 árvores; profundidade de 2 a 7; `max_bin` 64, 128 ou 256
XGBoost	Regularização e amostragem	taxa de aprendizado entre 0,015 e 0,12 (escala logarítmica); *subsample* e *colsample* entre 0,60 e 1,0; λ, α, γ e peso mínimo do filho; parada antecipada após 10, 15 ou 25 rodadas

4.7 Métricas de Avaliação

As métricas globais são as da Seção 2.12: MAE, RMSE, R^2, MBE, WAPE e sMAPE, além do MAPE. Como o alvo é baixo e inteiro (mediana próxima de 10 μg/m^3 e mínimo de 1), o MAPE é reportado apenas como referência; o WAPE e o sMAPE acompanham

Tabela 4.9: Hiperparâmetros selecionados pela busca com validação em janela expansiva

Modelo	Tentativas	Podadas	Época mediana da poda	Hiperparâmetros
LSTM direta (Huber)	24	17	12	taxa de aprendizado = 0,0025; decaimento de pesos = 0,0001; dropout = 0,3; camadas = 2; unidades ocultas = 192; agregação = atenção; δ de Huber = 0,5
LSTM direta (Huber) [PM10 só no histórico]	24	18	4	taxa de aprendizado = 0,0025; decaimento de pesos = 1e-06; dropout = 0,3; camadas = 2; unidades ocultas = 320; agregação = média; δ de Huber = 0,5
LSTM direta (Huber) [só PM2,5 e tempo]	24	16	4	taxa de aprendizado = 0,0012; decaimento de pesos = 1e-06; dropout = 0,3; camadas = 2; unidades ocultas = 320; agregação = média; δ de Huber = 2
LSTM direta (L1 pond., HPO própria)	24	16	4	taxa de aprendizado = 0,007; decaimento de pesos = 1e-06; dropout = 0,05; camadas = 2; unidades ocultas = 192; agregação = atenção; δ de Huber = 1
LSTM recursiva (Huber)	24	14	4	taxa de aprendizado = 0,0018; decaimento de pesos = 5e-06; dropout = 0,05; camadas = 3; unidades ocultas = 320; δ de Huber = 1
Seq2Seq atenção padrão (Huber)	24	16	4	taxa de aprendizado = 0,0025; decaimento de pesos = 5e-05; dropout = 0,15; camadas = 1; unidades do codificador = 160; unidades do decodificador = 160; unidades da atenção = 128; dimensão do horizonte = 16; δ de Huber = 0,5
Seq2Seq atenção adaptado (Huber)	24	13	4	taxa de aprendizado = 0,007; decaimento de pesos = 5e-05; dropout = 0,3; camadas = 1; unidades do codificador = 128; unidades do decodificador = 160; unidades da atenção = 64; dimensão do horizonte = 8; δ de Huber = 1
Seq2Seq atenção adaptado (L1 pond., HPO própria)	24	15	4	taxa de aprendizado = 0,007; decaimento de pesos = 1e-06; dropout = 0,3; camadas = 3; unidades do codificador = 160; unidades do decodificador = 160; unidades da atenção = 96; dimensão do horizonte = 24; δ de Huber = 0,5
Seq2Seq básico (Huber)	24	12	4	taxa de aprendizado = 0,0018; decaimento de pesos = 5e-05; dropout = 0,05; camadas = 3; unidades ocultas = 96; δ de Huber = 1,5
XGBoost (erro abs.)	24	0	–	árvores = 320; taxa de aprendizado = 0,07453; max_bin = 128; profundidade = 2; peso mínimo do filho = 0,6743; subsample = 0,6126; colsample = 0,8546; λ = 0,7432; α = 1,126e-05; γ = 0,09712; parada antecipada = 25
XGBoost (erro abs.) [PM10 só no histórico]	24	0	–	árvores = 480; taxa de aprendizado = 0,08094; max_bin = 128; profundidade = 2; peso mínimo do filho = 4,72; subsample = 0,8809; colsample = 0,9092; λ = 1,192; α = 8,888e-05; γ = 4,624e-05; parada antecipada = 25
XGBoost (erro abs.) [só PM2,5 e tempo]	24	0	–	árvores = 320; taxa de aprendizado = 0,07453; max_bin = 128; profundidade = 2; peso mínimo do filho = 0,6743; subsample = 0,6126; colsample = 0,8546; λ = 0,7432; α = 1,126e-05; γ = 0,09712; parada antecipada = 25

o MAE (HYNDMAN; KOEHLER, 2006). Também se reporta o MAE nos horizontes 1 e 24, e a habilidade em relação à média móvel de 24 horas.

Para os picos, definem-se o MAE, o viés e a taxa de subestimação (fração das horas em que a previsão fica abaixo do observado) restritos às horas com PM2,5 acima de 25, 35 e 50 μg/m^3, e a razão entre os desvios-padrão da previsão e da observação, que mede o quanto a previsão é suavizada, além do percentil 99 previsto. O limiar de 35 μg/m^3 é uma escolha de projeto, próxima ao padrão intermediário de 37 μg/m^3 para 24 horas da Resolução CONAMA nº 491/2018 (Conselho Nacional do Meio Ambiente, 2018), e produz eventos em número suficiente; os limiares 25 e 50 verificam a sensibilidade a essa escolha. Um *evento* é uma sequência de horas consecutivas medidas com PM2,5 acima do limiar; para cada evento calculam-se o MAE, o viés, a taxa de subestimação e o erro na hora do pico. A dinâmica horária é avaliada por três medidas sobre pares de horas consecutivas: a correlação entre os níveis, a correlação entre as diferenças de uma hora para a seguinte e a fração de vezes em que a direção da mudança (subida ou descida) é acertada. Elas separam acertar o nível de acertar o momento das mudanças.

Tratamento dos valores preenchidos. As métricas são calculadas somente sobre alvos efetivamente medidos, e a perda de treinamento também os ignora. Esta é uma escolha do trabalho, e não uma convenção geral da área de qualidade do ar. Ela tem precedente em previsão com dados faltantes: Li et al. (2018) excluem os valores ausentes do cálculo do MAE, do RMSE e do MAPE em previsão de tráfego, e Che et al. (2018) tratam a ausência como informação de entrada, na linha dos indicadores de ausência usados aqui. A justificativa é que um alvo preenchido é uma estimativa (aqui, uma interpolação linear); avaliar contra ele mediria a aderência à interpolação, e não ao fenômeno, e favoreceria previsões suaves. Não encontramos trabalho de previsão de PM2,5 que trate explicitamente dessa escolha; por isso ela é uma decisão metodológica, acompanhada de uma análise de sensibilidade (Seção 4.9) que reporta o MAE incluindo os pares preenchidos. As conclusões só são consideradas robustas a essa escolha se a ordenação dos modelos se mantiver. Uma limitação é a possível ausência informativa (falhas do instrumento concentradas em altas concentrações) (LITTLE; RUBIN, 2019), que a exclusão não corrige.

4.8 Inferência Estatística

Cada hora prevista aparece em cerca de 24 janelas sobrepostas, e os erros são autocorrelacionados; tratar os pares como independentes superestimaria a precisão (Seção 2.13). As diferenças entre modelos são avaliadas de três formas.

1. **Bootstrap em blocos, pareado.** Para cada instante de emissão, somam-se os erros absolutos (ou quadráticos) e a quantidade de pares medidos. Sorteiam-se blocos circulares de 168 horas consecutivas (uma semana) (POLITIS; ROMANO, 1992; KÜNSCH, 1989), com os mesmos blocos para os dois modelos comparados e 2.000 repetições, e obtém-se o intervalo de 95% da diferença do MAE (ou do RMSE). Um intervalo que contém zero indica empate estatístico.

2. **Teste de Diebold-Mariano** (DIEBOLD; MARIANO, 1995), sobre a série das diferenças de perda média por instante de emissão, com variância de longo prazo de Newey-West (NEWEY; WEST, 1987) (defasagem 23, que cobre a dependência induzida pelas janelas de 24 horas) e a correção de amostra pequena de Harvey, Leybourne e Newbold (1997).

3. **Bootstrap sobre eventos**, na comparação por evento de pico, sorteando os eventos.

Para estimar a diferença entre famílias de modelos, e não a de uma semente em particular, as comparações usam a média das estatísticas entre as sementes de cada caso; a variabilidade entre sementes é reportada à parte. As comparações são feitas contra duas referências fixadas antes da execução: a LSTM direta com perda de Huber, por ter sido o melhor modelo em etapas exploratórias anteriores, e a média móvel de 24 horas. Todas as tabelas e testes são gerados por um programa a partir das previsões salvas, sem retreinar os modelos.

4.9 Verificações de Sensibilidade

Três verificações testam se as conclusões dependem de escolhas de projeto. A primeira varia a janela de entrada em 24, 48, 72 e 96 horas, com o horizonte fixo em 24 horas, para

a LSTM direta e para o XGBoost; os hiperparâmetros são os do caso de 48 horas, e a comparação usa exclusivamente o MAE de *validação*, de modo que o teste não participa da escolha (Seção 5.9.1). A segunda recalcula o MAE incluindo, além das medições, os pares cujo alvo foi preenchido. A terceira refaz a busca de hiperparâmetros para a perda ponderada na LSTM direta e no Seq2Seq adaptado, para medir o viés de reaproveitar os hiperparâmetros do caso de Huber.

4.10 Diagnóstico da Atenção

Os pesos de atenção nem sempre indicam a importância de uma entrada (JAIN; WALLACE, 2019; SERRANO; SMITH, 2019; WIEGREFFE; PINTER, 2019). Por isso a leitura da atenção usa dois instrumentos. O primeiro são medidas dos pesos: a entropia normalizada (1 para pesos uniformes e menor quando os pesos se concentram), o peso máximo e a fração do peso total (massa) concentrada na última hora, nas últimas seis horas e nas posições do mesmo horário de um e de dois dias antes. Para pesos uniformes sobre 48 posições, cada posição recebe $1/48 \approx 0{,}021$. O segundo é uma contraprova feita sem novo treinamento: os pesos aprendidos são substituídos por pesos uniformes, por pesos uniformes dentro de cada faixa de defasagem, apenas pela última hora, apenas pela posição de 24 ou de 48 horas antes, ou o contexto é zerado, e mede-se a variação do erro. Se um padrão fixo produz erro equivalente ao da atenção aprendida, a atenção aprendida não é decisiva para a previsão, independentemente do seu aspecto. Cinar et al. (2017) argumentam que a atenção de Bahdanau, Cho e Bengio (2014) não atende por si só à sazonalidade de séries temporais; a variante adaptada, com faixas de defasagem alinhadas ao dia anterior, é uma resposta estrutural a essa limitação.

4.11 Reprodutibilidade

Toda a execução é orquestrada por um programa único, com o procedimento definido em arquivos de configuração e testes automatizados que verificam que o treino é idêntico entre os casos e que a construção dos dados não vaza informação posterior ao corte. Cada execução grava as sementes, os hiperparâmetros, o código de identificação dos dados, a

versão do código e a indicação de árvore de código limpa. As tabelas do Capítulo 5 são geradas por programa e incluídas diretamente no texto, sem transcrição manual. O código e os comandos de reprodução acompanham o repositório técnico do trabalho.

5 Resultados e Discussão

Este capítulo apresenta os resultados do procedimento descrito no Capítulo 4. Todas as tabelas e figuras numéricas são geradas por programa a partir das previsões salvas de cada execução e incluídas sem transcrição manual. Os resultados são apresentados em dois períodos. O *período de confirmação* (2021 a 2023) não foi consultado em nenhuma decisão de projeto e é a evidência principal, por isso as tabelas do texto se referem a ele. O *teste histórico* (27 de maio a 31 de dezembro de 2020) já foi consultado durante o desenvolvimento, e suas tabelas estão no Apêndice A; sempre que os dois períodos discordam, isso é indicado.

Nas tabelas de comparação, a diferença de MAE é calculada como o MAE do modelo menos o MAE da referência; valores negativos indicam que o modelo erra menos. O intervalo de confiança (IC) de 95% vem do bootstrap em blocos e o valor-p (DM) vem do teste de Diebold-Mariano (Seção 4.8). A coluna "Veredito" resume a comparação: "melhor" significa que o IC está inteiramente abaixo de zero (o modelo erra menos), "pior" que está inteiramente acima, e "empate estatístico" que o IC contém o zero, isto é, não há evidência de diferença. As médias de MAE da comparação principal são de quatro sementes.

5.1 Comparação Principal

A Tabela 5.1 apresenta as métricas de erro de cada modelo e das referências no período de confirmação, com a mesma preparação, o mesmo orçamento de busca e a mesma perda de Huber (o XGBoost usa o erro absoluto). A última coluna é a habilidade em relação à média móvel de 24 horas: um valor de 0,10 significa erro 10% menor que o dessa referência.

O XGBoost obteve o menor erro em todas as medidas globais: MAE de 2,767 μg/m^3, RMSE de 4,072 e R^2 de 0,640. Em seguida vêm a regressão Ridge (MAE de 2,794), as duas versões do Seq2Seq com atenção (2,870 e 2,876), a LSTM recursiva (2,944), o Seq2Seq básico (2,965) e a LSTM direta (2,979). Entre os modelos treinados, a diferença entre o

Tabela 5.1: Métricas de erro no período de confirmação (2021–2023)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24	Habilidade vs. MM 24 h
LSTM direta (Huber)	2,979	4,324	26,948	31,255	0,594	-0,046	2,864	3,058	0,030
LSTM recursiva (Huber)	2,944	4,195	26,634	31,483	0,618	-0,079	2,824	3,152	0,041
Seq2Seq básico (Huber)	2,965	4,232	26,817	31,633	0,611	-0,017	2,488	3,205	0,035
Seq2Seq atenção padrão (Huber)	2,870	4,096	25,963	30,636	0,636	0,048	2,678	2,962	0,066
Seq2Seq atenção adaptado (Huber)	2,876	4,128	26,016	30,449	0,630	0,190	2,613	2,982	0,064
XGBoost (erro abs.)	2,767	4,072	25,029	29,238	0,640	-0,310	2,291	2,891	0,099
Persistência y(t)	3,831	5,459	34,656	39,931	0,354	-0,069	2,672	3,489	-0,247
Sazonal y(t-24)	3,489	5,131	31,565	36,482	0,429	-0,088	3,490	3,489	-0,136
Sazonal y(t-48)	3,760	5,629	34,014	38,703	0,313	-0,067	3,761	3,760	-0,224
Média móvel 6 h	3,336	4,833	30,178	34,636	0,493	-0,077	2,780	3,254	-0,086
Média móvel 24 h	3,072	4,519	27,785	31,794	0,557	-0,096	2,839	3,223	0,000
Ridge	2,794	4,096	25,276	29,456	0,636	-0,016	2,402	2,940	0,090

melhor e o pior é de 0,212 μg/m^3, cerca de 7,7% do MAE do melhor. Todos superam as referências simples: a média móvel de 24 horas tem MAE de 3,072, e a persistência (repetir o último valor), de 3,831. O XGBoost, por exemplo, tem erro 9,9% menor que a média móvel de 24 horas. O WAPE do melhor modelo é de 25%, isto é, o erro médio é um quarto da concentração média observada.

A Tabela 5.2 mostra as diferenças de MAE em relação à LSTM direta com perda de Huber e em relação à média móvel de 24 horas, as duas referências fixadas antes da execução.

Tabela 5.2: Diferença de MAE em relação à referência, com IC de 95% (bootstrap em blocos): período de confirmação (2021–2023)

Modelo	Referência	Δ MAE	IC inf.	IC sup.	p (bootstrap)	p (DM)	Veredito
LSTM recursiva (Huber)	LSTM direta (Huber)	-0,035	-0,080	0,009	0,125	0,024	empate estatístico
Seq2Seq básico (Huber)	LSTM direta (Huber)	-0,014	-0,065	0,035	0,614	0,461	empate estatístico
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	-0,109	-0,147	-0,072	0,000	0,000	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	-0,103	-0,136	-0,071	0,000	0,000	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	-0,212	-0,255	-0,169	0,000	0,000	melhor
Persistência y(t)	LSTM direta (Huber)	0,852	0,764	0,940	0,000	0,000	pior
Sazonal y(t-24)	LSTM direta (Huber)	0,510	0,435	0,596	0,000	0,000	pior
Sazonal y(t-48)	LSTM direta (Huber)	0,781	0,659	0,928	0,000	0,000	pior
Média móvel 6 h	LSTM direta (Huber)	0,357	0,284	0,429	0,000	0,000	pior
Média móvel 24 h	LSTM direta (Huber)	0,093	0,028	0,157	0,003	0,005	pior
Ridge	LSTM direta (Huber)	-0,185	-0,228	-0,140	0,000	0,000	melhor
LSTM direta (Huber)	Média móvel 24 h	-0,093	-0,157	-0,028	0,003	0,005	melhor
LSTM recursiva (Huber)	Média móvel 24 h	-0,127	-0,209	-0,050	0,000	0,000	melhor
Seq2Seq básico (Huber)	Média móvel 24 h	-0,107	-0,197	-0,026	0,011	0,001	melhor
Seq2Seq atenção padrão (Huber)	Média móvel 24 h	-0,201	-0,275	-0,134	0,000	0,000	melhor
Seq2Seq atenção adaptado (Huber)	Média móvel 24 h	-0,196	-0,268	-0,128	0,000	0,000	melhor
XGBoost (erro abs.)	Média móvel 24 h	-0,305	-0,368	-0,250	0,000	0,000	melhor

Observe que o XGBoost erra menos que a LSTM direta em 0,212 (IC de $-0,255$ a $-0,169$) e que as duas versões do Seq2Seq com atenção erram cerca de 0,10 menos; a LSTM recursiva e o Seq2Seq básico empatam com a LSTM direta. Todos os modelos treinados erram menos que a média móvel de 24 horas, com diferenças de $-0,09$ (LSTM direta) a $-0,30$ (XGBoost), com IC que exclui o zero.

As comparações entre todos os pares (Apêndice A, Tabela A.4) mostram um

único empate com o melhor modelo: o XGBoost e a regressão Ridge têm diferença de $-0,027$ (IC de $-0,074$ a $0,007$), isto é, não é possível afirmar que um erra menos que o outro. Já o XGBoost erra menos que as duas versões do Seq2Seq com atenção (diferenças de 0,103 e 0,109), e a Ridge também erra menos que ambas (0,076 e 0,082, com IC que exclui o zero). As duas versões do Seq2Seq com atenção empatam entre si (diferença de $-0,006$, IC de $-0,028$ a $0,013$).

O *ensemble* (média das previsões das quatro sementes; Tabela 5.3) reduz o MAE em 0,01 a 0,06, conforme o modelo, mas não altera a ordenação: o XGBoost continua na frente (2,753). No teste histórico, o quadro é semelhante: a Ridge (2,673), o XGBoost (2,696) e o Seq2Seq com atenção adaptado (2,721) têm MAE próximos e sem diferença estatística entre si, e o Seq2Seq com atenção padrão fica atrás da Ridge.

Tabela 5.3: Ensemble das sementes (média das previsões): período de confirmação (2021–2023)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24
LSTM direta (Huber)	2,945	4,266	26,642	30,974	0,605	-0,046	2,829	3,025
LSTM recursiva (Huber)	2,914	4,158	26,358	31,134	0,625	-0,079	2,807	3,106
Seq2Seq básico (Huber)	2,902	4,139	26,248	30,960	0,628	-0,017	2,441	3,112
Seq2Seq atenção padrão (Huber)	2,841	4,059	25,699	30,338	0,643	0,048	2,629	2,936
Seq2Seq atenção adaptado (Huber)	2,841	4,079	25,695	30,127	0,639	0,190	2,574	2,947
XGBoost (erro abs.)	2,753	4,056	24,907	29,101	0,643	-0,310	2,280	2,878

Em resumo, não há vencedor entre o XGBoost e a regressão linear, e nenhuma rede neural erra menos que eles. A escolha do modelo de aprendizado alterou o MAE em pouco mais de 7%, uma diferença estatisticamente detectável, mas pequena.

5.2 Referências Simples e Regressão Linear

As linhas dos previsores ingênuos e da Ridge na Tabela 5.1 respondem se os modelos de aprendizado agregam valor. Sobre os previsores ingênuos, a resposta é sim: todos os modelos treinados têm MAE menor que o da melhor referência ingênua (a média móvel de 24 horas). A resposta é menos favorável quando a comparação é com a regressão Ridge, uma relação linear entre os 1.992 atributos e o valor a prever. Ela tem erro só 1% maior que o do XGBoost, sem diferença estatística, e erra menos que todas as redes neurais treinadas. Portanto, nesta série, a relação entre o histórico e o valor futuro é

bem capturada por um modelo linear, e os modelos não lineares (árvores e redes) não acrescentam ganho mensurável além dele.

5.3 Erro por Horizonte

A Figura 5.1 mostra o MAE em função do horizonte de previsão (1 a 24 horas). Observe que as linhas contínuas são os modelos treinados e as tracejadas, as referências.

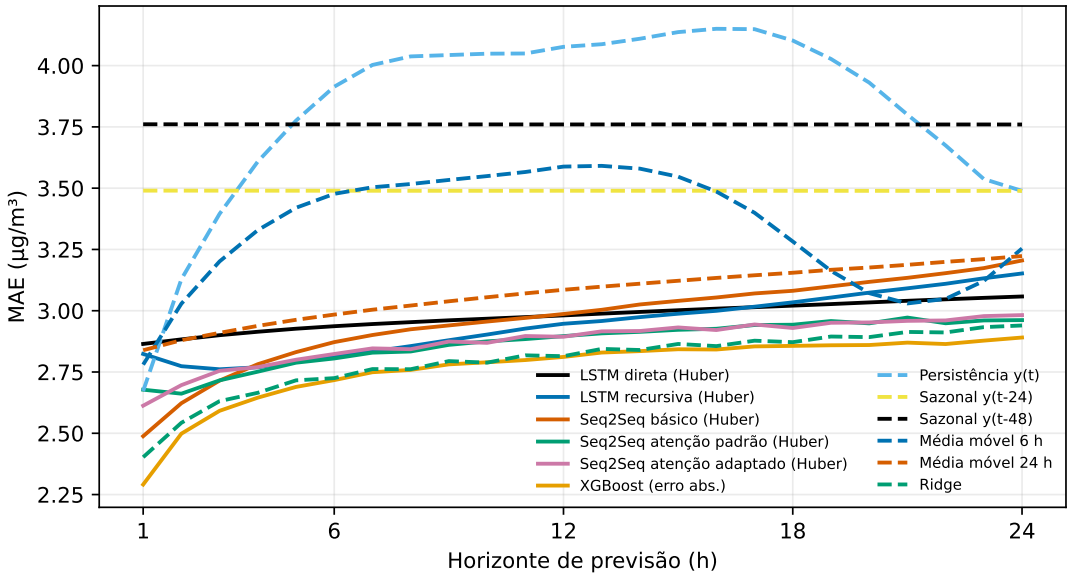


Figura 5.1: MAE por horizonte no período de confirmação (média das sementes). Linhas tracejadas: previsores de referência e regressão Ridge.

O erro cresce de forma lenta com o horizonte. Para o XGBoost, o MAE vai de 2,29 em 1 hora a 2,89 em 24 horas, um aumento de 26%; para o Seq2Seq com atenção adaptado, de 2,61 a 2,98. No primeiro horizonte, o XGBoost erra 14% menos que a persistência (2,29 contra 2,67), e a Ridge tem 2,40. A LSTM direta, por sua vez, tem erro quase constante (2,86 em 1 hora e 3,06 em 24 horas) e, nas primeiras horas, erra mais que a persistência: ao resumir a janela em um vetor único, ela parece perder precisão sobre o valor mais recente, o que os modelos que recebem o último valor observado no decodificador preservam. A LSTM recursiva e o Seq2Seq básico erram menos no início e mais no fim do horizonte (3,15 e 3,21 em 24 horas, contra 2,89 do XGBoost), o que é coerente com o acúmulo de erro típico das estratégias que realimentam a previsão. A ordenação entre os modelos no horizonte de 24 horas é a mesma da comparação global.

5.4 Picos, Cauda e Suavização

Modelos treinados com erro absoluto ou perda de Huber tendem a prever a mediana condicional (GNEITING, 2011) e, por isso, produzem séries mais suaves que a observada e subestimam valores altos. A Tabela 5.4 apresenta o MAE nas horas em que o PM2,5 observado excede 25, 35 e 50 μg/m^3, a fração dessas horas em que o modelo subestima, a razão entre os desvios-padrão previsto e observado, e o percentil 99 da previsão (o observado é 33).

Tabela 5.4: Métricas de cauda e amplitude no período de confirmação (2021–2023)

Modelo	MAE ≥25	MAE ≥35	MAE ≥50	Subestim. ≥35	Razão DP	p99 prev.	p99 obs.
LSTM direta (Huber)	11,854	21,031	35,487	0,987	0,746	27,180	33,000
LSTM recursiva (Huber)	10,633	19,398	33,621	0,988	0,791	27,861	33,000
Seq2Seq básico (Huber)	10,668	18,302	31,596	0,935	0,800	29,073	33,000
Seq2Seq atenção padrão (Huber)	10,368	18,399	31,828	0,978	0,791	28,742	33,000
Seq2Seq atenção adaptado (Huber)	10,681	19,224	32,616	0,977	0,774	27,898	33,000
XGBoost (erro abs.)	10,263	18,784	31,905	0,975	0,801	27,025	33,000
Persistência y(t)	11,658	17,166	24,818	0,844	1,011	33,000	33,000
Sazonal y(t-24)	11,384	19,492	33,372	0,913	0,989	32,000	33,000
Sazonal y(t-48)	11,568	19,705	32,023	0,863	1,011	33,000	33,000
Média móvel 6 h	11,502	17,540	26,522	0,897	0,924	30,667	33,000
Média móvel 24 h	11,564	18,778	30,345	0,940	0,854	30,208	33,000
Ridge	9,954	16,983	29,870	0,946	0,831	29,916	33,000

Todos os modelos subestimam de forma sistemática as horas de concentração alta. O MAE acima de 35 μg/m^3 fica entre 17 e 21, isto é, cerca de metade do valor típico de um evento, e o modelo prevê valor abaixo do observado em 93% a 100% dessas horas. A razão entre os desvios-padrão fica entre 0,75 e 0,83 para os modelos treinados, e o percentil 99 previsto (27 a 30) fica abaixo do observado (33). A persistência e os previsores sazonais, que repetem valores passados, preservam a amplitude (razão próxima de 1), mas erram o momento dos picos.

A Tabela 5.5 e a Figura 5.2 descrevem os eventos, isto é, sequências contínuas de horas com PM2,5 acima do limiar. O período de confirmação tem 58 eventos acima de 35 μg/m^3 e 243 acima de 25 μg/m^3.

No nível dos eventos, o MAE por evento acima de 35 fica entre 16,5 (Seq2Seq básico) e 19,0 (LSTM direta). A persistência (16,6) e a Ridge (16,8) estão entre os melhores, o que mostra que nenhum modelo treinado antecipa os picos melhor do que simplesmente repetir o último valor. Na comparação por evento com a LSTM direta (Tabela 5.6), todos os modelos treinados erram menos, mas a persistência também erra.

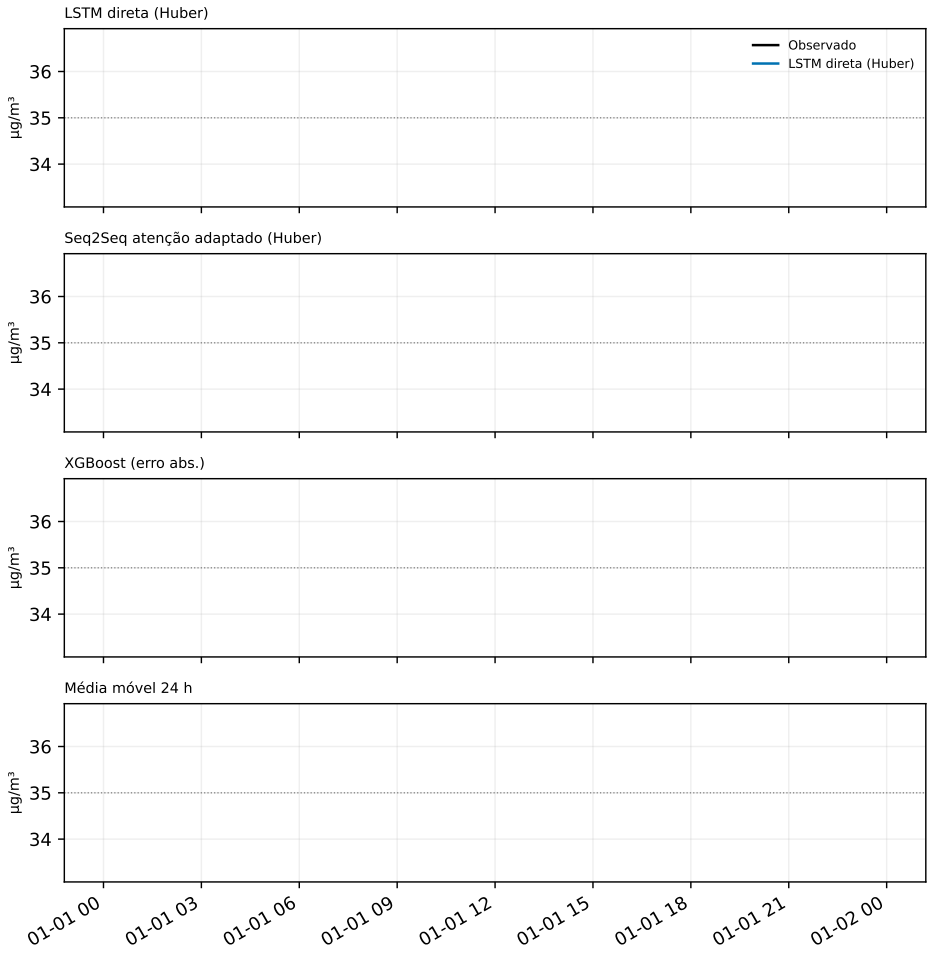


Figura 5.2: Previsões (média das sementes) em torno do maior evento do período de confirmação, em painéis separados por modelo e com escala comum. Observe que a linha tracejada horizontal marca 35 μg/m^3 e que as lacunas da série observada aparecem como quebras na linha.

Tabela 5.5: Desempenho nos eventos de pico: período de confirmação (2021–2023)

Modelo	Limiar	Eventos	MAE por evento	Viés no evento	Subestimação	Erro no pico
LSTM direta (Huber)	35	58	18,964	-18,938	0,995	-22,499
LSTM recursiva (Huber)	35	58	17,233	-17,197	0,989	-20,632
Seq2Seq básico (Huber)	35	58	16,493	-16,286	0,952	-19,802
Seq2Seq atenção padrão (Huber)	35	58	16,835	-16,789	0,987	-20,243
Seq2Seq atenção adaptado (Huber)	35	58	17,403	-17,324	0,987	-20,710
XGBoost (erro abs.)	35	58	18,055	-18,055	1,000	-21,612
Persistência y(t)	35	58	16,566	-15,470	0,921	-18,909
Sazonal y(t-24)	35	58	18,611	-15,352	0,886	-18,879
Sazonal y(t-48)	35	58	19,167	-16,707	0,894	-20,224
Média móvel 6 h	35	58	17,427	-16,187	0,927	-19,664
Média móvel 24 h	35	58	18,758	-17,635	0,948	-21,164
Ridge	35	58	16,812	-16,172	0,966	-19,663
LSTM direta (Huber)	25	243	10,234	-9,675	0,925	-11,692
LSTM recursiva (Huber)	25	243	9,041	-8,397	0,902	-10,283
Seq2Seq básico (Huber)	25	243	9,228	-8,287	0,895	-10,221
Seq2Seq atenção padrão (Huber)	25	243	8,955	-8,130	0,890	-10,034
Seq2Seq atenção adaptado (Huber)	25	243	9,046	-8,324	0,902	-10,206
XGBoost (erro abs.)	25	243	9,417	-8,943	0,930	-10,926
Persistência y(t)	25	243	10,564	-8,728	0,884	-10,773
Sazonal y(t-24)	25	243	10,184	-6,225	0,784	-7,852
Sazonal y(t-48)	25	243	10,720	-7,970	0,797	-9,601
Média móvel 6 h	25	243	10,863	-8,806	0,875	-10,855
Média móvel 24 h	25	243	11,120	-9,083	0,871	-11,146
Ridge	25	243	9,396	-7,773	0,884	-9,704

As diferenças entre modelos nos picos são, portanto, pequenas diante do tamanho do erro de todos eles.

Tabela 5.6: Diferença de MAE por evento em relação à referência: período de confirmação (2021–2023)

Modelo	Referência	Limiar	Δ MAE por evento	IC inf.	IC sup.	Vitórias	Eventos	Veredito
LSTM recursiva (Huber)	LSTM direta (Huber)	35	-1,731	-2,406	-1,022	39	58	melhor
Seq2Seq básico (Huber)	LSTM direta (Huber)	35	-2,471	-3,273	-1,625	48	58	melhor
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	35	-2,129	-2,598	-1,664	53	58	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	35	-1,561	-2,070	-1,039	47	58	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	35	-0,908	-1,487	-0,351	37	58	melhor
Persistência y(t)	LSTM direta (Huber)	35	-2,397	-3,771	-1,099	36	58	melhor
Sazonal y(t-24)	LSTM direta (Huber)	35	-0,353	-1,734	1,142	33	58	empate estatístico
Sazonal y(t-48)	LSTM direta (Huber)	35	0,203	-1,425	1,772	25	58	empate estatístico
Média móvel 6 h	LSTM direta (Huber)	35	-1,536	-2,793	-0,351	32	58	melhor
Média móvel 24 h	LSTM direta (Huber)	35	-0,205	-1,036	0,653	28	58	empate estatístico
Ridge	LSTM direta (Huber)	35	-2,151	-2,834	-1,528	48	58	melhor
LSTM recursiva (Huber)	LSTM direta (Huber)	25	-1,193	-1,450	-0,948	182	243	melhor
Seq2Seq básico (Huber)	LSTM direta (Huber)	25	-1,006	-1,333	-0,667	168	243	melhor
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	25	-1,279	-1,494	-1,052	188	243	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	25	-1,188	-1,403	-0,975	190	243	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	25	-0,817	-1,055	-0,590	164	243	melhor
Persistência y(t)	LSTM direta (Huber)	25	0,330	-0,167	0,867	107	243	empate estatístico
Sazonal y(t-24)	LSTM direta (Huber)	25	-0,049	-0,820	0,834	136	243	empate estatístico
Sazonal y(t-48)	LSTM direta (Huber)	25	0,486	-0,254	1,254	111	243	empate estatístico
Média móvel 6 h	LSTM direta (Huber)	25	0,629	0,135	1,166	99	243	pior
Média móvel 24 h	LSTM direta (Huber)	25	0,886	0,427	1,373	91	243	pior
Ridge	LSTM direta (Huber)	25	-0,838	-1,175	-0,479	175	243	melhor

5.4.1 Dinâmica Horária

Preservar a amplitude não garante acertar o momento das variações. A Tabela 5.7 mostra a correlação entre os níveis previsto e observado, a correlação entre as variações de uma

hora para a seguinte, e a fração de vezes em que a direção da mudança é acertada.

Tabela 5.7: Dinâmica horária: período de confirmação (2021–2023)

Modelo	Corr. nível	Corr. diferenças	Acerto de direção	DP dif. obs.	DP dif. prev.
LSTM direta (Huber)	0,778	0,131	0,545	3,695	0,814
LSTM recursiva (Huber)	0,795	0,174	0,558	3,695	0,839
Seq2Seq básico (Huber)	0,803	0,147	0,544	3,695	0,906
Seq2Seq atenção padrão (Huber)	0,805	0,146	0,543	3,695	0,976
Seq2Seq atenção adaptado (Huber)	0,803	0,153	0,547	3,695	0,968
XGBoost (erro abs.)	0,815	0,128	0,544	3,695	0,780
Persistência y(t)	0,800	-0,332	0,315	3,695	0,212
Sazonal y(t-24)	0,711	0,069	0,430	3,695	3,595
Sazonal y(t-48)	0,660	0,072	0,423	3,695	3,600
Média móvel 6 h	0,785	-0,118	0,439	3,695	0,152
Média móvel 24 h	0,763	-0,052	0,474	3,695	0,109
Ridge	0,806	0,162	0,557	3,695	0,739

A correlação entre os níveis é alta (0,78 a 0,81 nos modelos treinados), pois o modelo acompanha o nível médio. Porém, a correlação entre as variações horárias é baixa: de 0,13 a 0,17 nos modelos treinados, contra $-0,33$ da persistência, e a direção da mudança é acertada em 54% a 56% das horas. O desvio-padrão das variações previstas (0,74 a 0,98) é muito menor que o das observadas (3,70). Assim, nenhum modelo acompanha as oscilações de hora em hora: eles acertam o nível diário, mas não o momento exato das variações.

5.5 Efeito da Função de Perda

Em etapas exploratórias anteriores, a vantagem do Seq2Seq adaptado em picos foi atribuída à combinação de arquitetura, perda ponderada e perda auxiliar. Como a perda ponderada foi aplicada a todas as arquiteturas, a Tabela 5.8 separa o efeito da perda: para cada arquitetura, a diferença de MAE entre a perda ponderada e a de Huber, com intervalo de confiança pareado.

Tabela 5.8: Efeito da perda por arquitetura (L1 ponderada - Huber): período de confirmação (2021–2023)

Arquitetura	MAE Huber	MAE L1 pond.	Δ MAE	IC inf.	IC sup.	Veredito
LSTM direta	2,965	2,971	0,007	-0,008	0,022	empate estatístico
LSTM recursiva	2,940	2,935	-0,005	-0,024	0,012	empate estatístico
Seq2Seq básico	2,968	2,953	-0,015	-0,047	0,021	empate estatístico
Seq2Seq atenção padrão	2,877	2,879	0,002	-0,007	0,013	empate estatístico
Seq2Seq atenção adaptado	2,884	2,835	-0,049	-0,064	-0,032	melhor

A perda ponderada não altera o MAE de quatro das cinco arquiteturas (empate estatístico). Em uma delas, o Seq2Seq adaptado, reduz o MAE em 0,049 (IC de $-0,064$ a $-0,032$), o que equivale a 1,7%. O efeito nos picos é pequeno: o MAE acima de 35 cai de 21,3 para 20,4 na LSTM direta, de 19,7 para 18,4 na recursiva, de 18,5 para 17,7 no Seq2Seq padrão e de 19,3 para 18,9 no adaptado (Tabela 5.9), e a razão entre os desvios-padrão sobe de 0,01 a 0,04. Portanto, a perda ponderada melhora modestamente os picos sem piorar o erro médio no período de confirmação. No teste histórico, ela piora o MAE da LSTM recursiva e do Seq2Seq básico, e portanto o efeito não é consistente entre arquiteturas e períodos.

Tabela 5.9: Fatores (perda, resíduo e evento), métricas de cauda: período de confirmação (2021–2023)

Modelo	MAE ≥25	MAE ≥35	MAE ≥50	Subestim. ≥35	Razão DP	p99 prev.	p99 obs.
LSTM direta (L1 pond.)	11,622	20,363	35,036	0,992	0,764	28,363	33,000
LSTM recursiva (L1 pond.)	10,242	18,441	32,886	0,976	0,824	29,021	33,000
Seq2Seq básico (L1 pond.)	11,413	17,972	29,936	0,894	0,821	30,827	33,000
Seq2Seq atenção padrão (L1 pond.)	10,316	17,671	30,488	0,951	0,798	29,390	33,000
Seq2Seq atenção adaptado (L1 pond.)	10,617	18,883	32,182	0,973	0,793	28,228	33,000
Seq2Seq atenção adaptado (L1 pond. + evento)	10,606	18,640	31,838	0,961	0,802	28,428	33,000
LSTM direta (Huber + resíduo)	10,845	18,704	32,058	0,947	0,851	28,860	33,000
Seq2Seq atenção adaptado (Huber + resíduo)	10,811	18,067	30,980	0,907	0,845	30,237	33,000
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	10,901	18,340	31,869	0,918	0,839	29,814	33,000

5.6 Fatores Adicionais e Desenho do Seq2Seq

A Tabela 5.10 mostra o efeito da perda auxiliar de evento e do aprendizado residual, e a Tabela 5.11 remove, uma de cada vez, as quatro alterações que distinguem o Seq2Seq adaptado do padrão (Seção 4.5), mantendo os hiperparâmetros do modelo completo.

Tabela 5.10: Efeito isolado de fatores adicionais: período de confirmação (2021–2023)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
Seq2Seq atenção adaptado (L1 pond. + evento)	Seq2Seq atenção adaptado (L1 pond.)	2,814	2,835	-0,021	-0,033	-0,011	melhor
LSTM direta (Huber + resíduo)	LSTM direta (Huber)	2,969	2,965	0,004	-0,037	0,044	empate estatístico
Seq2Seq atenção adaptado (Huber + resíduo)	Seq2Seq atenção adaptado (Huber)	2,946	2,884	0,063	0,018	0,112	pior
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	Seq2Seq atenção adaptado (L1 pond. + evento)	2,914	2,814	0,099	0,065	0,144	pior

Tabela 5.11: Ablação de cada elemento do desenho do Seq2Seq adaptado: período de confirmação (2021–2023)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
Seq2Seq atenção adaptado (sem reinício por horizonte)	Seq2Seq atenção adaptado (Huber)	2,877	2,884	-0,006	-0,021	0,009	empate estatístico
Seq2Seq atenção adaptado (com input feeding)	Seq2Seq atenção adaptado (Huber)	2,884	2,884	0,000	-0,012	0,012	empate estatístico
Seq2Seq atenção adaptado (sem faixas de defasagem)	Seq2Seq atenção adaptado (Huber)	2,898	2,884	0,014	0,001	0,028	pior
Seq2Seq atenção adaptado (consulta sem horizonte/exógenas)	Seq2Seq atenção adaptado (Huber)	2,883	2,884	-0,001	-0,014	0,014	empate estatístico

O aprendizado residual não ajuda: na LSTM direta não há diferença (+0,004, empate) e, no Seq2Seq adaptado, o MAE aumenta em 0,063 (IC de 0,018 a 0,112). Acrescentá-lo à combinação de perda ponderada e perda de evento piora em 0,099. Uma explicação possível é que a base sobre a qual o modelo aprende a correção, uma média de valores passados, é menos precisa que o próprio modelo, de modo que a correção precisa compensar o erro dela. A perda auxiliar de evento reduz o MAE em 0,021 sobre a perda ponderada (IC de $-0,033$ a $-0,011$), um ganho pequeno.

Na ablação do desenho, remover o reinício do estado do decodificador, acrescentar o *input feeding* ou remover o condicionamento da consulta ao horizonte não altera o MAE (empates). Remover as faixas de defasagem o aumenta em 0,015 (IC de 0,001 a 0,028), um efeito quase no limite da significância. No teste histórico, remover o reinício e o condicionamento da consulta chega a reduzir o MAE, com sinal oposto. Portanto, entre as quatro alterações, só as faixas de defasagem têm efeito distinguível de zero no período de confirmação, e ele é pequeno. Isso é coerente com o empate entre as duas versões do Seq2Seq com atenção observado na Seção 5.1.

5.7 Variáveis Derivadas do PM10

A Tabela 5.12 compara o conjunto completo de variáveis com duas remoções: o PM10 apenas no histórico, sem as duas variáveis derivadas dele para o futuro, e a remoção completa do PM10. Cada conjunto tem sua própria busca de hiperparâmetros, de modo que o conjunto completo não é favorecido.

Para a LSTM direta, nenhuma remoção altera o MAE. Para o XGBoost, a remoção das variáveis derivadas aumenta o MAE em 0,010 (IC de 0,006 a 0,014), e a

Tabela 5.12: Ablação das variáveis de PM10: período de confirmação (2021–2023)

Modelo	Variáveis	Sementes	Δ MAE vs. completo	IC inf.	IC sup.	Veredito
LSTM direta	PM10 só no histórico	3	-0,007	-0,045	0,038	empate estatístico
LSTM direta	só PM2,5 e tempo	3	-0,015	-0,059	0,036	empate estatístico
XGBoost	PM10 só no histórico	3	0,010	0,006	0,013	pior
XGBoost	só PM2,5 e tempo	3	0,016	0,010	0,021	pior

remoção do PM10 em 0,016 (IC de 0,010 a 0,022). Esses aumentos são estatisticamente distinguíveis de zero, mas equivalem a menos de 1% do MAE e não têm importância prática. O PM10 medido pelo mesmo sensor traz, portanto, quase nenhuma informação adicional sobre o PM2,5 futuro.

5.8 Interpretação da Atenção

Para testar se a atenção do Seq2Seq adaptado é funcionalmente relevante, aplicou-se a contraprova da Seção 4.10, sem retreinar. A Tabela 5.14 mostra o erro quando os pesos aprendidos são substituídos por padrões fixos, e a Tabela 5.13 compara as medidas dos pesos aprendidos com as dos pesos uniformes.

Tabela 5.13: Diagnóstico da atenção aprendida frente a pesos uniformes (Seq2Seq atenção adaptado (Huber))

Medida	aprendida	uniforme por faixa	uniforme por posição
Entropia normalizada	0,834	0,841	1,000
Peso máximo	0,207	0,207	0,021
Massa nas 3 maiores posições	0,319	0,310	0,062
Massa na última hora	0,207	0,207	0,021
Massa nas últimas 6 horas	0,414	0,417	0,125
Massa no mesmo horário do dia anterior	0,055	0,055	0,021
Massa no mesmo horário de dois dias antes	0,042	0,042	0,021

Observe que zerar o contexto de atenção aumenta o MAE em 2,25 no período de confirmação (de 2,88 para 5,13): o modelo depende das informações que a atenção entrega. Já substituir os pesos por pesos uniformes sobre as 48 posições aumenta o erro em 0,15, e usar apenas a última hora, o mesmo horário do dia anterior ou o de dois dias antes o aumenta em 0,37, 0,48 e 0,76, respectivamente. O resultado mais informativo, porém, é a substituição por pesos uniformes *dentro das seis faixas de defasagem*: o MAE aumenta em apenas 0,027 (1%). As medidas dos pesos confirmam: a entropia normalizada dos pesos aprendidos (0,834) é quase igual à dos pesos uniformes por faixa (0,841), e as massas na

Tabela 5.14: Contraprova da atenção (Seq2Seq atenção adaptado (Huber))

Período	Pesos usados	MAE	Δ MAE vs. aprendida	MAE ≥35	Mudança média da previsão
confirmação	aprendidos	2,876	0,000	19,222	0,000
confirmação	uniformes	3,026	0,150	19,513	0,770
confirmação	uniformes por faixa	2,903	0,027	18,701	0,224
confirmação	só a última hora	3,243	0,367	17,717	1,669
confirmação	só 24 h antes	3,354	0,478	19,571	1,647
confirmação	só 48 h antes	3,633	0,757	19,608	1,981
confirmação	contexto zerado	5,127	2,251	32,269	4,145
teste histórico	aprendidos	2,721	0,000	13,293	0,000
teste histórico	uniformes	2,856	0,135	13,892	0,791
teste histórico	uniformes por faixa	2,733	0,012	13,138	0,183
teste histórico	só a última hora	3,181	0,460	12,095	1,713
teste histórico	só 24 h antes	3,198	0,477	12,613	1,682
teste histórico	só 48 h antes	3,510	0,789	14,696	2,012
teste histórico	contexto zerado	4,271	1,550	27,470	3,592

última hora (0,207) e nas últimas seis horas (0,414 contra 0,417) também. Ou seja, a estrutura de seis faixas fornece quase todo o ganho, e a ponderação aprendida acrescenta pouco. Isso é coerente com o resultado da ablação, em que as faixas de defasagem são a única peça com efeito mensurável. Os pesos, porém, não devem ser lidos como uma explicação causal do modelo (JAIN; WALLACE, 2019): o que a contraprova mostra é o efeito no erro, não a razão pela qual o modelo prevê como prevê.

5.9 Sensibilidades

5.9.1 Janela de Entrada

A Tabela 5.15 mostra o MAE de validação para janelas de 24, 48, 72 e 96 horas (o teste não participa desta escolha). Para a LSTM direta, a janela de 48 horas tem o menor erro (2,808), contra 2,842 com 24 horas, 2,832 com 72 e 2,829 com 96; as diferenças (0,02 a 0,03) são da ordem do desvio entre sementes (0,01 a 0,03). Para o XGBoost, o erro diminui com janelas maiores: 2,845 com 24 horas, 2,804 com 48, 2,787 com 72 e 2,772 com 96. A janela de 48 horas não é a ideal para o XGBoost, mas ganhar 0,03 (1%) com uma janela de 96 horas é uma diferença pequena diante das demais deste capítulo, e não altera a ordenação entre as duas famílias na validação. A conclusão principal, portanto, não depende da janela na faixa testada.

Tabela 5.15: Sensibilidade à janela de entrada (MAE de validação, horizonte fixo de 24 h)

Modelo	Janela (h)	MAE validação	DP	Sementes
LSTM direta	24	2,842	0,010	3
LSTM direta	48	2,808	0,026	4
LSTM direta	72	2,832	0,007	3
LSTM direta	96	2,829	0,024	3
XGBoost	24	2,845	0,003	3
XGBoost	48	2,804	0,001	4
XGBoost	72	2,787	0,002	3
XGBoost	96	2,772	0,001	3

5.9.2 Alvos Preenchidos, Busca de Hiperparâmetros e Vencedores

A Tabela 5.16 repete o cálculo do MAE incluindo, além das medições, os pares cujo alvo foi preenchido por interpolação. O erro sobre os alvos preenchidos é maior que o erro nos medidos para a maioria dos modelos (por exemplo, 3,54 contra 2,98 na LSTM direta); o XGBoost é exceção (2,51 contra 2,77). Isso mostra que o resultado sobre valores preenchidos depende de quanto o modelo se assemelha à interpolação, e não do fenômeno. A ordenação dos três melhores modelos se mantém (XGBoost, Seq2Seq padrão e adaptado); a LSTM recursiva e o Seq2Seq básico trocam de posição entre si. No teste histórico, a ordenação é idêntica. A conclusão, portanto, é robusta à exclusão dos alvos preenchidos.

Tabela 5.16: Sensibilidade às métricas com alvos imputados: período de confirmação (2021–2023)

Modelo	Pares observados	Pares imputados	MAE observados	MAE imputados	MAE todos	Posição (observados)	Posição (todos)
LSTM direta (Huber)	549252	81168	2,979	3,535	3,051	6	6
LSTM recursiva (Huber)	549252	81168	2,944	3,271	2,986	4	5
Seq2Seq básico (Huber)	549252	81168	2,965	3,103	2,982	5	4
Seq2Seq atenção padrão (Huber)	549252	81168	2,870	3,087	2,898	2	2
Seq2Seq atenção adaptado (Huber)	549252	81168	2,876	3,398	2,943	3	3
XGBoost (erro abs.)	549252	81168	2,767	2,511	2,734	1	1

A Tabela 5.17 mostra o efeito de refazer a busca de hiperparâmetros para a perda ponderada, em vez de reaproveitar os do caso de Huber. Em ambas as arquiteturas, a diferença é estatisticamente indistinguível de zero ($-0,004$ na LSTM direta e $+0,006$ no Seq2Seq adaptado), o que indica que o reaproveitamento não distorce as conclusões sobre o efeito da perda.

A Tabela 5.18 resume o melhor modelo em cada critério. O XGBoost é o melhor

Tabela 5.17: Efeito de refazer a busca de hiperparâmetros para a perda ponderada: período de confirmação (2021–2023)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
LSTM direta (L1 pond., HPO própria)	LSTM direta (L1 pond.)	2,967	2,971	-0,004	-0,022	0,013	empate estatístico
Seq2Seq atenção adaptado (L1 pond., HPO própria)	Seq2Seq atenção adaptado (L1 pond.)	2,841	2,835	0,006	-0,014	0,025	empate estatístico

em todas as medidas globais e nos horizontes 1 e 24, empatado com a Ridge no MAE. O Seq2Seq básico é o melhor nas métricas de pico e no viés, com margens que não são estatisticamente relevantes diante do erro de todos os modelos nos picos.

Tabela 5.18: Melhor modelo por critério: período de confirmação (2021–2023)

Critério	Melhor	Valor	Empate estatístico com
MAE	XGBoost (erro abs.)	2,767	Ridge
RMSE	XGBoost (erro abs.)	4,072	—
R^2	XGBoost (erro abs.)	0,640	—
WAPE	XGBoost (erro abs.)	25,029	—
MAE H1	XGBoost (erro abs.)	2,291	—
MAE H24	XGBoost (erro abs.)	2,891	—
MAE pico ≥35	Seq2Seq básico (Huber)	18,302	—
MAE por evento	Seq2Seq básico (Huber)	16,493	—
—1 - razão de desvios—	XGBoost (erro abs.)	0,199	—
—viés—	Seq2Seq básico (Huber)	0,017	—

5.10 O Que Limita a Qualidade da Previsão

Três resultados apontam na mesma direção. Primeiro, modelos de famílias muito diferentes (regressão linear, árvores e redes com e sem atenção) terminam com MAE dentro de uma faixa estreita, de 2,77 a 2,98 no período de confirmação, e o modelo mais simples entre os treinados, a Ridge, empata com o melhor. Segundo, o erro já é alto na previsão de uma hora à frente: 2,29 μg/m^3 para o melhor modelo, cerca de 21% da concentração média (11,05), e o aumento até 24 horas é de apenas 26%. Terceiro, o PM10 medido pela mesma estação pouco contribui (menos de 1% do MAE), e nenhum modelo acompanha as oscilações de hora em hora ou os picos, que são subestimados em quase todas as horas.

Uma leitura compatível com esses resultados é que a informação contida no histórico de PM2,5 e PM10 e no calendário é o limite da previsão: a estação não mede variáveis meteorológicas, e estudos em outras cidades indicam que elas, como a altura

da camada limite atmosférica, são as variáveis mais importantes para explicar o PM2,5 (CHAVES et al., 2024). Esta é uma hipótese consistente com os dados, e não uma conclusão testada neste trabalho, pois testá-la exigiria variáveis meteorológicas que a estação não fornece. O que os resultados mostram, de forma direta, é que trocar de arquitetura ou de função de perda altera o erro em poucos por cento, e que nenhuma delas resolve a imprevisibilidade dos picos e das oscilações horárias.

5.11 Ameaças à Validade

Há limitações que condicionam a leitura dos resultados. Primeiro, o estudo usa uma única estação, o que limita a generalização espacial. Segundo, o teste histórico foi consultado em etapas anteriores e não é confirmatório; o período de confirmação é a única evidência independente, e cobre apenas três anos, com nível médio de PM2,5 variável entre eles. Terceiro, os fatores que reaproveitam os hiperparâmetros do caso de Huber podem subestimar o potencial de cada variante, embora a verificação da Seção 5.9.2 não tenha encontrado viés em duas arquiteturas. Quarto, quatro sementes fornecem pouca precisão para inferência entre famílias; o bootstrap incorpora a incerteza da amostra de teste, mas não a de novas inicializações além das quatro usadas. Quinto, o número de eventos de pico é limitado (58 acima de 35 μg/m^3 no período de confirmação), e quase não há valores acima de 35 em 2023. Sexto, a validação tem cerca de 32% de ausências e uma lacuna de 48 dias preenchida por repetição do último valor, o que pode enfraquecer a parada antecipada e a escolha do ponto de controle. Sétimo, a janela de 48 horas não é a ideal para o XGBoost, como mostrado na Seção 5.9.1. Por fim, o limiar de 35 μg/m^3, os pesos da perda ponderada e as faixas de defasagem são decisões de projeto e não resultados estabelecidos na literatura.

6 Conclusão

Este trabalho comparou modelos de aprendizado de máquina para a previsão horária de PM2,5 nas 24 horas seguintes, usando como estudo de caso a série da estação Sapo, em Conceição do Mato Dentro (MG). Foram comparadas redes LSTM, modelos Seq2Seq com e sem atenção e o XGBoost, além de previsores simples e de uma regressão linear como referências. Todos os modelos receberam os mesmos dados, o mesmo tratamento das lacunas e o mesmo treinamento, com hiperparâmetros escolhidos por uma busca com o mesmo orçamento. As diferenças foram avaliadas com testes estatísticos que consideram a dependência dos erros no tempo, e os resultados foram confirmados em um período de 2021 a 2023 que não foi consultado em nenhuma decisão de projeto.

6.1 Principais Resultados

Os resultados respondem às perguntas colocadas nos objetivos da seguinte forma.

- **Erro médio.** O XGBoost teve o menor erro médio absoluto no período de confirmação (2,77 μg/m^3), seguido da regressão Ridge (2,79), das duas versões do Seq2Seq com atenção (2,87 e 2,88) e das demais redes LSTM e Seq2Seq (2,94 a 2,98). O XGBoost e a Ridge têm desempenho estatisticamente equivalente, e ambos erram menos que todas as redes neurais. Todos os modelos treinados superam as referências simples, mas a diferença entre o melhor e o pior deles é de cerca de 7,7%.

- **Horizonte.** O erro cresce devagar com o horizonte, de 2,29 μg/m^3 em 1 hora a 2,89 em 24 horas para o XGBoost, e já é elevado na previsão de uma hora à frente (cerca de 21% da concentração média).

- **Picos e oscilações horárias.** Todos os modelos subestimam as horas de concentração alta e suavizam a série. Nenhum antecipa os eventos de pico melhor do que

repetir o último valor observado, e nenhum acompanha as oscilações de hora em hora.

- **Fatores de projeto.** A função de perda ponderada, o aprendizado residual, a perda auxiliar de evento e as alterações do Seq2Seq com atenção adaptado tiveram efeitos pequenos ou nulos no erro médio; o aprendizado residual piorou o resultado no Seq2Seq. Nas variáveis derivadas do PM10, o efeito foi inferior a 1% do erro e só apareceu no XGBoost.

- **Atenção.** No Seq2Seq adaptado, a atenção é necessária (zerar o contexto piora muito o erro), mas quase todo o ganho vem da divisão do histórico em seis faixas de defasagem; a ponderação aprendida dentro das faixas acrescenta cerca de 1% de melhora.

- **Robustez.** As conclusões se mantêm ao excluir os alvos preenchidos da avaliação, ao refazer a busca de hiperparâmetros para a perda ponderada e ao variar a janela de entrada de 24 a 96 horas (nesta última, o XGBoost teria melhorado cerca de 1% com uma janela maior).

Em conjunto, os resultados indicam que, nesta série, a escolha da arquitetura altera pouco a qualidade da previsão e que os modelos convergem para um erro semelhante, inclusive um modelo linear. A leitura compatível com isso é que o limite está na informação disponível: a estação não mede variáveis meteorológicas, que outros estudos apontam como determinantes do PM2,5. Esta é uma hipótese consistente com os dados, mas não foi testada neste trabalho.

6.2 Contribuições

Do ponto de vista metodológico, o trabalho reforça quatro pontos. Primeiro, as comparações entre modelos só são interpretáveis quando os modelos recebem o mesmo tratamento: etapas exploratórias em que o passo das janelas, as épocas, a função de perda e o orçamento de busca variavam entre os modelos não permitiam atribuir diferenças à arquitetura. Segundo, a seleção de variantes a partir do bloco de teste infla o desempenho

aparente (CAWLEY; TALBOT, 2010), e por isso é necessário um período de confirmação que nenhuma decisão tenha observado. Terceiro, é necessário incluir referências simples e uma regressão linear na comparação, pois, nesta série, elas são difíceis de superar, como também observam Makridakis, Spiliotis e Assimakopoulos (2018) em outro contexto. Quarto, a incerteza estatística precisa respeitar a dependência dos erros no tempo; sem isso, diferenças de poucos centésimos seriam interpretadas como reais.

6.3 Limitações

O estudo tem limitações. Ele usa uma única estação, o que restringe a generalização para outras localidades. O teste histórico de 2020 foi consultado durante o desenvolvimento e não é confirmatório; o período de confirmação cobre apenas três anos, com nível médio de PM2,5 que varia entre eles e com poucos eventos de pico. Quatro sementes fornecem pouca precisão para comparar famílias de modelos. Os fatores que reaproveitam os hiperparâmetros do caso de Huber podem subestimar cada variante, embora a verificação feita não tenha encontrado viés. A validação tem elevada proporção de ausências e uma lacuna longa. Por fim, o limiar de 35 $\mu g/m^3$, os pesos da perda ponderada e as alterações do Seq2Seq adaptado são decisões de projeto sem referência direta na literatura. A comparação numérica com outros estudos também não é direta, pois eles diferem no horizonte, nas variáveis e na escala dos dados (Capítulo 3).

6.4 Trabalhos Futuros

O próximo passo natural é acrescentar variáveis meteorológicas confiáveis (vento, temperatura, pressão, umidade e precipitação) e informações de outras estações da rede, o que permitiria testar a hipótese de que a informação disponível é o limite da previsão. Também é importante repetir o procedimento em outras estações, e treinar um modelo global com várias estações, como fazem abordagens que aprendem sobre muitas séries (SALINAS et al., 2020). Outra extensão é prever quantis do PM2,5 em vez de um único valor, o que expressa o risco de picos: a mediana mantém o objetivo do MAE e os quantis superiores indicam a chance de concentrações altas (WEN et al., 2017; KOENKER; BAS-

SETT, 1978); nesse caso, seriam necessárias métricas de calibração além das pontuais. Por fim, os Transformers temporais poderiam ser comparados com orçamento de busca equivalente e várias sementes.

Em síntese, este trabalho não demonstra a superioridade de nenhuma arquitetura para a previsão de PM2,5 na estação Sapo. Sob o mesmo tratamento dos dados, o XGBoost e uma regressão linear tiveram os menores erros, sem diferença estatística entre eles, as redes neurais ficaram até cerca de 8% atrás, e nenhum modelo previu bem os picos e as oscilações horárias.

A Tabelas Complementares

Este apêndice reúne as tabelas do teste histórico (27 de maio a 31 de dezembro de 2020), que já foi consultado durante o desenvolvimento e, portanto, não é confirmatório, e as tabelas do período de confirmação que são longas demais para o corpo do texto. A leitura das colunas é a mesma do Capítulo 5.

A.1 Comparação Principal

A Tabela A.1 traz as métricas do teste histórico e a Tabela A.2, as do *ensemble* nesse período. A Tabela A.3 traz a diferença de MAE em relação à referência, com intervalo de confiança, e as Tabelas A.4 e A.5 trazem a diferença entre todos os pares de modelos no período de confirmação e no teste histórico.

Tabela A.1: Métricas de erro no teste histórico (jun.–dez./2020)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24	Habilidade vs. MM 24 h
LSTM direta (Huber)	2,836	3,929	20,869	21,035	0,491	0,061	2,720	2,943	0,067
LSTM recursiva (Huber)	2,848	3,800	20,954	21,360	0,524	0,438	2,754	3,089	0,063
Seq2Seq básico (Huber)	2,843	3,969	20,921	21,081	0,480	0,090	2,408	3,053	0,065
Seq2Seq atenção padrão (Huber)	2,737	3,780	20,138	20,433	0,529	0,201	2,673	2,851	0,100
Seq2Seq atenção adaptado (Huber)	2,721	3,750	20,021	20,322	0,536	0,190	2,496	2,839	0,105
XGBoost (erro abs.)	2,696	3,751	19,838	20,236	0,536	-0,348	2,350	2,832	0,113
Persistência y(t)	3,900	5,285	28,696	29,058	0,079	-0,030	2,803	3,377	-0,283
Sazonal y(t-24)	3,377	4,719	24,851	25,196	0,266	-0,037	3,377	3,377	-0,111
Sazonal y(t-48)	3,762	5,246	27,684	27,551	0,092	-0,029	3,760	3,764	-0,238
Média móvel 6 h	3,350	4,555	24,654	24,874	0,316	-0,036	2,867	3,147	-0,102
Média móvel 24 h	3,040	4,225	22,369	22,608	0,411	-0,038	2,835	3,210	0,000
Ridge	2,673	3,749	19,668	19,979	0,536	-0,064	2,358	2,828	0,121

Tabela A.2: Ensemble das sementes (média das previsões): teste histórico (jun.–dez./2020)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24
LSTM direta (Huber)	2,798	3,874	20,590	20,809	0,505	0,061	2,675	2,911
LSTM recursiva (Huber)	2,817	3,760	20,728	21,162	0,534	0,438	2,737	3,043
Seq2Seq básico (Huber)	2,753	3,833	20,256	20,524	0,516	0,090	2,358	2,903
Seq2Seq atenção padrão (Huber)	2,706	3,745	19,913	20,218	0,537	0,201	2,631	2,825
Seq2Seq atenção adaptado (Huber)	2,683	3,705	19,741	20,062	0,547	0,190	2,451	2,802
XGBoost (erro abs.)	2,679	3,732	19,716	20,113	0,541	-0,348	2,335	2,815

Tabela A.3: Diferença de MAE em relação à referência, com IC de 95% (bootstrap em blocos): teste histórico (jun.–dez./2020)

Modelo	Referência	Δ MAE	IC inf.	IC sup.	p (bootstrap)	p (DM)	Veredito
LSTM recursiva (Huber)	LSTM direta (Huber)	0,012	-0,128	0,130	0,789	0,973	empate estatístico
Seq2Seq básico (Huber)	LSTM direta (Huber)	0,007	-0,058	0,078	0,860	0,874	empate estatístico
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	-0,099	-0,156	-0,051	0,000	0,000	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	-0,115	-0,176	-0,061	0,000	0,000	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	-0,140	-0,211	-0,076	0,000	0,000	melhor
Persistência y(t)	LSTM direta (Huber)	1,064	0,924	1,193	0,000	0,000	pior
Sazonal y(t-24)	LSTM direta (Huber)	0,541	0,454	0,625	0,000	0,000	pior
Sazonal y(t-48)	LSTM direta (Huber)	0,926	0,722	1,187	0,000	0,000	pior
Média móvel 6 h	LSTM direta (Huber)	0,514	0,379	0,636	0,000	0,000	pior
Média móvel 24 h	LSTM direta (Huber)	0,204	0,112	0,290	0,000	0,000	pior
Ridge	LSTM direta (Huber)	-0,163	-0,218	-0,106	0,000	0,000	melhor
LSTM direta (Huber)	Média móvel 24 h	-0,204	-0,290	-0,112	0,000	0,000	melhor
LSTM recursiva (Huber)	Média móvel 24 h	-0,192	-0,323	-0,069	0,002	0,001	melhor
Seq2Seq básico (Huber)	Média móvel 24 h	-0,197	-0,313	-0,070	0,004	0,000	melhor
Seq2Seq atenção padrão (Huber)	Média móvel 24 h	-0,303	-0,389	-0,215	0,000	0,000	melhor
Seq2Seq atenção adaptado (Huber)	Média móvel 24 h	-0,319	-0,400	-0,240	0,000	0,000	melhor
XGBoost (erro abs.)	Média móvel 24 h	-0,344	-0,420	-0,269	0,000	0,000	melhor

Tabela A.4: Diferença de MAE entre todos os pares de modelos: período de confirmação (2021–2023)

Modelo A	Modelo B	Δ MAE (A - B)	IC inf.	IC sup.	p (bootstrap)	Veredito (A vs. B)
LSTM direta (Huber)	LSTM recursiva (Huber)	0,035	-0,006	0,082	0,108	empate estatístico
LSTM direta (Huber)	Seq2Seq básico (Huber)	0,014	-0,032	0,065	0,568	empate estatístico
LSTM direta (Huber)	Seq2Seq atenção padrão (Huber)	0,109	0,072	0,148	0,000	pior
LSTM direta (Huber)	Seq2Seq atenção adaptado (Huber)	0,103	0,072	0,135	0,000	pior
LSTM direta (Huber)	XGBoost (erro abs.)	0,212	0,169	0,255	0,000	pior
LSTM direta (Huber)	Ridge	0,185	0,141	0,227	0,000	pior
LSTM recursiva (Huber)	Seq2Seq básico (Huber)	-0,020	-0,054	0,013	0,290	empate estatístico
LSTM recursiva (Huber)	Seq2Seq atenção padrão (Huber)	0,074	0,043	0,106	0,000	pior
LSTM recursiva (Huber)	Seq2Seq atenção adaptado (Huber)	0,068	0,033	0,104	0,000	pior
LSTM recursiva (Huber)	XGBoost (erro abs.)	0,177	0,134	0,226	0,000	pior
LSTM recursiva (Huber)	Ridge	0,150	0,088	0,204	0,000	pior
Seq2Seq básico (Huber)	Seq2Seq atenção padrão (Huber)	0,094	0,056	0,130	0,000	pior
Seq2Seq básico (Huber)	Seq2Seq atenção adaptado (Huber)	0,089	0,049	0,127	0,000	pior
Seq2Seq básico (Huber)	XGBoost (erro abs.)	0,198	0,142	0,250	0,000	pior
Seq2Seq básico (Huber)	Ridge	0,170	0,099	0,232	0,000	pior
Seq2Seq atenção padrão (Huber)	Seq2Seq atenção adaptado (Huber)	-0,006	-0,028	0,013	0,608	empate estatístico
Seq2Seq atenção padrão (Huber)	XGBoost (erro abs.)	0,103	0,064	0,138	0,000	pior
Seq2Seq atenção padrão (Huber)	Ridge	0,076	0,027	0,118	0,000	pior
Seq2Seq atenção adaptado (Huber)	XGBoost (erro abs.)	0,109	0,075	0,145	0,000	pior
Seq2Seq atenção adaptado (Huber)	Ridge	0,082	0,034	0,120	0,000	pior
XGBoost (erro abs.)	Ridge	-0,027	-0,074	0,007	0,150	empate estatístico

Tabela A.5: Diferença de MAE entre todos os pares de modelos: teste histórico (jun.–dez./2020)

Modelo A	Modelo B	Δ MAE (A - B)	IC inf.	IC sup.	p (bootstrap)	Veredito (A vs. B)
LSTM direta (Huber)	LSTM recursiva (Huber)	-0,012	-0,133	0,129	0,808	empate estatístico
LSTM direta (Huber)	Seq2Seq básico (Huber)	-0,007	-0,077	0,058	0,874	empate estatístico
LSTM direta (Huber)	Seq2Seq atenção padrão (Huber)	0,099	0,051	0,160	0,000	pior
LSTM direta (Huber)	Seq2Seq atenção adaptado (Huber)	0,115	0,062	0,179	0,000	pior
LSTM direta (Huber)	XGBoost (erro abs.)	0,140	0,078	0,211	0,000	pior
LSTM direta (Huber)	Ridge	0,163	0,105	0,220	0,000	pior
LSTM recursiva (Huber)	Seq2Seq básico (Huber)	0,005	-0,130	0,120	0,848	empate estatístico
LSTM recursiva (Huber)	Seq2Seq atenção padrão (Huber)	0,111	0,002	0,205	0,046	pior
LSTM recursiva (Huber)	Seq2Seq atenção adaptado (Huber)	0,127	0,029	0,215	0,010	pior
LSTM recursiva (Huber)	XGBoost (erro abs.)	0,152	0,042	0,260	0,006	pior
LSTM recursiva (Huber)	Ridge	0,175	0,045	0,299	0,016	pior
Seq2Seq básico (Huber)	Seq2Seq atenção padrão (Huber)	0,106	0,044	0,182	0,000	pior
Seq2Seq básico (Huber)	Seq2Seq atenção adaptado (Huber)	0,122	0,060	0,203	0,000	pior
Seq2Seq básico (Huber)	XGBoost (erro abs.)	0,147	0,073	0,229	0,000	pior
Seq2Seq básico (Huber)	Ridge	0,170	0,101	0,253	0,000	pior
Seq2Seq atenção padrão (Huber)	Seq2Seq atenção adaptado (Huber)	0,016	-0,009	0,042	0,208	empate estatístico
Seq2Seq atenção padrão (Huber)	XGBoost (erro abs.)	0,041	-0,008	0,095	0,098	empate estatístico
Seq2Seq atenção padrão (Huber)	Ridge	0,064	0,021	0,109	0,008	pior
Seq2Seq atenção adaptado (Huber)	XGBoost (erro abs.)	0,025	-0,015	0,063	0,260	empate estatístico
Seq2Seq atenção adaptado (Huber)	Ridge	0,048	-0,004	0,093	0,074	empate estatístico
XGBoost (erro abs.)	Ridge	0,023	-0,042	0,073	0,410	empate estatístico

A.2 Picos, Cauda e Dinâmica

As Tabelas A.6 e A.7 descrevem o desempenho nas concentrações altas e nos eventos de pico do teste histórico, e a Tabela A.8 compara os modelos por evento. A Tabela A.9 e as Figuras A.1 e A.2 mostram a dinâmica horária, o erro por horizonte e o maior evento do período.

Tabela A.6: Métricas de cauda e amplitude no teste histórico (jun.–dez./2020)

Modelo	MAE ≥25	MAE ≥35	MAE ≥50	Subestim. ≥35	Razão DP	p99 prev.	p99 obs.
LSTM direta (Huber)	8,722	14,370	27,061	0,996	0,728	28,157	34
LSTM recursiva (Huber)	6,884	12,281	18,524	0,979	0,850	30,322	34
Seq2Seq básico (Huber)	7,452	11,414	21,580	0,704	0,964	34,366	34
Seq2Seq atenção padrão (Huber)	7,444	12,846	22,153	0,988	0,790	29,887	34
Seq2Seq atenção adaptado (Huber)	7,441	13,295	24,148	0,998	0,783	29,271	34
XGBoost (erro abs.)	7,280	13,405	26,076	0,986	0,769	27,934	34
Persistência y(t)	8,290	11,977	25,083	0,879	0,987	33,000	34
Sazonal y(t-24)	7,371	12,423	24,000	0,936	0,990	33,000	34
Sazonal y(t-48)	8,114	13,508	21,000	0,871	0,996	34,000	34
Média móvel 6 h	7,720	11,923	25,479	0,933	0,843	32,500	34
Média móvel 24 h	7,646	12,596	27,800	0,993	0,746	31,500	34
Ridge	7,028	12,440	23,485	0,989	0,770	29,389	34

Tabela A.7: Desempenho nos eventos de pico: teste histórico (jun.–dez./2020)

Modelo	Limiar	Eventos	MAE por evento	Viés no evento	Subestimação	Erro no pico
LSTM direta (Huber)	35	21	16,210	-16,210	0,999	-17,147
LSTM recursiva (Huber)	35	21	13,168	-13,149	0,987	-13,912
Seq2Seq básico (Huber)	35	21	12,495	-10,428	0,793	-11,253
Seq2Seq atenção padrão (Huber)	35	21	14,178	-14,178	1,000	-15,032
Seq2Seq atenção adaptado (Huber)	35	21	14,501	-14,501	1,000	-15,354
XGBoost (erro abs.)	35	21	15,556	-15,556	1,000	-16,542
Persistência y(t)	35	21	13,880	-13,869	0,989	-14,921
Sazonal y(t-24)	35	21	14,368	-14,249	0,940	-15,381
Sazonal y(t-48)	35	21	15,753	-14,221	0,876	-15,619
Média móvel 6 h	35	21	14,337	-14,337	1,000	-15,374
Média móvel 24 h	35	21	15,391	-15,391	1,000	-16,433
Ridge	35	21	14,889	-14,889	1,000	-15,912
LSTM direta (Huber)	25	65	9,623	-9,545	0,979	-11,138
LSTM recursiva (Huber)	25	65	7,786	-7,339	0,911	-8,812
Seq2Seq básico (Huber)	25	65	7,866	-7,057	0,859	-8,475
Seq2Seq atenção padrão (Huber)	25	65	8,454	-8,163	0,944	-9,614
Seq2Seq atenção adaptado (Huber)	25	65	8,411	-8,204	0,945	-9,695
XGBoost (erro abs.)	25	65	8,989	-8,979	0,994	-10,620
Persistência y(t)	25	65	9,615	-9,476	0,947	-11,273
Sazonal y(t-24)	25	65	8,929	-7,639	0,828	-9,292
Sazonal y(t-48)	25	65	9,406	-8,565	0,876	-10,262
Média móvel 6 h	25	65	9,762	-9,663	0,964	-11,453
Média móvel 24 h	25	65	10,224	-10,168	0,986	-11,972
Ridge	25	65	9,003	-8,885	0,955	-10,517

Tabela A.8: Diferença de MAE por evento em relação à referência: teste histórico (jun.–dez./2020)

Modelo	Referência	Limiar	Δ MAE por evento	IC inf.	IC sup.	Vitórias	Eventos	Veredito
LSTM recursiva (Huber)	LSTM direta (Huber)	35	-3,043	-3,984	-2,094	20	21	melhor
Seq2Seq básico (Huber)	LSTM direta (Huber)	35	-3,716	-5,043	-2,284	18	21	melhor
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	35	-2,033	-2,744	-1,267	18	21	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	35	-1,709	-2,303	-1,090	17	21	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	35	-0,655	-1,296	0,029	15	21	empate estatístico
Persistência y(t)	LSTM direta (Huber)	35	-2,330	-3,615	-1,032	14	21	melhor
Sazonal y(t-24)	LSTM direta (Huber)	35	-1,843	-3,357	-0,406	15	21	melhor
Sazonal y(t-48)	LSTM direta (Huber)	35	-0,458	-2,189	1,080	10	21	empate estatístico
Média móvel 6 h	LSTM direta (Huber)	35	-1,874	-3,212	-0,503	14	21	melhor
Média móvel 24 h	LSTM direta (Huber)	35	-0,820	-2,105	0,503	13	21	empate estatístico
Ridge	LSTM direta (Huber)	35	-1,322	-2,119	-0,679	18	21	melhor
LSTM recursiva (Huber)	LSTM direta (Huber)	25	-1,837	-2,211	-1,452	56	65	melhor
Seq2Seq básico (Huber)	LSTM direta (Huber)	25	-1,757	-2,281	-1,228	52	65	melhor
Seq2Seq atenção padrão (Huber)	LSTM direta (Huber)	25	-1,169	-1,502	-0,837	52	65	melhor
Seq2Seq atenção adaptado (Huber)	LSTM direta (Huber)	25	-1,212	-1,551	-0,865	51	65	melhor
XGBoost (erro abs.)	LSTM direta (Huber)	25	-0,634	-0,990	-0,295	42	65	melhor
Persistência y(t)	LSTM direta (Huber)	25	-0,008	-0,649	0,614	28	65	empate estatístico
Sazonal y(t-24)	LSTM direta (Huber)	25	-0,694	-1,443	0,029	34	65	empate estatístico
Sazonal y(t-48)	LSTM direta (Huber)	25	-0,217	-1,141	0,724	33	65	empate estatístico
Média móvel 6 h	LSTM direta (Huber)	25	0,139	-0,510	0,762	31	65	empate estatístico
Média móvel 24 h	LSTM direta (Huber)	25	0,601	0,045	1,151	26	65	pior
Ridge	LSTM direta (Huber)	25	-0,620	-0,892	-0,366	45	65	melhor

Tabela A.9: Dinâmica horária: teste histórico (jun.–dez./2020)

Modelo	Corr. nível	Corr. diferenças	Acerto de direção	DP dif. obs.	DP dif. prev.
LSTM direta (Huber)	0,711	0,152	0,540	3,820	0,816
LSTM recursiva (Huber)	0,750	0,196	0,561	3,820	0,975
Seq2Seq básico (Huber)	0,755	0,176	0,548	3,820	1,104
Seq2Seq atenção padrão (Huber)	0,741	0,173	0,551	3,820	1,078
Seq2Seq atenção adaptado (Huber)	0,745	0,177	0,552	3,820	1,046
XGBoost (erro abs.)	0,753	0,156	0,540	3,820	0,868
Persistência y(t)	0,709	-0,374	0,320	3,820	0,198
Sazonal y(t-24)	0,629	0,089	0,439	3,820	3,761
Sazonal y(t-48)	0,545	0,092	0,428	3,820	3,723
Média móvel 6 h	0,692	-0,132	0,438	3,820	0,131
Média móvel 24 h	0,659	-0,049	0,480	3,820	0,092
Ridge	0,742	0,183	0,557	3,820	0,720

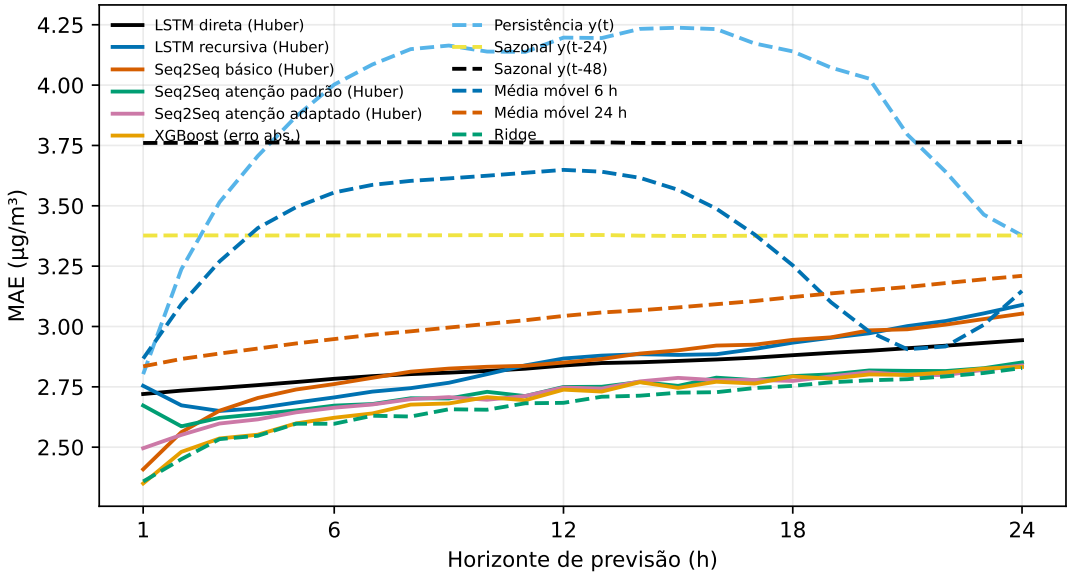


Figura A.1: MAE por horizonte no teste histórico (média das sementes). Linhas tracejadas: previsores de referência e regressão Ridge.

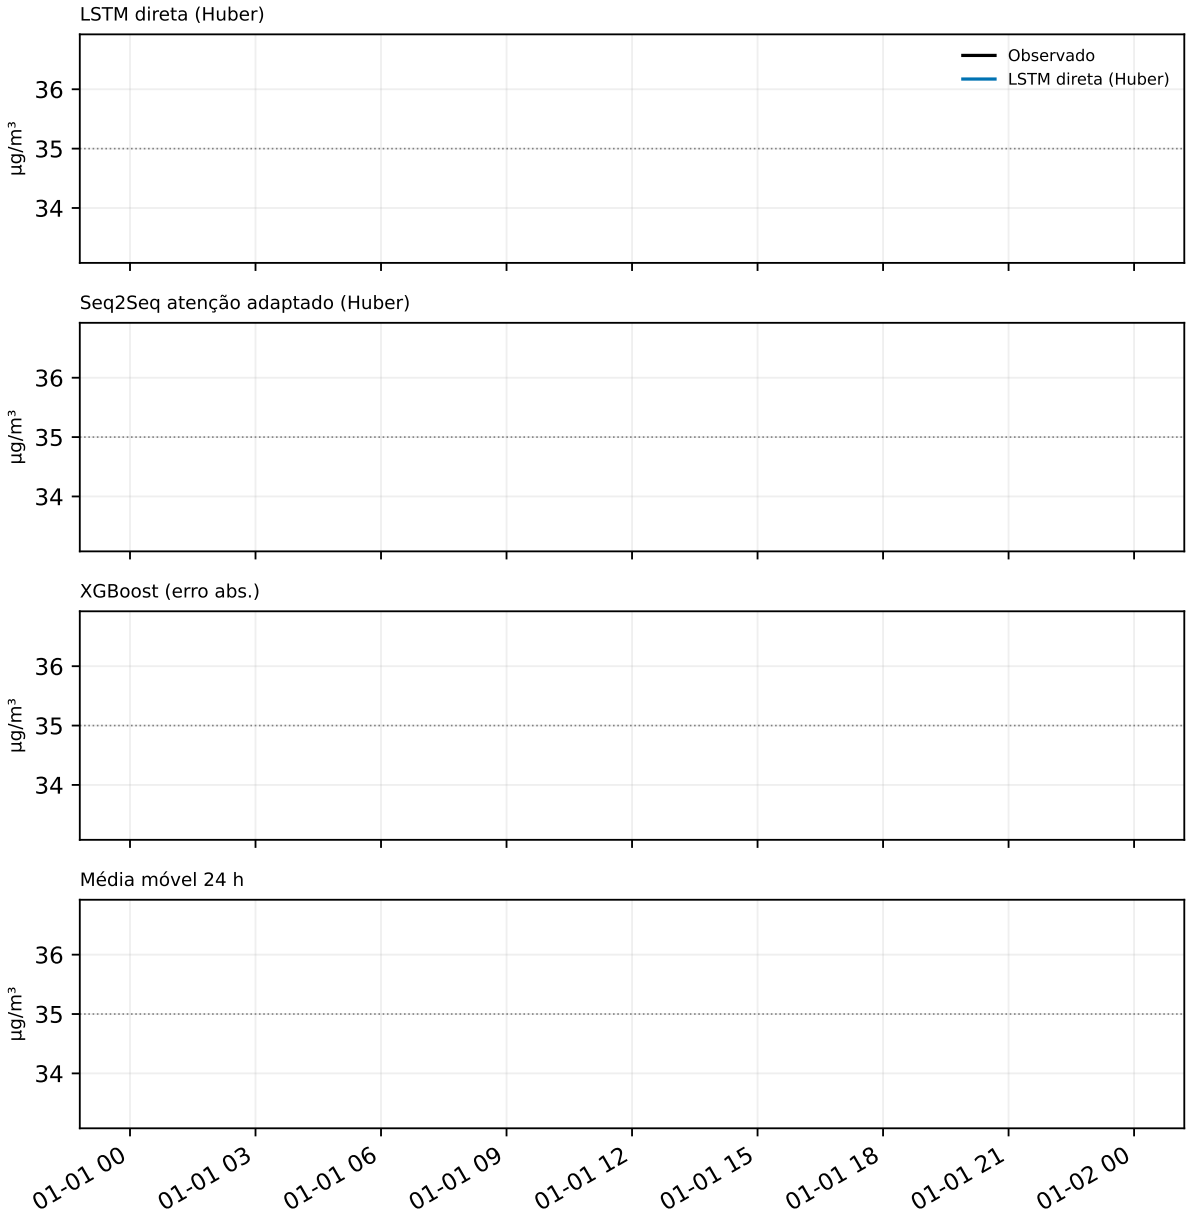


Figura A.2: Previsões (média das sementes) em torno do maior evento do teste histórico, em painéis separados por modelo e com escala comum.

A.3 Fatores de Projeto

As Tabelas A.10 e A.11 comparam as variantes de projeto no período de confirmação e no teste histórico, e a Tabela A.12 mostra o efeito delas nas concentrações altas. As Tabelas A.13, A.14, A.15 e A.16 detalham a perda, as variantes extras e as ablações do desenho e das variáveis derivadas do PM10 no teste histórico.

Tabela A.10: Fatores (perda, resíduo e evento), métricas de erro: período de confirmação (2021–2023)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24
LSTM direta (L1 pond.)	2,971	4,320	26,879	31,209	0,595	-0,071	2,858	3,057
LSTM recursiva (L1 pond.)	2,935	4,181	26,548	31,363	0,621	0,071	2,817	3,175
Seq2Seq básico (L1 pond.)	2,953	4,308	26,713	31,464	0,597	-0,606	2,473	3,214
Seq2Seq atenção padrão (L1 pond.)	2,879	4,107	26,047	30,681	0,634	0,020	2,672	2,973
Seq2Seq atenção adaptado (L1 pond.)	2,835	4,101	25,648	30,128	0,635	-0,071	2,534	2,959
Seq2Seq atenção adaptado (L1 pond. + evento)	2,814	4,078	25,459	29,918	0,639	-0,096	2,525	2,935
LSTM direta (Huber + resíduo)	2,969	4,321	26,858	31,134	0,595	-0,081	2,672	3,209
Seq2Seq atenção adaptado (Huber + resíduo)	2,946	4,312	26,654	30,694	0,597	0,002	2,700	3,099
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	2,914	4,270	26,357	30,414	0,605	-0,039	2,691	3,066

Tabela A.11: Fatores (perda, resíduo e evento), métricas de erro: teste histórico (jun.–dez./2020)

Modelo	MAE	RMSE	WAPE (%)	sMAPE (%)	R^2	MBE	MAE H1	MAE H24
LSTM direta (L1 pond.)	2,869	4,007	21,109	21,311	0,470	-0,129	2,757	2,977
LSTM recursiva (L1 pond.)	2,954	3,915	21,736	22,171	0,494	0,524	2,802	3,305
Seq2Seq básico (L1 pond.)	2,904	4,122	21,369	21,634	0,437	-0,492	2,442	3,241
Seq2Seq atenção padrão (L1 pond.)	2,749	3,837	20,227	20,476	0,514	0,129	2,680	2,868
Seq2Seq atenção adaptado (L1 pond.)	2,695	3,746	19,832	20,198	0,537	-0,018	2,445	2,813
Seq2Seq atenção adaptado (L1 pond. + evento)	2,713	3,795	19,963	20,269	0,525	0,028	2,456	2,844
LSTM direta (Huber + resíduo)	2,903	4,003	21,365	21,714	0,472	-0,038	2,661	3,128
Seq2Seq atenção adaptado (Huber + resíduo)	2,812	3,906	20,690	21,033	0,497	-0,032	2,642	2,960
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	2,845	3,953	20,932	21,223	0,485	-0,044	2,669	2,989

Tabela A.12: Fatores (perda, resíduo e evento), métricas de cauda: teste histórico (jun.–dez./2020)

Modelo	MAE ≥25	MAE ≥35	MAE ≥50	Subestim. ≥35	Razão DP	p99 prev.	p99 obs.
LSTM direta (L1 pond.)	8,206	13,482	25,131	0,996	0,776	29,681	34
LSTM recursiva (L1 pond.)	6,369	10,799	15,659	0,956	0,913	31,848	34
Seq2Seq básico (L1 pond.)	8,446	11,376	19,904	0,645	0,993	37,293	34
Seq2Seq atenção padrão (L1 pond.)	7,121	11,736	18,538	0,945	0,841	32,015	34
Seq2Seq atenção adaptado (L1 pond.)	7,075	12,205	22,590	0,985	0,827	30,728	34
Seq2Seq atenção adaptado (L1 pond. + evento)	7,063	11,652	22,719	0,931	0,837	31,312	34
LSTM direta (Huber + resíduo)	8,132	13,997	24,976	0,982	0,793	29,087	34
Seq2Seq atenção adaptado (Huber + resíduo)	7,541	12,775	24,527	0,941	0,823	30,459	34
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	7,732	13,139	24,228	0,958	0,817	30,427	34

Tabela A.13: Efeito da perda por arquitetura (L1 ponderada - Huber): teste histórico (jun.–dez./2020)

Arquitetura	MAE Huber	MAE L1 pond.	Δ MAE	IC inf.	IC sup.	Veredito
LSTM direta	2,829	2,869	0,039	-0,004	0,075	empate estatístico
LSTM recursiva	2,827	2,954	0,127	0,087	0,168	pior
Seq2Seq básico	2,851	2,904	0,053	0,003	0,108	pior
Seq2Seq atenção padrão	2,739	2,749	0,010	-0,013	0,037	empate estatístico
Seq2Seq atenção adaptado	2,722	2,695	-0,027	-0,050	-0,003	melhor

Tabela A.14: Efeito isolado de fatores adicionais: teste histórico (jun.–dez./2020)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
Seq2Seq atenção adaptado (L1 pond. + evento)	Seq2Seq atenção adaptado (L1 pond.)	2,713	2,695	0,018	-0,000	0,039	empate estatístico
LSTM direta (Huber + resíduo)	LSTM direta (Huber)	2,903	2,829	0,074	0,002	0,143	pior
Seq2Seq atenção adaptado (Huber + resíduo)	Seq2Seq atenção adaptado (Huber)	2,812	2,722	0,089	0,034	0,147	pior
Seq2Seq atenção adaptado (L1 pond. + evento + resíduo)	Seq2Seq atenção adaptado (L1 pond. + evento)	2,845	2,713	0,132	0,080	0,185	pior

Tabela A.15: Ablação de cada elemento do desenho do Seq2Seq adaptado: teste histórico (jun.–dez./2020)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
Seq2Seq atenção adaptado (sem reinício por horizonte)	Seq2Seq atenção adaptado (Huber)	2,697	2,722	-0,026	-0,051	-0,004	melhor
Seq2Seq atenção adaptado (com input feeding)	Seq2Seq atenção adaptado (Huber)	2,705	2,722	-0,018	-0,037	0,002	empate estatístico
Seq2Seq atenção adaptado (sem faixas de defasagem)	Seq2Seq atenção adaptado (Huber)	2,741	2,722	0,018	-0,016	0,060	empate estatístico
Seq2Seq atenção adaptado (consulta sem horizonte/exógenas)	Seq2Seq atenção adaptado (Huber)	2,698	2,722	-0,025	-0,044	-0,004	melhor

Tabela A.16: Ablação das variáveis de PM10: teste histórico (jun.–dez./2020)

Modelo	Variáveis	Sementes	Δ MAE vs. completo	IC inf.	IC sup.	Veredito
LSTM direta	PM10 só no histórico	3	0,046	0,007	0,094	pior
LSTM direta	só PM2,5 e tempo	3	-0,006	-0,044	0,031	empate estatístico
XGBoost	PM10 só no histórico	3	0,010	0,003	0,016	pior
XGBoost	só PM2,5 e tempo	3	0,016	0,008	0,024	pior

A.4 Sensibilidades e Vencedores por Critério

As Tabelas A.17, A.18 e A.19 trazem, para o teste histórico, a sensibilidade aos alvos preenchidos, a verificação da busca de hiperparâmetros e o modelo com menor erro em cada critério.

Tabela A.17: Sensibilidade às métricas com alvos imputados: teste histórico (jun.–dez./2020)

Modelo	Pares observados	Pares imputados	MAE observados	MAE imputados	MAE todos	Posição (observados)	Posição (todos)
LSTM direta (Huber)	116326	8222	2,836	2,537	2,816	4	4
LSTM recursiva (Huber)	116326	8222	2,848	2,549	2,828	6	6
Seq2Seq básico (Huber)	116326	8222	2,843	2,582	2,826	5	5
Seq2Seq atenção padrão (Huber)	116326	8222	2,737	2,401	2,714	3	3
Seq2Seq atenção adaptado (Huber)	116326	8222	2,721	2,293	2,693	2	2
XGBoost (erro abs.)	116326	8222	2,696	2,237	2,665	1	1

Tabela A.18: Efeito de refazer a busca de hiperparâmetros para a perda ponderada: teste histórico (jun.–dez./2020)

Caso	Base	MAE caso	MAE base	Δ MAE	IC inf.	IC sup.	Veredito
LSTM direta (L1 pond., HPO própria)	LSTM direta (L1 pond.)	2,858	2,869	-0,011	-0,049	0,032	empate estatístico
Seq2Seq atenção adaptado (L1 pond., HPO própria)	Seq2Seq atenção adaptado (L1 pond.)	2,733	2,695	0,038	-0,001	0,079	empate estatístico

Tabela A.19: Melhor modelo por critério: teste histórico (jun.–dez./2020)

Critério	Melhor	Valor	Empate estatístico com
MAE	XGBoost (erro abs.)	2,696	Seq2Seq atenção padrão (Huber), Seq2Seq atenção adaptado (Huber), Ridge
RMSE	Seq2Seq atenção adaptado (Huber)	3,750	—
R^2	Seq2Seq atenção adaptado (Huber)	0,536	—
WAPE	XGBoost (erro abs.)	19,838	—
MAE H1	XGBoost (erro abs.)	2,350	—
MAE H24	XGBoost (erro abs.)	2,832	—
MAE pico $\geq$35	Seq2Seq básico (Huber)	11,414	—
MAE por evento	Seq2Seq básico (Huber)	12,495	—
—1 - razão de desvios—	Seq2Seq básico (Huber)	0,036	—
—viés—	LSTM direta (Huber)	0,061	—

Bibliografia

AKIBA, T. et al. Optuna: A next-generation hyperparameter optimization framework. In: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.]: ACM, 2019. p. 2623–2631. DOI: 10.1145/3292500.3330701.

AYTURAN, Y. A. et al. Short-term prediction of PM2.5 pollution with deep learning methods. *Global NEST Journal*, v. 22, n. 1, p. 126–131, 2020. DOI: 10.30955/gnj.003208.

BAHDANAU, D.; CHO, K.; BENGIO, Y. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014. Published in ICLR 2015. Disponível em: ⟨https://arxiv.org/abs/1409.0473⟩. DOI: 10.48550/arXiv.1409.0473.

BENGIO, S. et al. Scheduled sampling for sequence prediction with recurrent neural networks. *arXiv preprint arXiv:1506.03099*, 2015. Published in NIPS 2015. Disponível em: ⟨https://arxiv.org/abs/1506.03099⟩. DOI: 10.48550/arXiv.1506.03099.

BENIDIS, K. et al. Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, v. 55, n. 6, p. 1–36, 2022. DOI: 10.1145/3533382.

BERGMEIR, C.; BENITEZ, J. M. On the use of cross-validation for time series predictor evaluation. *Information Sciences*, v. 191, p. 192–213, 2012. DOI: 10.1016/j.ins.2011.12.028.

BERGSTRA, J. et al. Algorithms for hyper-parameter optimization. In: *Advances in Neural Information Processing Systems (NIPS)*. [S.l.: s.n.], 2011. v. 24, p. 2546–2554.

BROOK, R. D. et al. Particulate matter air pollution and cardiovascular disease: An update to the scientific statement from the american heart association. *Circulation*, v. 121, n. 21, p. 2331–2378, 2010. DOI: 10.1161/CIR.0b013e3181dbece1.

BUUREN, S. van; GROOTHUIS-OUDSHOORN, K. mice: Multivariate imputation by chained equations in r. *Journal of Statistical Software*, v. 45, n. 3, p. 1–67, 2011. DOI: 10.18637/jss.v045.i03.

CARUANA, R. Multitask learning. *Machine Learning*, v. 28, p. 41–75, 1997.

CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Disponível em: ⟨https://jmlr.org/papers/v11/cawley10a.html⟩.

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, v. 7, n. 3, p. 1247–1250, 2014.

CHAVES, M. G. D. et al. Particulate matter forecast and prediction in curitiba using machine learning. *Frontiers in Big Data*, v. 7, p. 1412837, 2024. DOI: 10.3389/fdata.2024.1412837.

CHE, Z. et al. Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, v. 8, p. 6085, 2018.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.]: ACM, 2016. p. 785–794. DOI: 10.1145/2939672.2939785.

CHEN, Y. et al. Improved prediction of hourly PM2.5 concentrations with a long short-term memory and spatio-temporal causal convolutional network deep learning model. *Science of the Total Environment*, v. 912, p. 168672, 2024. DOI: 10.1016/j.scitotenv.2023.168672.

CHENG, H.-T. et al. Wide & deep learning for recommender systems. In: *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems*. [S.l.: s.n.], 2016. p. 7–10.

CINAR, Y. G. et al. Position-based content attention for time series forecasting with sequence-to-sequence RNNs. In: *Neural Information Processing (ICONIP 2017)*. [S.l.]: Springer, 2017. (Lecture Notes in Computer Science, v. 10638), p. 533–544.

Conselho Nacional do Meio Ambiente. *Resolução CONAMA n. 491, de 19 de novembro de 2018: dispõe sobre padrões de qualidade do ar*. 2018. Diário Oficial da União. Revogada pela Resolução CONAMA n. 506, de 5 de julho de 2024. Disponível em: ⟨https://www.in.gov.br/web/guest/materia/-/asset_publisher/Kujrw0TZC2Mb/content/id/51058895/do1-2018-11-21-resolucao-n-491-de-19-de-novembro-de-2018-51058603⟩.

DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, v. 13, n. 3, p. 253–263, 1995.

ELKAN, C. The foundations of cost-sensitive learning. In: *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*. [S.l.: s.n.], 2001. p. 973–978.

Fdeloche. *Long Short-Term Memory.svg*. 2017. Wikimedia Commons. Imagem sob licença CC BY-SA 4.0. Acesso em: 17 jun. 2026. Disponível em: ⟨https://commons.wikimedia.org/wiki/File:Long_Short-Term_Memory.svg⟩.

FENG, X. et al. A hybrid model for enhanced forecasting of PM2.5 spatiotemporal concentrations with high resolution and accuracy. *Environmental Pollution*, v. 355, p. 124263, 2024. DOI: 10.1016/j.envpol.2024.124263.

Fundação Estadual do Meio Ambiente de Minas Gerais. *Dados do Monitoramento Contínuo da Qualidade do Ar*. 2026. Página institucional da FEAM/SISEMA. Acesso em: 20 maio 2026. Disponível em: ⟨https://feam.br/w/dados-do-monitoramento-continuo-da-qualidade-do-ar⟩.

GNEITING, T. Making and evaluating point forecasts. *Journal of the American Statistical Association*, v. 106, n. 494, p. 746–762, 2011.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA: MIT Press, 2016. Disponível em: ⟨https://www.deeplearningbook.org/⟩.

GOYAL, P. et al. Accurate, large minibatch SGD: Training ImageNet in 1 hour. *arXiv preprint arXiv:1706.02677*, 2017. Disponível em: ⟨https://arxiv.org/abs/1706.02677⟩. DOI: 10.48550/arXiv.1706.02677.

HARVEY, D.; LEYBOURNE, S.; NEWBOLD, P. Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, v. 13, n. 2, p. 281–291, 1997.

HE, Z.; GUO, Q. Comparative analysis of multiple deep learning models for forecasting monthly ambient PM2.5 concentrations: A case study in dezhou city, china. *Atmosphere*, v. 15, n. 12, p. 1432, 2024. DOI: 10.3390/atmos15121432.

HEWAMALAGE, H.; BERGMEIR, C.; BANDARA, K. Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, v. 37, n. 1, p. 388–427, 2021. DOI: 10.1016/j.ijforecast.2020.06.008.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. DOI: 10.1162/neco.1997.9.8.1735.

HOERL, A. E.; KENNARD, R. W. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, v. 12, n. 1, p. 55–67, 1970.

HUBER, P. J. Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, v. 35, n. 1, p. 73–101, 1964. DOI: 10.1214/aoms/1177703732.

HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. OTexts, 2021. Disponível em: ⟨https://otexts.com/fpp3/⟩.

HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. *International Journal of Forecasting*, v. 22, n. 4, p. 679–688, 2006.

JAIN, S.; WALLACE, B. C. Attention is not explanation. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019. p. 3543–3556. DOI: 10.18653/v1/N19-1357.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014. Disponível em: ⟨https://arxiv.org/abs/1412.6980⟩. DOI: 10.48550/arXiv.1412.6980.

KOENKER, R.; BASSETT, G. Regression quantiles. *Econometrica*, v. 46, n. 1, p. 33–50, 1978.

KÜNSCH, H. R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, v. 17, n. 3, p. 1217–1241, 1989.

LAKSHMINARAYANAN, B.; PRITZEL, A.; BLUNDELL, C. Simple and scalable predictive uncertainty estimation using deep ensembles. In: *Advances in Neural Information Processing Systems 30*. [S.l.: s.n.], 2017.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539.

LI, L. et al. Hyperband: A novel bandit-based approach to hyperparameter optimization. *Journal of Machine Learning Research*, v. 18, n. 185, p. 1–52, 2018. Disponível em: ⟨https://www.jmlr.org/papers/v18/16-558.html⟩. DOI: 10.48550/arXiv.1603.06560.

LI, T.; HUA, M.; WU, X. A hybrid CNN-LSTM model for forecasting particulate matter (PM2.5). *IEEE Access*, v. 8, p. 26933–26940, 2020. DOI: 10.1109/ACCESS.2020.2971348.

LI, T. et al. Urban PM2.5 concentration prediction via attention-based CNN-LSTM. *Applied Sciences*, v. 10, n. 6, p. 1953, 2020. DOI: 10.3390/app10061953.

LI, Y. et al. Diffusion convolutional recurrent neural network: data-driven traffic forecasting. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2018.

LIM, B. et al. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, v. 37, n. 4, p. 1748–1764, 2021. DOI: 10.1016/j.ijforecast.2021.03.012.

LIM, B.; ZOHREN, S. Time-series forecasting with deep learning: A survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, v. 379, n. 2194, p. 20200209, 2021. DOI: 10.1098/rsta.2020.0209.

LITTLE, R. J. A.; RUBIN, D. B. *Statistical Analysis with Missing Data*. 3. ed. [S.l.]: Wiley, 2019.

LOSHCHILOV, I.; HUTTER, F. SGDR: Stochastic gradient descent with warm restarts. In: *International Conference on Learning Representations*. [s.n.], 2017. Disponível em: ⟨https://arxiv.org/abs/1608.03983⟩.

_____. Decoupled weight decay regularization. In: *International Conference on Learning Representations*. [s.n.], 2019. Disponível em: ⟨https://arxiv.org/abs/1711.05101⟩.

LUONG, M.-T.; PHAM, H.; MANNING, C. D. Effective approaches to attention-based neural machine translation. In: *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. Lisbon, Portugal: Association for Computational Linguistics, 2015. p. 1412–1421. DOI: 10.18653/v1/D15-1166.

MAKRIDAKIS, S.; SPILIOTIS, E.; ASSIMAKOPOULOS, V. Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE*, v. 13, n. 3, p. e0194889, 2018.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, v. 5, p. 115–133, 1943. DOI: 10.1007/BF02478259.

NAPVASCONCELOS; VASCONCELOS, N. *Neuron pt.svg*. 2008. Wikimedia Commons. Imagem com modificações em português do Brasil, sob licenças CC BY-SA/GFDL. Acesso em: 10 maio 2026. Disponível em: ⟨https://commons.wikimedia.org/wiki/File:Neuron_pt.svg⟩.

NEWEY, W. K.; WEST, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, v. 55, n. 3, p. 703–708, 1987. DOI: 10.2307/1913610.

NIE, Y. et al. A time series is worth 64 words: Long-term forecasting with transformers. In: *International Conference on Learning Representations*. [s.n.], 2023. Disponível em: ⟨https://openreview.net/forum?id=Jbdc0vTOcol⟩. DOI: 10.48550/arXiv.2211.14730.

Optuna Contributors. *optuna.pruners.MedianPruner*. 2026. Optuna 4.9.0 documentation. Acesso em: 15 jun. 2026. Disponível em: ⟨https://optuna.readthedocs.io/en/stable/reference/generated/optuna.pruners.MedianPruner.html⟩.

_____. *optuna.samplers.TPESampler*. 2026. Optuna 4.9.0 documentation. Acesso em: 15 jun. 2026. Disponível em: ⟨https://optuna.readthedocs.io/en/stable/reference/samplers/generated/optuna.samplers.TPESampler.html⟩.

POLITIS, D. N.; ROMANO, J. P. A circular block-resampling procedure for stationary data. In: LEPAGE, R.; BILLARD, L. (Ed.). *Exploring the Limits of Bootstrap*. New York: John Wiley & Sons, 1992. p. 263–270.

POPE, C. A.; DOCKERY, D. W. Health effects of fine particulate air pollution: Lines that connect. *Journal of the Air & Waste Management Association*, v. 56, n. 6, p. 709–742, 2006. DOI: 10.1080/10473289.2006.10464485.

QAMAR, M. S.; MUNIR, M. F.; WASEEM, A. AI for cleaner air: Predictive modeling of PM2.5 using deep learning and traditional time-series approaches. *Computer Modeling in Engineering & Sciences*, v. 144, n. 3, p. 3557–3584, 2025. DOI: 10.32604/cmes.2025.067447.

QIN, Y. et al. A dual-stage attention-based recurrent neural network for time series prediction. In: *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence*. [S.l.: s.n.], 2017. p. 2627–2633. DOI: 10.24963/ijcai.2017/366.

REQUIA, W. J. et al. Health impacts of wildfire-related air pollution in brazil: a nationwide study of more than 2 million hospital admissions between 2008 and 2018. *Nature Communications*, v. 12, n. 1, p. 6555, 2021. DOI: 10.1038/s41467-021-26822-7.

_____. Short-term exposure to wildfire-related pm2.5 increases mortality risks and burdens in brazil. *Nature Communications*, v. 13, n. 1, p. 7922, 2022. DOI: 10.1038/s41467-022-35326-x.

ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, v. 65, n. 6, p. 386–408, 1958. DOI: 10.1037/h0042519.

SALINAS, D. et al. DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, v. 36, n. 3, p. 1181–1191, 2020. DOI: 10.1016/j.ijforecast.2019.07.001.

SERRANO, S.; SMITH, N. A. Is attention interpretable? In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. [S.l.: s.n.], 2019. p. 2931–2951.

SRIVASTAVA, N. et al. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, n. 56, p. 1929–1958, 2014.

STEKHOVEN, D. J.; BUHLMANN, P. Missforest: non-parametric missing value imputation for mixed-type data. *Bioinformatics*, v. 28, n. 1, p. 112–118, 2012. DOI: 10.1093/bioinformatics/btr597.

SU, Y. et al. Application of CNN-LSTM algorithm for PM2.5 concentration forecasting in the beijing-tianjin-hebei metropolitan area. *Atmosphere*, v. 14, n. 9, p. 1392, 2023. DOI: 10.3390/atmos14091392.

SUTSKEVER, I.; VINYALS, O.; LE, Q. V. Sequence to sequence learning with neural networks. *arXiv preprint arXiv:1409.3215*, 2014. Published in NIPS 2014. Disponível em: ⟨https://arxiv.org/abs/1409.3215⟩. DOI: 10.48550/arXiv.1409.3215.

TAIEB, S. B. et al. A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition. *Expert Systems with Applications*, v. 39, n. 8, p. 7067–7083, 2012.

TASHMAN, L. J. Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, v. 16, n. 4, p. 437–450, 2000. DOI: 10.1016/S0169-2070(00)00065-0.

TRAN, H. D. et al. Forecasting hourly PM2.5 concentration with an optimized LSTM model. *Atmospheric Environment*, v. 315, p. 120161, 2023. DOI: 10.1016/j.atmosenv.2023.120161.

TZANIS, C. G.; ALIMISSIS, A. Contributing towards representative PM data coverage by utilizing artificial neural networks. *Applied Sciences*, v. 11, n. 18, p. 8431, 2021. Disponível em: ⟨https://www.mdpi.com/2076-3417/11/18/8431⟩. DOI: 10.3390/app11188431.

WEN, R. et al. A multi-horizon quantile recurrent forecaster. *arXiv preprint arXiv:1711.11053*, 2017. Disponível em: ⟨https://arxiv.org/abs/1711.11053⟩. DOI: 10.48550/arXiv.1711.11053.

WIEGREFFE, S.; PINTER, Y. Attention is not not explanation. In: *Proceedings of EMNLP-IJCNLP 2019*. [S.l.: s.n.], 2019. p. 11–20.

WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, v. 30, n. 1, p. 79–82, 2005.

World Health Organization. *WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Geneva, 2021. Disponível em: ⟨https://www.who.int/publications/i/item/9789240034228⟩.

WU, H. et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2021. v. 34, p. 22419–22430. DOI: 10.48550/arXiv.2106.13008.

YANG, L. et al. Attention-lstm-based prediction model of pm2.5 hourly concentration. In: *2023 12th International Conference of Information and Communication Technology (ICTech)*. [S.l.: s.n.], 2023. p. 137–141. DOI: 10.1109/ICTech58362.2023.00037.

ZENG, A. et al. Are transformers effective for time series forecasting? In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2023. v. 37, n. 9, p. 11121–11128. DOI: 10.1609/aaai.v37i9.26317.

ZENG, L. et al. Evaluating deep learning time series models for PM2.5 forecasting across diverse horizons. *iScience*, v. 29, n. 2, p. 114770, 2026. DOI: 10.1016/j.isci.2026.114770.

ZHANG, M. et al. PM2.5 concentration prediction model utilizing GNSS-PWV and RF-LSTM fusion algorithms. *Atmosphere*, v. 16, n. 10, p. 1147–1161, 2025. DOI: 10.3390/atmos16101147.

ZHANG, Z.; MA, X.; YAN, K. A deep learning model for pm2.5 concentration prediction. In: *2021 IEEE Intl Conf on Dependable, Autonomic and Secure Computing, Intl Conf on Pervasive Intelligence and Computing, Intl Conf on Cloud and Big Data Computing, Intl Conf on Cyber Science and Technology Congress (DASC/PiCom/CBDCom/CyberSciTech)*. [S.l.: s.n.], 2021. p. 428–433. DOI: 10.1109/DASC-PICom-CBDCom-CyberSciTech52372.2021.00078.

ZHAO, J. et al. PM2.5 prediction based on the combined emd-lstm model. In: *2021 International Conference on Computational Science and Computational Intelligence (CSCI)*. [S.l.: s.n.], 2021. p. 193–195. DOI: 10.1109/CSCI54926.2021.00104.

ZHOU, H. et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2021. v. 35, n. 12, p. 11106–11115. DOI: 10.1609/aaai.v35i12.17325.

ZHOU, S. et al. Deep-learning architecture for PM2.5 concentration prediction: A review. *Environmental Science and Ecotechnology*, v. 21, p. 100400, 2024. DOI: 10.1016/j.ese.2024.100400.