

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
INSTITUTO DE CIÊNCIAS EXATAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

**Estudo ^{comparativo} ~~experimental~~ de modelos para
previsão horária de PM2.5**

Daniel Fagundes Portes Fernandes

JUIZ DE FORA
DEZEMBRO, 2026

Estudo experimental de modelos para previsão horária de PM2.5

DANIEL FAGUNDES PORTES FERNANDES

Universidade Federal de Juiz de Fora
INSTITUTO DE CIÊNCIAS EXATAS
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
Bacharelado em Ciência da Computação

Orientador: Luciana Conceição Dias Campos

JUIZ DE FORA
DEZEMBRO, 2026

ESTUDO EXPERIMENTAL DE MODELOS PARA PREVISÃO HORÁRIA DE PM2.5

Daniel Fagundes Portes Fernandes

MONOGRAFIA SUBMETIDA AO CORPO DOCENTE DO INSTITUTO DE CIÊNCIAS
EXATAS DA UNIVERSIDADE FEDERAL DE JUIZ DE FORA,
COMO PARTE INTEGRANTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO
DO GRAU DE BACHAREL EM CIÊNCIA DA COMPUTAÇÃO.

Aprovada por:

Luciana Conceição Dias Campos
Doutora em Engenharia Elétrica PUC-Rio

JUIZ DE FORA
02 DE DEZEMBRO, 2026

Aos meus amigos e irmãos.

Aos meus pais, pelo apoio e sustento.

Agradecimentos

A todos os meus parentes, pelo encorajamento e apoio.

Ao meu orientador, pela orientação, amizade e principalmente, pela paciência, sem a qual este trabalho não se realizaria.

Aos professores do Departamento de Ciência da Computação pelos seus ensinamentos e aos funcionários do curso, que durante esses anos, contribuíram de algum modo para o meu enriquecimento pessoal e profissional.

O Resumo que eu arrumei, mas antes de ler tudo:

O material particulado fino (denominado PM_{2,5}) é um poluente atmosférico crítico, cujos elevados níveis estão diretamente associados a agravos à saúde pública, sobrecarga do sistema de saúde e desequilíbrios ambientais. A previsão horária de curto prazo torna-se, portanto, uma ferramenta estratégica para sistemas de alerta precoce e gestão da qualidade do ar. Contudo, essa tarefa é desafiadora devido à natureza não linear, ruidosa e frequentemente incompleta das séries de monitoramento, além da dependência causal de variáveis meteorológicas e de emissão. Este trabalho propõe um estudo experimental comparativo para previsão horária de PM_{2,5} com horizonte de 24 horas, utilizando como base a Estação Sapo, integrante da rede CMD (Conjunto de Monitoramento da Qualidade do Ar). A estação foi selecionada por sua representatividade urbana e por apresentar a menor taxa de dados faltantes da rede, minimizando vieses de imputação e preservando a estrutura temporal original. O protocolo experimental utiliza as 48 horas antecedentes como janela de entrada e as variáveis preditoras incluem defasagens de PM_{2,5} e PM₁₀, indicadores temporais, termos de Fourier para sazonalidade e proxies causais de PM₁₀ disponíveis no instante da previsão. Foi aplicada uma técnica de mascaramento para excluir valores imputados do alvo da função de perda e das métricas de avaliação. Foram comparados modelos de LSTM (recursiva e direta), arquiteturas Seq2Seq (com e sem mecanismo de atenção e perda L1 ponderada) e XGBoost multissaiada, com ajuste de hiperparâmetros via validação walk-forward e análise de robustez por múltiplas sementes. Nos resultados principais, a LSTM direta destacou-se como o modelo mais equilibrado. O XGBoost consolidou-se como linha de base tabular robusta, enquanto o Seq2Seq com atenção melhorou a captura de picos sem superar o erro médio da LSTM direta. Experimentos diagnósticos com variáveis auxiliares futuras elevaram o R^2 , evidenciando que parte da variância horária depende de informações não disponíveis causalmente no cenário operacional. Conclui-se que a modelagem deve equilibrar a minimização do erro médio, a preservação da amplitude dos picos e a disponibilidade causal de variáveis explicativas, oferecendo subsídios práticos para sistemas operacionais de previsão da qualidade do ar.

*“Lembra que o sono é sagrado e alimenta
de horizontes o tempo acordado de vi-
ver.”*

Beto Guedes (Amor de Índio)

Adaptar pelo resumo que eu apresentei acima

Resumo

O material particulado fino (PM2.5) é um poluente atmosférico associado a impactos relevantes na saúde pública, o que torna sua previsão de curto prazo uma tarefa útil para análise ambiental e apoio a alertas. Este trabalho apresenta um estudo experimental comparável para previsão horária de PM2.5 na estação Sapo, no conjunto CMD. A tarefa principal usa 48 horas anteriores para prever as 24 horas seguintes, com divisão cronológica externa 70/15/15 e avaliação final no teste. O protocolo final utiliza PM2.5, PM10, indicadores de ausência, atributos temporais, termos de Fourier e variáveis substitutas causais de PM10 disponíveis no momento da previsão. Também são usadas máscaras para impedir que valores imputados do alvo sejam tratados como verdade observada na função de perda e nas métricas. Foram comparadas LSTM recursiva, LSTM direta, Seq2Seq básico, Seq2Seq atenção canônica, Seq2Seq atenção com L1 ponderada e XGBoost com saída múltipla, com busca de hiperparâmetros por validação temporal *walk-forward* dentro do bloco de desenvolvimento e análise com múltiplas sementes. No resultado principal, a LSTM direta foi o melhor modelo por MAE, com MAE 2,7713, RMSE 3,8346 e R2 0,5154 na semente canônica. O XGBoost permaneceu uma linha de base tabular forte, enquanto o Seq2Seq com atenção e L1 ponderada melhorou parte do comportamento em picos e cauda sem superar a LSTM direta no erro médio. Experimentos diagnósticos com variáveis auxiliares futuras reais elevaram o R2 do Seq2Seq para aproximadamente 0,65, indicando que parte da variância horária depende de informação não disponível causalmente no contrato atual. Os resultados indicam um compromisso entre erro médio, preservação de amplitude e disponibilidade de variáveis explicativas para eventos de maior concentração.

Palavras-chave: PM2.5, previsão de séries temporais, aprendizado profundo, LSTM, Seq2Seq, XGBoost, qualidade do ar. **letra maiúscula**

Abstract

Fine particulate matter (PM2.5) is an air pollutant associated with relevant public health impacts, making short-term forecasting useful for environmental analysis and warning support. This work presents a comparable experimental study for hourly PM2.5 forecasting at the Sapo monitoring station in the CMD dataset. The main task uses the previous 48 hours to forecast the next 24 hours, with an external chronological 70/15/15 holdout and final evaluation on the test set. The final protocol uses PM2.5, PM10, missingness flags, temporal attributes, Fourier terms, and causal PM10 proxies available at prediction time. Target observation masks are also used to prevent imputed target values from being treated as observed truth in the loss and metrics. The study compares recursive LSTM, direct LSTM, basic Seq2Seq, canonical attention Seq2Seq, weighted-L1 attention-based Seq2Seq, and multi-output XGBoost under walk-forward hyperparameter search within the development block and multi-seed analysis. In the main result, the direct LSTM was the best model by MAE, with MAE 2.7713, RMSE 3.8346, and R2 0.5154 in the canonical seed. XGBoost remained a strong tabular baseline, while weighted-L1 attention-based Seq2Seq improved part of its behavior in peaks and tail regimes without surpassing the direct LSTM in average error. Diagnostic experiments with real future auxiliary variables raised the Seq2Seq R2 to approximately 0.65, indicating that part of the hourly variance depends on information that is not causally available in the current feature contract. The results indicate a trade-off between average error, amplitude preservation, and the availability of explanatory variables for higher-concentration events.

Keywords: PM2.5, time series forecasting, deep learning, LSTM, Seq2Seq, XGBoost, air quality.

Índice

Lista de Figuras	7
Lista de Tabelas	8
Lista de Abreviações	1
1 Introdução	2
1.1 Problema de Pesquisa e Contribuições	3
1.2 Objetivos	4
1.2.1 Objetivo Geral	4
1.2.2 Objetivos Específicos	4
1.3 Organização do Trabalho	5
2 Fundamentação Teórica	6
2.1 PM2.5 e Monitoramento da Qualidade do Ar	6
2.2 Séries Temporais Multivariadas	6
2.2.1 Validação cruzada temporal e <i>walk-forward</i>	8
2.3 Previsão de Múltiplos Passos	9
2.4 Dados Faltantes, Imputação e Vazamento Temporal	10
2.5 Janelas e Variáveis Exógenas	11
2.6 Redes Neurais e Aprendizado Profundo	11
2.7 Redes Neurais Recorrentes e LSTM	13
2.8 Seq2Seq e Atenção	15
2.9 <i>Teacher Forcing</i> e <i>Scheduled Sampling</i>	17
2.10 Impulsionamento por Gradiente e XGBoost	19
2.11 Treinamento, Função de Perda e HPO	20
2.12 Métricas de Avaliação	23
2.13 Resumo do Capítulo	23
3 Trabalhos Relacionados	25
3.1 Referências Estruturantes em Previsão	25
3.2 Modelos para Previsão de PM2.5	26
3.3 Deep Learning para Qualidade do Ar	27
3.4 Seq2Seq, Previsão Multi-Horizonte e Atenção	27
3.5 Dados Faltantes em Séries Ambientais	29
3.6 Protocolos de Avaliação Temporal	29
3.7 Posicionamento deste TCC	30
4 Materiais e Métodos	32
4.1 Fonte de Dados e Escopo	32
4.2 Análise Exploratória e Escolha da Estação	33
4.2.1 Padrões Temporais de PM2.5 e PM10	35
4.3 Formulação da Tarefa	38
4.4 Pré-processamento	39
4.5 Engenharia de Atributos	39

4.6	Modelos Avaliados	40
4.7	Treinamento e Busca de Hiperparâmetros	41
4.8	Métricas de Avaliação	44
4.9	Reprodutibilidade	45
5	Resultados e Discussão	46
5.1	Caracterização da Comparação Principal	46
5.2	Resultado Principal com HPO <i>Walk-Forward</i>	46
5.3	Estabilidade com Múltiplas Sementes	48
5.4	Linhas de Base Ingênuas	49
5.5	Erro por Horizonte	49
5.6	Picos, Cauda e Suavização	50
5.6.1	Análise por Evento de Pico	52
5.7	Seq2Seq com Atenção e Perda L1 Ponderada	52
5.8	Ablação PM10 Causal	53
5.9	Limite Informacional com Variáveis Futuras	53
5.10	Seq2Seq Multi-Alvo com Variáveis Auxiliares	55
5.11	Ablação de Máscara e Imputação	55
5.12	Análise dos Pesos de Atenção	56
5.13	Ablações Auxiliares e Resultados Negativos	59
5.14	Ameaças à Validade	59
6	Conclusão	61
6.1	Limitações	62
6.2	Trabalhos Futuros	62
	Bibliografia	64

Lista de Figuras

2.1	Validação cruzada temporal por janela expansiva	9
2.2	Comparação visual entre neurônio biológico e neurônio artificial	12
2.3	Diagrama conceitual de uma célula LSTM. Elaboração própria com base em Hochreiter e Schmidhuber (1997).	14
2.4	Diagrama conceitual de Seq2Seq com atenção para previsão 48 para 24 horas. Elaboração própria com base em Sutskever, Vinyals e Le (2014), Bahdanau, Cho e Bengio (2014), Luong, Pham e Manning (2015) e Qin et al. (2017).	16
2.5	<i>Teacher forcing, scheduled sampling</i> e agenda crescente	18
2.6	Conversão de uma janela temporal em matriz tabular para XGBoost com saída múltipla. Elaboração própria com base em Chen e Guestrin (2016). . .	19
4.1	Classificação preliminar das estações por previsibilidade de PM2.5 com contexto de PM10.	34
4.2	Cobertura mensal e maiores lacunas originais de PM2.5 no artefato Sapo. .	35
4.3	Distribuição observada de PM2.5 e frequência de eventos altos por partição.	35
4.4	Série temporal de PM2.5 e decomposição descritiva no artefato Sapo. Elaboração própria com base na decomposição aditiva discutida por Hyndman e Athanasopoulos (2021).	36
4.5	Formulação da tarefa de múltiplos passos do protocolo Sapo.	38
4.6	Linha temporal da divisão cronológica externa usada no artefato Sapo. . .	39
5.1	Evolução do MAE de validação e da taxa de aprendizado nos modelos neurais com métricas consolidadas. As estrelas indicam o melhor ponto de controle selecionado por validação; os círculos indicam a última época registrada antes da parada antecipada.	48
5.2	Evolução do MAE por horizonte no teste externo para os modelos com métricas consolidadas.	50
5.3	Predições agregadas no teste em uma janela com evento de maior concentração, separadas por modelo e com interrupções nas lacunas temporais. . .	51
5.4	Perfil médio dos pesos de atenção temporal no codificador para as variantes Seq2Seq avaliadas, após agregação sobre janelas e horizontes previstos. . .	56
5.5	Mapa de calor médio dos pesos de atenção da melhor variante Seq2Seq atenção com L1 ponderada por horizonte previsto e posição do codificador. O painel inferior mostra a média por posição calculada a partir do próprio mapa.	57

Lista de Tabelas

3.1	Diferenças de contrato em trabalhos recentes de PM2.5 em relação ao protocolo Sapo.	31
4.1	Resumo do contrato experimental principal.	32
4.2	Resumo exploratório do artefato Sapo por partição.	34
4.3	Padrões temporais observados de PM2.5 e PM10 no artefato Sapo.	37
4.4	Divisão cronológica externa do conjunto final de Sapo.	38
4.5	Variáveis do protocolo final.	40
4.6	Modelos avaliados na comparação principal.	40
4.7	Espaço de busca de hiperparâmetros na comparação principal.	43
4.8	Hiperparâmetros selecionados pela busca na comparação principal.	43
5.1	Resultado principal no protocolo final de Sapo com HPO <i>walk-forward</i> . . .	47
5.2	Estabilidade com múltiplas sementes dos modelos selecionados.	48
5.3	Linhas de base ingênuas no teste externo.	49
5.4	MAE por horizonte no teste.	50
5.5	Métricas de amplitude e cauda no teste.	51
5.6	Métricas por evento contínuo de pico no teste.	52
5.7	Seq2Seq com <code>weighted_l1</code> após HPO <i>walk-forward</i>	52
5.8	Ablação de PM10 causal no contrato final.	53
5.9	Diagnóstico <i>oracle future auxiliary</i> no Seq2Seq atenção em Sapo.	54
5.10	Experimentos Seq2Seq multi-alvo com PM10 e PTS como tarefas auxiliares. .	55
5.11	Ablação de máscara do alvo e imputação.	56
5.12	Diagnósticos agregados dos pesos de atenção no teste.	58

Lista de Abreviações

ANN	Artificial Neural Network (Rede Neural Artificial)
BPTT	Backpropagation Through Time
DCC	Departamento de Ciência da Computação
FEAM	Fundação Estadual do Meio Ambiente
GRU	Gated Recurrent Unit
HPO	Hyperparameter Optimization (Otimização de Hiperparâmetros)
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error (Erro Médio Absoluto)
MAPE	Mean Absolute Percentage Error (Erro Percentual Médio Absoluto)
MLP	Multi-Layer Perceptron
MSE	Mean Squared Error (Erro Quadrático Médio)
MTS	Multi-variate Time Series (Séries Temporais Multivariadas)
NLL	Negative Log-Likelihood
ODS	Objetivos de Desenvolvimento Sustentável
OMS	Organização Mundial da Saúde
PM10	Material Particulado com diâmetro inferior a 10 micrômetros
PM2.5	Material Particulado com diâmetro inferior a 2.5 micrômetros
R2	Coefficiente de Determinação
ReLU	Rectified Linear Unit
RMSE	Root Mean Squared Error (Raiz do Erro Quadrático Médio)
RNN	Recurrent Neural Network (Rede Neural Recorrente)
Seq2Seq	Sequence-to-Sequence
SMAPE	Symmetric Mean Absolute Percentage Error (Erro Percentual Médio Absoluto Simétrico)
UFJF	Universidade Federal de Juiz de Fora
XGBoost	Extreme Gradient Boosting

1 Introdução

A poluição atmosférica por material particulado fino (*Particulate Matter*, PM2.5) permanece entre os problemas ambientais de maior impacto direto sobre a saúde pública. Por possuir diâmetro aerodinâmico inferior a 2,5 micrômetros, esse poluente consegue penetrar profundamente no sistema respiratório e está associado a desfechos respiratórios e cardiovasculares adversos (World Health Organization, 2021; POPE; DOCKERY, 2006; BROOK et al., 2010). A carga global de doença atribuível à poluição atmosférica por partículas finas reforça a importância de sistemas de monitoramento, prevenção e resposta (COHEN et al., 2017). No Brasil, episódios associados a queimadas e transporte atmosférico também ampliam a relevância do tema, com impactos mensuráveis sobre internações e mortalidade (REQUIA et al., 2021; REQUIA et al., 2022).

Nesse contexto, prever a concentração horária de PM2.5 com antecedência útil pode apoiar alertas, análise ambiental e planejamento operacional em regiões monitoradas. A tarefa, entretanto, é tecnicamente desafiadora. Séries ambientais reais combinam autocorrelação, sazonalidade, picos raros, mudanças de regime, ruído instrumental e lacunas de medição. Além disso, decisões aparentemente auxiliares, como imputação, normalização, criação de janelas, escolha do conjunto de atributos e separação temporal entre treino e teste, podem alterar substancialmente a conclusão experimental. Por isso, uma comparação entre modelos de previsão só é defensável quando essas escolhas são explicitadas e mantidas sob um protocolo comum.

A literatura recente tem explorado modelos de aprendizado profundo para previsão de PM2.5, incluindo redes recorrentes, LSTM e arquiteturas com codificador, decodificador e atenção (YANG et al., 2023; ZHAO et al., 2021; ZHANG; MA; YAN, 2021). Essas abordagens são atrativas porque conseguem modelar dependências temporais e relações não lineares. Ainda assim, em muitos estudos a comparação entre modelos mistura mudanças de arquitetura com mudanças de dados, horizonte de previsão, atributos disponíveis, imputação e procedimento de validação. Essa mistura dificulta responder se o ganho observado vem da arquitetura, do pré-processamento ou de outra decisão do fluxo

experimental.

Este trabalho parte desse problema metodológico. Em vez de apresentar a criação de um novo modelo como contribuição central, o TCC desenvolve um estudo experimental rastreável para previsão horária de PM2.5 na estação Sapo, no conjunto CMD. A tarefa principal usa as 48 horas anteriores para prever as 24 horas seguintes, com divisão cronológica externa em treino, validação e teste na proporção 70/15/15. A seleção de hiperparâmetros é feita por validação temporal *walk-forward* dentro do bloco de desenvolvimento anterior ao teste, mantendo o teste final reservado para avaliação fora da amostra. O protocolo final combina o alvo PM2.5 e o poluente PM10 com atributos temporais, termos de Fourier, indicadores de ausência e duas variáveis causais derivadas de PM10: um valor recente disponível antes da emissão da previsão e uma tendência calculada sem olhar o futuro. Essas variáveis representam informação disponível no momento da previsão, evitando uso indevido de dados futuros.

O estudo compara modelos sequenciais e uma linha de base tabular sob o mesmo contrato experimental. São avaliadas LSTM recursiva, LSTM direta, Seq2Seq básico, Seq2Seq atenção canônica, Seq2Seq atenção com L1 ponderada e XGBoost com saída múltipla. Além da comparação principal, o trabalho discute ablações metodológicas e variantes internas do Seq2Seq, incluindo estratégias de decodificação, uso de variáveis futuras causalmente disponíveis, funções de perda voltadas a picos e comportamento da atenção. A interpretação dos resultados distingue erro médio global, desempenho por horizonte e comportamento em regimes de maior concentração, pois modelos com melhor MAE podem produzir curvas mais suavizadas e subestimar eventos altos.

Não precisa quebrar em seção, mas faz um texto para linkar a parte de cima com essa parte aqui.

Você finaliza falando que fez um estudo rastreável. Explique o que significa isso, sem entrar em detalhe sobre como foi feito o experimento, porque os detalhes vamos ver nos capítulos,

Mas para motivar o leitor a ler.

1.1 Problema de Pesquisa e Contribuições

A pergunta central deste trabalho pode ser formulada da seguinte forma:

Em uma tarefa horária de previsão de PM2.5 na estação Sapo, com entrada de 48 horas, horizonte de 24 horas e teste temporal externo fixo, como diferentes escolhas de modelagem — arquiteturas sequenciais, linha de base tabular, imputação, variáveis exógenas e estratégias de treinamento — afetam o de-

o que vc usou de baseline?
Detalhar melhor no texto, antes de mostrar essa pergunta central.

o que significa isso?

e hiperparâmetros

de dados

o que vc quer dizer aqui é um comparativo com um modelo baseline? ficou confuso esse linha de base tabular, detalhar melhor.

sempenho preditivo e os erros por horizonte?

Para responder a essa pergunta, o trabalho é estruturado como um estudo experimental comparável. As principais contribuições são:

Antes explicar como chegou nesse horizonte de 48 para trás para prever 24 para frente, mesmo que seja explicado que através de estudos empíricos realizados anteriormente

1. Definir um protocolo rastreável de previsão horária de PM2.5 para a estação Sapo, com tarefa de múltiplos passos, entrada de 48 horas e horizonte de 24 horas.

isso está muito confuso para ser dito aqui, o importante é detalhar o seguinte: vc usou variáveis exógenas depois detalhar isso na metodologia, não aqui.

2. Consolidar um protocolo de dados com PM2.5, PM10, atributos temporais, indicadores de ausência e variáveis substitutas causais de PM10 disponíveis para o horizonte de previsão, reduzindo risco de vazamento de informação futura.

o que é teste temporal externo? Se está dizendo comparar os resultados com a mesma preparação dos dados, só detalhar isso. Fez o pré-processamento e aplicou em todos os modelos para comparação.

3. Comparar, no mesmo teste temporal externo, modelos LSTM, Seq2Seq e XGBoost, incluindo variantes com atenção e perda ponderada.

4. Avaliar os resultados por métricas globais, métricas por horizonte e comportamento **o que é desempenho médio de resposta? Deixa isso mais claro.** em picos/cauda, separando desempenho médio de resposta a eventos de maior concentração.

5. Documentar resultados ~~negativos e compromissos de modelagem, especialmente no uso de atenção, perdas ponderadas e estratégias voltadas a picos.~~

,avaliando se os modelos testados são realmente eficazes ou detalhando o que falhou.

1.2 Objetivos

1.2.1 Objetivo Geral

Avaliar, sob um protocolo experimental rastreável e comparável, o desempenho de modelos de aprendizado de máquina ~~e aprendizado profundo~~ para previsão horária de ~~múltiplos passos~~ de PM2.5 ~~na estação Sapo, distinguindo erro médio global, erros por horizonte e comportamento em regimes de maior concentração.~~

1.2.2 Objetivos Específicos

para mim aqueles 5 passos são os objetivos específicos do seu trabalho

1. Construir uma base horária para a estação Sapo com PM2.5, PM10, atributos temporais, termos de Fourier, indicadores de ausência e variáveis substitutas causais de PM10.

2. Definir a tarefa de previsão 48 -> 24 com divisão cronológica externa 70/15/15 e seleção de hiperparâmetros por *walk-forward*.
3. Descrever o pré-processamento com imputação, normalização e máscaras para impedir que valores imputados do alvo distorçam a função de perda e as métricas observadas. isso é importante detalhar não entendi isso ainda
4. Comparar LSTM direta/recursiva, Seq2Seq básico, duas variantes Seq2Seq com atenção e XGBoost com saída múltipla no teste externo.
5. Avaliar os modelos por MAE, RMSE, MAPE, R2, métricas por horizonte e métricas de cauda/picos.
6. Discutir ablações relevantes de imputação, uso causal de PM10, funções de perda, desenho do decodificador, atenção e busca de hiperparâmetros.
7. Identificar limitações do protocolo e caminhos de extensão para múltiplas estações, avaliação de eventos extremos e modelos espaço-temporais.

1.3 Organização do Trabalho

cadê a seção de Motivação do seu trabalho?

Este documento está estruturado em seis capítulos. O Capítulo 1 apresenta a motivação, o problema de pesquisa, as contribuições e os objetivos. O Capítulo 2 reúne os conceitos para fundamentar o trabalho. necessários ~~sobre PM2.5, séries temporais, dados faltantes, modelos recorrentes, Seq2Seq, atenção, linha de base tabular e métricas de avaliação.~~ faz uma revisão sistemática do tema na literatura? O Capítulo 3 ~~posiciona~~ o trabalho na literatura de previsão de qualidade do ar e discute lacunas de comparabilidade experimental. O Capítulo 4 descreve a metodologia do trabalho, o protocolo experimental, o contrato de dados, os modelos, o treinamento e as métricas. O Capítulo 5 apresenta os resultados dos experimentos realizados. ~~principais, as análises por horizonte e as ablações auxiliares.~~ Por fim, o Capítulo 6 sintetiza as conclusões, limitações e possibilidades de continuidade.

2 Fundamentação Teórica

Este capítulo apresenta os conceitos usados no protocolo experimental deste trabalho. O foco é a previsão horária de múltiplos passos de PM2.5 em séries temporais ambientais, com dados faltantes, variáveis exógenas conhecidas no momento da previsão, redes neurais artificiais, modelos recorrentes, arquiteturas codificador-decodificador com atenção e uma linha de base tabular baseada em impulsionamento por gradiente (*gradient boosting*).

2.1 PM2.5 e Monitoramento da Qualidade do Ar

PM2.5 designa partículas finas com diâmetro aerodinâmico de até 2,5 micrômetros. Por seu tamanho reduzido, elas podem penetrar profundamente no sistema respiratório e estão associadas a impactos respiratórios e cardiovasculares relevantes (POPE; DOCKERY, 2006; BROOK et al., 2010). As diretrizes globais da Organização Mundial da Saúde tratam PM2.5 e PM10 como poluentes prioritários para avaliação de qualidade do ar (World Health Organization, 2021).

Em redes de monitoramento, as concentrações de poluentes são medidas em intervalos regulares e formam séries temporais. A previsão de curto prazo busca estimar concentrações futuras a partir de medições recentes e de variáveis auxiliares. No contexto deste trabalho, a tarefa é horária: usa-se uma janela de 48 horas passadas para prever as próximas 24 horas de PM2.5 na estação Sapo.

2.2 Séries Temporais Multivariadas

Uma série temporal é uma sequência de observações indexadas no tempo. Em qualidade do ar, a concentração de um poluente depende de autocorrelação, ciclos diários e semanais, condições meteorológicas, variações de emissão, mudanças de regime e eventos raros. Quando múltiplas variáveis são observadas simultaneamente, como PM2.5, PM10 e atributos temporais, a tarefa passa a ser multivariada.

A análise de séries temporais costuma separar padrões em componentes interpretáveis. Hyndman e Athanasopoulos (2021) distinguem tendência, sazonalidade, ciclos e variações remanescentes como padrões úteis para escolher métodos de previsão. Em uma decomposição aditiva simples, uma observação pode ser representada por:

$$y_t = T_t + S_t + R_t,$$

em que T_t representa tendência ou tendência-ciclo, S_t representa sazonalidade de período conhecido e R_t representa o restante da série, incluindo ruído, mudanças abruptas e eventos raros. Para séries horárias, pode haver mais de uma sazonalidade relevante, como ciclo diário, semanal e anual. No protocolo deste TCC, essa leitura motiva o uso de atributos temporais e termos de Fourier para representar ciclos conhecidos, além de defasagens e variáveis substitutas causais para capturar dependências temporais sem usar informação futura.

Outro conceito central é autocorrelação, isto é, a associação entre a série e versões defasadas dela mesma. Para uma defasagem ℓ , a autocorrelação amostral pode ser escrita como:

$$\rho(\ell) = \frac{\sum_t (y_t - \bar{y})(y_{t-\ell} - \bar{y})}{\sum_t (y_t - \bar{y})^2}.$$

Valores altos de $\rho(1)$, $\rho(24)$ ou $\rho(168)$ indicam, respectivamente, persistência de curto prazo, repetição diária e repetição semanal. No diagnóstico exploratório do artefato final de Sapo, considerando pares observados completos de PM2.5, a autocorrelação foi aproximadamente 0,81 em 1 hora, 0,68 em 24 horas e 0,46 em 168 horas. Isso ajuda a justificar a janela histórica de 48 horas, a avaliação de defasagens sazonais e a presença de termos cíclicos no conjunto de atributos.

Formalmente, seja $\mathbf{x}_t \in \mathbb{R}^d$ o vetor de atributos observado no instante t , $y_t \in \mathbb{R}$ a concentração de PM2.5 e $\mathbf{z}_{t+k}$ o vetor de atributos futuros conhecidos no instante de emissão da previsão, como calendário, termos de Fourier e variáveis substitutas causais. Para uma janela de entrada de tamanho L e horizonte H , o problema pode ser escrito como:

$$\hat{\mathbf{y}}_{t+1:t+H} = f_{\theta}(\mathbf{x}_{t-L+1:t}, \mathbf{z}_{t+1:t+H}),$$

em que f_{θ} é o modelo treinado e $\hat{\mathbf{y}}_{t+1:t+H} = (\hat{y}_{t+1}, \dots, \hat{y}_{t+H})$. Neste TCC, $L = 48$ e $H = 24$. Essa formulação explicita a diferença entre variáveis observadas apenas no passado e variáveis conhecidas para o horizonte futuro.

Em problemas de previsão, a ordem temporal dos dados deve ser preservada. Separações aleatórias, comuns em tarefas tabulares independentes, podem introduzir vazamento de informação futura em séries temporais. Por isso, avaliações fora da amostra e divisões cronológicas são recomendadas para estimar desempenho em um cenário próximo ao uso real (HYNDMAN; ATHANASOPOULOS, 2021; TASHMAN, 2000; BERGMEIR; BENITEZ, 2012).

2.2.1 Validação cruzada temporal e *walk-forward*

A validação cruzada tradicional divide os dados em partições e assume exemplos aproximadamente independentes. Essa suposição não vale diretamente para séries temporais, nas quais observações vizinhas compartilham autocorrelação, sazonalidade e tendência. Em previsão, uma avaliação coerente deve respeitar a direção do tempo: o modelo só pode ser treinado com dados anteriores ao período validado. Essa preocupação é central em testes fora da amostra para previsão (TASHMAN, 2000) e motiva adaptações da validação cruzada para séries temporais (BERGMEIR; BENITEZ, 2012; HYNDMAN; ATHANASOPOULOS, 2021).

Uma adaptação comum é a validação cruzada temporal por janela expansiva, também chamada de *walk-forward validation*. Nesse procedimento, cada partição usa uma janela de treino que termina antes do bloco de validação seguinte. A cada nova partição, a janela de treino se expande e a validação avança para um período futuro. Assim, o protocolo avalia várias origens temporais de previsão sem permitir que dados futuros influenciem o treinamento. Para K partições, a métrica de seleção pode ser resumida pela média:

$$\mathcal{L}_{CV} = \frac{1}{K} \sum_{k=1}^K \mathcal{L}_{val}^{(k)}.$$

No contexto deste TCC, a validação cruzada temporal é usada para seleção de hiperparâmetros dentro do bloco de desenvolvimento anterior ao teste. Ela não substitui o teste cronológico externo: o conjunto de teste final permanece separado e só é usado depois da seleção, para estimar o desempenho fora da amostra. A Figura 2.1 ilustra esse protocolo para uma janela expansiva com três partições e teste final reservado.




Figura 2.1: Validação cruzada temporal por janela expansiva, ou *walk-forward validation*. Cada partição treina com dados passados e valida no bloco temporal seguinte dentro do bloco de desenvolvimento; o teste final permanece reservado para avaliação fora da amostra. Elaboração própria com base em Tashman (2000), Bergmeir e Benitez (2012) e Hyndman e Athanasopoulos (2021).

2.3 Previsão de Múltiplos Passos

Na previsão de múltiplos passos, o objetivo é estimar mais de um instante futuro. Para uma entrada $\mathbf{x}_{t-47:t}$ e um horizonte de 24 horas, o modelo deve produzir $\hat{y}_{t+1:t+24}$. Revisões recentes de previsão com aprendizado profundo descrevem arquiteturas de codificador e decodificador tanto para previsão um-passo quanto para previsão multi-horizonte (LIM; ZOHREN, 2021; BENIDIS et al., 2022). Três estratégias são especialmente relevantes:

- **Previsão recursiva:** o modelo aprende uma função de um passo $\hat{y}_{t+1} = g_{\theta}(\mathbf{x}_{t-L+1:t})$ e realimenta suas próprias saídas para obter $\hat{y}_{t+2}, \dots, \hat{y}_{t+H}$. A estratégia é simples, mas pode acumular erros ao longo do horizonte.

- **Previsão direta:** o modelo aprende diretamente $\hat{\mathbf{y}}_{t+1:t+H} = g_{\theta}(\mathbf{x}_{t-L+1:t})$. Isso reduz a realimentação de erro, mas exige aprender a estrutura conjunta do horizonte.
- **Codificador-decodificador:** uma rede codifica a janela de entrada e outra gera a sequência futura, possivelmente condicionada por variáveis conhecidas no horizonte. Essa formulação é natural para tarefas sequência-para-sequência.

Este trabalho compara essas alternativas por meio de LSTM recursiva, LSTM direta, Seq2Seq básico, Seq2Seq atenção canônica e Seq2Seq atenção com L1 ponderada. Também é avaliada uma linha de base XGBoost com saída múltipla, que prevê o horizonte completo de forma tabular. A comparação é necessária porque a literatura de previsão não sustenta uma única arquitetura universalmente dominante; revisões de RNNs para séries temporais ressaltam que não existem “*no silver bullets*” em previsão (HEWAMALAGE; BERGMEIR; BANDARA, 2021).

2.4 Dados Faltantes, Imputação e Vazamento Temporal

Dados ambientais reais frequentemente contêm lacunas por falhas de sensor, manutenção, comunicação ou filtragem de leituras inconsistentes. A ausência de dados deve ser tratada com cuidado porque pode afetar tanto o treinamento quanto a avaliação. A literatura de dados faltantes diferencia o valor não observado do valor realmente medido; tratá-los como equivalentes pode distorcer inferências e métricas (RUBIN, 1976).

Imputação é o processo de preencher lacunas com estimativas. Métodos simples, como interpolação linear, preservam a estrutura temporal local e são transparentes; métodos multivariados, como MICE e MissForest, exploram relações entre variáveis (BUUREN; GROOTHUIS-OUDSHOORN, 2011; STEKHOVEN; BUHLMANN, 2012). Métodos baseados em atenção, como SAITS, também foram propostos para imputação em séries temporais (DU et al., 2023). Neste TCC, entretanto, SAITS não é o método central: o contrato final usa imputação linear e registra uma máscara para impedir que valores imputados do alvo sejam tratados como observações reais na função de perda e

nas métricas.

Outro risco é o vazamento temporal. A imputação, a normalização e a criação de atributos precisam ser ajustadas sem usar estatísticas futuras indisponíveis no instante de previsão. Por isso, o protocolo deste trabalho usa divisão cronológica, estatísticas de normalização calculadas no treino e atributos futuros apenas quando são conhecidos causalmente, como calendário e variáveis substitutas de PM10 defasadas.

2.5 Janelas e Variáveis Exógenas

Modelos supervisionados de séries temporais costumam converter uma sequência contínua em pares de entrada e saída por janelas deslizantes. No caso deste trabalho, cada amostra contém 48 horas de histórico e 24 valores futuros de PM2.5 como alvo. A sobreposição entre janelas aumenta o número de exemplos, mas exige cuidado para manter a divisão temporal e evitar que uma janela de treino alcance o período de validação ou teste.

Defasagens explícitas e variáveis exógenas podem aumentar a informação disponível para o modelo. No entanto, uma variável exógena só pode entrar no decodificador se estiver disponível no momento em que a previsão seria feita. Atributos de calendário e termos de Fourier são conhecidos antecipadamente. Já PM10 futuro não deve ser usado diretamente; por isso, o contrato final usa variáveis substitutas causais, como $PM10(t - 24)$ e a tendência $PM10(t - 24) - PM10(t - 27)$, que usam apenas medições anteriores ao início do horizonte.

2.6 Redes Neurais e Aprendizado Profundo

Redes neurais artificiais são modelos paramétricos compostos por unidades simples conectadas por pesos. A inspiração histórica vem de modelos computacionais do neurônio biológico, como o neurônio lógico de McCulloch e Pitts (1943) e o perceptron de Rosenblatt (1958). Essa relação, porém, deve ser entendida como uma analogia didática. Redes neurais usadas em aprendizado de máquina não simulam de forma completa a fisiologia de neurônios reais; elas usam uma abstração matemática capaz de combinar entradas, ajustar pesos e produzir saídas.

Em um neurônio biológico, dendritos recebem sinais, o corpo celular integra parte dessas informações e o axônio transmite sinais para outras células. Em um neurônio artificial, a operação análoga é representada por entradas numéricas, pesos, viés e uma função de ativação. A Figura 2.2 apresenta essa relação de forma visual.




Figura 2.2: Comparação visual entre neurônio biológico e neurônio artificial. A imagem do neurônio biológico possui rótulos em português do Brasil e foi obtida de Napvasconcelos e Vasconcelos (2008); a imagem do perceptron explicita entradas x_i , pesos w_i , soma ponderada, função de ativação φ e saída o , conforme Thoma (2014).

Formalmente, para um vetor de entrada $\mathbf{x} = (x_1, \dots, x_d)$, um neurônio artificial calcula uma soma ponderada e aplica uma função de ativação:

$$a = \sum_{j=1}^d w_j x_j + b, \quad h = \phi(a).$$

Nessa expressão, w_j são pesos, b é o viés, a é a ativação antes da não linearidade e ϕ é uma função de ativação, como sigmoide, tangente hiperbólica ou ReLU. Os pesos e vieses são parâmetros aprendidos a partir dos dados. A função de ativação é importante porque introduz não linearidade; sem ela, uma composição de camadas lineares continuaria equivalente a uma única transformação linear.

Uma rede neural organiza vários neurônios em camadas. A saída de uma camada alimenta a camada seguinte, permitindo que o modelo componha transformações simples em representações mais complexas. De forma resumida, uma camada pode ser escrita como:

$$\mathbf{h}^{(\ell)} = \phi \left(W^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)} \right),$$

em que $W^{(\ell)}$ e $\mathbf{b}^{(\ell)}$ são os parâmetros da camada ℓ . O treinamento ajusta esses parâmetros para minimizar uma função de perda nos exemplos observados. Em tarefas de regressão, como a previsão de PM2.5 deste trabalho, essa perda mede a distância entre os valores previstos e observados.

Aprendizado profundo, ou *deep learning*, refere-se ao treinamento de redes neurais com múltiplas camadas e representações sucessivas dos dados (GOODFELLOW; BENGIO; COURVILLE, 2016; LECUN; BENGIO; HINTON, 2015). Em séries temporais, essa ideia é útil porque o modelo pode aprender relações não lineares entre medições recentes, variáveis exógenas, padrões cíclicos e o horizonte previsto. As arquiteturas recorrentes e codificador-decodificador discutidas nas seções seguintes são casos específicos de redes profundas voltadas a sequências: elas compartilham parâmetros ao longo do tempo, mantêm estados internos e produzem previsões para um ou mais passos futuros.

2.7 Redes Neurais Recorrentes e LSTM

Redes neurais recorrentes são projetadas para dados sequenciais, pois atualizam um estado interno conforme processam cada passo da sequência. Em RNNs simples, o treinamento pode sofrer com desaparecimento ou explosão de gradientes, dificultando o aprendizado de dependências mais longas. A arquitetura Long Short-Term Memory (LSTM) introduz uma célula de memória e portões de entrada, esquecimento e saída para controlar o fluxo de informação (HOCHREITER; SCHMIDHUBER, 1997).

Uma célula LSTM pode ser descrita pelas seguintes equações, para entrada $\mathbf{x}_t$, estado oculto anterior $\mathbf{h}_{t-1}$ e memória anterior $\mathbf{c}_{t-1}$:

$$\begin{aligned}
\mathbf{i}_t &= \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i), \\
\mathbf{f}_t &= \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f), \\
\mathbf{o}_t &= \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o), \\
\tilde{\mathbf{c}}_t &= \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c), \\
\mathbf{c}_t &= \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \\
\mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t).
\end{aligned}$$

O portão de esquecimento $\mathbf{f}_t$ controla quanto da memória anterior é preservado; o portão de entrada $\mathbf{i}_t$ controla quanto da nova informação candidata é incorporado; e o portão de saída $\mathbf{o}_t$ controla a parte da memória exposta no estado oculto. A Figura 2.3 resume essa estrutura.




Figura 2.3: Diagrama conceitual de uma célula LSTM. Elaboração própria com base em Hochreiter e Schmidhuber (1997).

Neste trabalho, a LSTM aparece em duas estratégias. Na LSTM recursiva, o modelo aprende a avançar ao longo do horizonte com realimentação. Na LSTM direta, o estado final da janela de entrada é projetado para todos os 24 passos futuros. A comparação entre as duas estratégias permite separar o efeito da arquitetura recorrente do efeito da forma de gerar o horizonte.

2.8 Seq2Seq e Atenção

Modelos Sequence-to-Sequence, ou Seq2Seq, foram propostos para mapear uma sequência de entrada em uma sequência de saída. Sutskever, Vinyals e Le (2014) descrevem a proposta como uma abordagem “*end-to-end*” para aprendizado de sequências, em que um codificador transforma a entrada em representação latente e um decodificador gera a sequência de saída. Em séries temporais, essa estrutura é útil porque o decodificador pode produzir um horizonte completo e receber variáveis conhecidas para cada passo futuro.

Sejam $\mathbf{h}_j$ os estados do codificador para os L passos da janela de entrada. Uma formulação simplificada do codificador é:

$$\mathbf{h}_j = \text{Enc}_\theta(\mathbf{x}_{t-L+j}, \mathbf{h}_{j-1}), \quad j = 1, \dots, L.$$

Sem atenção, o decodificador depende principalmente de um vetor de contexto, frequentemente associado ao último estado do codificador. A atenção reduz esse gargalo. O próprio trabalho de Bahdanau, Cho e Bengio (2014) caracteriza o “*fixed-length vector*” como uma limitação em tarefas sequência-para-sequência. Com atenção aditiva, para cada passo futuro k , calculam-se escores, pesos normalizados e um contexto:

$$\begin{aligned} e_{k,j} &= \mathbf{v}_a^\top \tanh(W_s \mathbf{s}_{k-1} + W_h \mathbf{h}_j + \mathbf{b}_a), \\ \alpha_{k,j} &= \frac{\exp(e_{k,j})}{\sum_{\ell=1}^L \exp(e_{k,\ell})}, \\ \mathbf{c}_k &= \sum_{j=1}^L \alpha_{k,j} \mathbf{h}_j. \end{aligned}$$

O decodificador atualiza seu estado e produz a previsão:

$$\begin{aligned} \mathbf{s}_k &= \text{Dec}_\theta(\mathbf{s}_{k-1}, \tilde{y}_{t+k-1}, \mathbf{z}_{t+k}, \mathbf{c}_k), \\ \hat{y}_{t+k} &= g_\theta(\mathbf{s}_k, \mathbf{c}_k, \mathbf{z}_{t+k}). \end{aligned}$$

Nesse caso, $\tilde{y}_{t+k-1}$ representa o valor real anterior durante *teacher forcing* ou a previsão anterior durante inferência. Variações de atenção global e local também foram propostas, incluindo mecanismos do tipo Luong (LUONG; PHAM; MANNING, 2015). Para séries temporais multivariadas, arquiteturas como DA-RNN combinam atenção sobre

variáveis de entrada e atenção temporal (QIN et al., 2017).

A escolha de Seq2Seq neste TCC não se apoia na ideia de que ele seja sempre estado da arte. A justificativa é mais específica: a tarefa é naturalmente multi-horizonte, o decodificador pode ser condicionado por atributos futuros conhecidos e trabalhos de previsão adotam estruturas recorrentes sequência-para-sequência para prever múltiplos passos. Por exemplo, Wen et al. (2017) exploram a natureza temporal de “*Sequence-to-Sequence Neural Networks*” em previsão multi-horizonte, enquanto DeepAR e Temporal Fusion Transformer exemplificam linhas modernas de previsão profunda com decodificadores autoregressivos, covariáveis e previsão multi-horizonte (SALINAS et al., 2020; LIM et al., 2021). A Figura 2.4 sintetiza a arquitetura avaliada neste trabalho.




Figura 2.4: Diagrama conceitual de Seq2Seq com atenção para previsão 48 para 24 horas. Elaboração própria com base em Sutskever, Vinyals e Le (2014), Bahdanau, Cho e Bengio (2014), Luong, Pham e Manning (2015) e Qin et al. (2017).

No TCC, a atenção é tratada como uma família de mecanismos avaliados, não como garantia de superioridade. A interpretação dos resultados considera que pesos de atenção podem ser pouco informativos quando ficam quase uniformes ou quando o ganho de desempenho não aparece no teste externo.

2.9 Teacher Forcing e Scheduled Sampling

Em modelos com decodificador autoregressivo, o treinamento pode usar *teacher forcing*: em vez de alimentar a previsão anterior do próprio modelo, usa-se o valor observado anterior como entrada do próximo passo. Isso acelera o treinamento, mas cria diferença entre treino e inferência, já que em produção o valor real futuro não está disponível. Bengio et al. (2015) descrevem esse problema como discrepância entre treinamento e inferência, pois o item anterior verdadeiro está disponível no treino, mas é substituído por uma saída gerada pelo próprio modelo na inferência.

Seja p_{TF} a probabilidade de usar o valor real anterior no decodificador. Em cada passo futuro k , pode-se sortear $b_{i,k} \sim \text{Bernoulli}(p_{TF})$ e definir a entrada autoregressiva como:

$$\tilde{y}_{t+k-1} = b_{i,k}y_{t+k-1} + (1 - b_{i,k})\hat{y}_{t+k-1}.$$

Quando $p_{TF} = 1$, o modelo opera em *teacher forcing* puro; quando $p_{TF} = 0$, ele treina de modo equivalente à inferência autoregressiva, sempre realimentando suas próprias previsões. O *scheduled sampling* clássico propõe variar p_{TF} ao longo do treinamento, geralmente reduzindo essa probabilidade para deslocar gradualmente o decodificador de um regime totalmente guiado para um regime menos guiado e mais próximo da inferência (BENGIO et al., 2015).

Para previsão de séries temporais contínuas, entretanto, há uma motivação adicional para testar a direção oposta. Teutsch e Mäder (2022) argumentam que o *scheduled sampling* clássico, herdado de tarefas de NLP, pode não ser a estratégia mais adequada para previsão e propõem currículos de *Increasing Teacher Forcing*, denominados *Flipped Classroom*. Nessa família, o treinamento começa mais próximo de *free running*, com baixo p_{TF} , e aumenta gradualmente a presença de *teacher forcing*. Em experimentos com sistemas dinâmicos, os autores relataram ganhos de aproximadamente 15% a 80% em NRMSE em previsão de múltiplos passos em relação à melhor linha de base de *teacher forcing* ou *free running*, embora limitem a conclusão ao escopo experimental avaliado.

A Figura 2.5 resume essa diferença. A notação é importante: neste TCC, p_{TF}




Figura 2.5: Comparação entre *teacher forcing*, inferência autoregressiva, *scheduled sampling* clássico e agenda crescente de *teacher forcing*. Elaboração própria com base em Bengio et al. (2015) e Teutsch e Mäder (2022).

sempre significa probabilidade de usar o valor real anterior. Assim, uma agenda decrescente de p_{TF} aumenta o uso das próprias previsões do modelo e corresponde à intuição original do *scheduled sampling*; já uma agenda crescente de p_{TF} aumenta a dependência de *teacher forcing* e se aproxima da hipótese de *Increasing Teacher Forcing*. A inclusão dessa agenda crescente nas ablações do Seq2Seq foi motivada por essa literatura recente, mas, nos experimentos consolidados de Sapo, ela não produziu ganho determinístico suficiente para alterar o protocolo final. Por isso, na comparação principal, a técnica é tratada como ablação fundamentada de treinamento, não como componente responsável pelo melhor resultado.

2.10 Impulsioneamento por Gradiente e XGBoost

Modelos de árvores com impulsioneamento (*boosting*) constroem um preditor aditivo por meio de várias árvores fracas, ajustadas sequencialmente para corrigir erros residuais. O XGBoost é uma implementação eficiente de impulsioneamento por gradiente (*gradient boosting*) com regularização, paralelização e recursos práticos para dados tabulares (CHEN; GUESTRIN, 2016). Por lidar bem com atributos defasados e variáveis derivadas, ele é uma linha de base forte para previsão de séries temporais transformadas em matriz supervisionada.

No impulsioneamento aditivo, a predição após K árvores pode ser escrita como:

$$\hat{y}_i^{(K)} = \sum_{k=1}^K f_k(\mathbf{u}_i), \quad f_k \in \mathcal{F},$$

em que $\mathbf{u}_i$ é o vetor tabular de atributos da janela. O objetivo regularizado do XGBoost pode ser representado por:

$$\mathcal{L}^{(K)} = \sum_i \ell(y_i, \hat{y}_i^{(K)}) + \sum_{k=1}^K \Omega(f_k), \quad \Omega(f_k) = \gamma T_k + \frac{1}{2} \lambda \|\mathbf{w}_k\|_2^2.$$

Nessa expressão, T_k é o número de folhas da árvore e $\mathbf{w}_k$ são os pesos das folhas. A regularização penaliza árvores excessivamente complexas e ajuda a controlar sobreajuste. No protocolo deste TCC, o XGBoost é usado em versão com saída múltipla para prever os 24 passos do horizonte; a Figura 2.6 ilustra essa conversão tabular.




Figura 2.6: Conversão de uma janela temporal em matriz tabular para XGBoost com saída múltipla. Elaboração própria com base em Chen e Guestrin (2016).

A avaliação final ocorre no mesmo teste externo dos modelos neurais, mas o treinamento tem uma ressalva: a linha de base tabular exige janelas com horizonte completo observado, enquanto os modelos neurais usam máscara ponto a ponto para ignorar alvos imputados.

2.11 Treinamento, Função de Perda e HPO

Parâmetros são aprendidos pelo modelo durante o treinamento; hiperparâmetros, como taxa de aprendizado, número de camadas, tamanho do estado oculto e *dropout*, são definidos antes ou buscados por procedimento externo. Neste trabalho, redes neurais são treinadas com otimizadores baseados em gradiente, como Adam e AdamW (KINGMA; BA, 2014; LOSHCHILOV; HUTTER, 2019), e usam monitoramento em validação para seleção de ponto de controle.

A taxa de aprendizado controla o tamanho do passo aplicado aos parâmetros a cada atualização por gradiente. Ela pode ser mantida constante ou seguir uma agenda ao longo das épocas. Nos modelos neurais deste TCC, a taxa informada como hiperparâmetro corresponde ao valor nominal ou máximo, denotado por $\eta_{\max}$, e não a um valor fixo usado em todas as épocas. A agenda usada combina aquecimento linear (*linear warm-up*) e decaimento cosseno, estratégia relacionada ao uso de agendas cossenoidais em treinamento de redes neurais (LOSHCHILOV; HUTTER, 2017). Com E_w épocas de aquecimento, E épocas máximas e $\eta_{\min} = 0,01\eta_{\max}$, a forma idealizada é:

$$\eta_t = \begin{cases} \eta_{\max} \left(10^{-5} + (1 - 10^{-5}) \frac{t}{E_w} \right), & 0 \leq t \leq E_w, \\ \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left[1 + \cos \left(\pi \frac{t - E_w}{E - E_w} \right) \right], & E_w < t \leq E. \end{cases}$$

Assim, as primeiras épocas usam passos muito pequenos e aumentam gradualmente a taxa até $\eta_{\max}$. Depois do aquecimento, a taxa decai suavemente até 1% do valor nominal. Essa variação ocorre por época durante o treinamento. A etapa de validação, por sua vez, não aplica retropropagação nem atualiza os pesos; ela avalia o modelo no fim das épocas e fornece métricas para parada antecipada, escolha de ponto de controle e

poda de tentativas na HPO. Portanto, a validação influencia a seleção e a interrupção de treinamentos, mas não ajusta diretamente a taxa de aprendizado como ocorreria em uma agenda dependente da métrica de validação.

Também são usadas funções de perda robustas ou ponderadas. A perda de Huber combina comportamento quadrático para erros pequenos e linear para erros grandes, reduzindo a sensibilidade a outliers em comparação com o erro quadrático puro (HUBER, 1964). Para erro $e = y - \hat{y}$, ela é definida por:

$$\ell_{\delta}(e) = \begin{cases} \frac{1}{2}e^2, & \text{se } |e| \leq \delta, \\ \delta \left(|e| - \frac{1}{2}\delta \right), & \text{caso contrário.} \end{cases}$$

Como o conjunto de dados contém valores imputados, a função de perda observada usa uma máscara $m_{i,k}$ que vale 1 quando o alvo do exemplo i e horizonte k foi observado e 0 quando foi imputado:

$$\mathcal{J}(\theta) = \frac{\sum_{i,k} m_{i,k} \ell(y_{i,k}, \hat{y}_{i,k})}{\sum_{i,k} m_{i,k}}.$$

A variante `weighted_l1`, discutida nos resultados, altera explicitamente o objetivo para atribuir maior peso a determinados regimes de concentração e erros de subestimação:

$$\mathcal{J}_w(\theta) = \frac{\sum_{i,k} m_{i,k} w_{i,k} |y_{i,k} - \hat{y}_{i,k}|}{\sum_{i,k} m_{i,k} w_{i,k}}.$$

Essa formulação não é regularização L1 dos parâmetros; é uma perda absoluta ponderada no espaço das previsões. Por isso, a melhora em picos ou cauda deve ser interpretada como consequência de uma mudança de objetivo, e não como simples ganho arquitetural.

A busca de hiperparâmetros do resultado final foi conduzida com Optuna, ferramenta de otimização com definição dinâmica de espaços de busca, estratégias de amostragem e poda de tentativas pouco promissoras (AKIBA et al., 2019). Formalmente, seja $\lambda \in \Lambda$ um vetor de hiperparâmetros no espaço de busca Λ e seja $A(D_{treino}; \lambda)$ o algoritmo de treinamento com essa configuração. Em uma validação simples, o objetivo da HPO

seria selecionar a configuração com menor erro de validação:

$$\lambda^* = \arg \min_{\lambda \in \Lambda} \mathcal{L}_{val} (A(D_{treino}; \lambda), D_{val}).$$

No protocolo final, esse termo de validação é substituído pela média das partições temporais, isto é, pela métrica $\mathcal{L}_{CV}$ da validação *walk-forward*. Assim, a escolha de λ^* usa várias origens temporais dentro do desenvolvimento, sem consultar o teste final.

No Optuna, cada tentativa, ou *trial*, escolhe um ponto λ do espaço de busca, treina o modelo com esse ponto e retorna uma métrica objetivo. O conjunto de tentativas forma um estudo (*study*). A cada tentativa, o amostrador usa o histórico de configurações já avaliadas para propor novos hiperparâmetros. No caso padrão de otimização mono-objetivo, o Optuna usa o **TPESampler** como amostrador padrão (Optuna Contributors, 2026a). O TPE, ou *Tree-structured Parzen Estimator*, separa os valores de hiperparâmetros associados aos melhores resultados dos demais, ajusta modelos probabilísticos para esses dois grupos e tende a escolher novos valores que maximizem a razão entre regiões promissoras e não promissoras (Optuna Contributors, 2026d).

A poda, ou *pruning*, é uma forma de parada antecipada no nível da HPO. Em vez de treinar todas as configurações até o orçamento máximo, o treinamento reporta valores intermediários de validação; o mecanismo de poda decide se uma tentativa deve continuar ou ser interrompida. Nas redes neurais deste TCC, o recurso usado pelo mecanismo de poda é a época de treinamento e a métrica monitorada é o MAE de validação. A escolha principal foi o **HyperbandPruner**, que combina múltiplas instâncias de *Successive Halving*, chamadas de chaves (*brackets*), para distribuir orçamento entre muitas configurações baratas e poucas configurações que recebem mais épocas (LI et al., 2018; Optuna Contributors, 2026b). Essa escolha segue a própria documentação do Optuna, que indica o **HyperbandPruner** como a combinação recomendada com **TPESampler** em seus resultados de referência para tarefas mono-objetivo (Optuna Contributors, 2026a). O orçamento usado é controlado e limitado, adequado para comparação experimental de TCC, mas não deve ser interpretado como garantia de ótimo global.

2.12 Métricas de Avaliação

A avaliação de modelos de regressão de múltiplos passos deve combinar métricas globais e métricas por horizonte. O erro médio absoluto (MAE) mede a magnitude média dos erros e é menos sensível a valores extremos que o erro quadrático:

$$\text{MAE}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

A raiz do erro quadrático médio (RMSE) penaliza erros grandes com mais intensidade:

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}.$$

O erro percentual médio absoluto (MAPE) expressa o erro relativo em percentual, com cuidado adicional para valores próximos de zero:

$$\text{MAPE}(y, \hat{y}) = \frac{100}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i + \epsilon} \right|.$$

O coeficiente de determinação (R^2) compara o erro do modelo com a variância do alvo:

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}.$$

Além dessas métricas, este TCC analisa MAE por horizonte, viés médio, percentis altos previstos e erro em eventos de maior concentração. Essa combinação é necessária porque um modelo pode vencer em erro médio e ainda produzir curvas excessivamente suavizadas, subestimando picos relevantes para a interpretação ambiental.

2.13 Resumo do Capítulo

Este capítulo definiu a base teórica do estudo: PM2.5 como série temporal ambiental, componentes temporais, autocorrelação, previsão de múltiplos passos, tratamento de dados faltantes sem vazamento, janelas supervisionadas, variáveis exógenas causalmente

disponíveis, redes neurais artificiais, aprendizado profundo, LSTM, Seq2Seq com atenção, *scheduled sampling*, XGBoost, HPO e métricas. A formulação matemática deixa explícito o contrato de previsão 48 para 24 horas e a distinção entre arquiteturas recorrentes, codificador-decodificador e linha de base tabular.

3 Trabalhos Relacionados

Este capítulo posiciona o trabalho em relação à literatura de previsão de PM2.5 e de avaliação experimental em séries temporais. A discussão não busca listar arquiteturas de forma exaustiva; ela destaca estudos que justificam as decisões metodológicas do TCC: uso de modelos recorrentes, atenção, linhas de base tabulares, tratamento de dados faltantes, previsão multi-horizonte e protocolo temporal comparável.

3.1 Referências Estruturantes em Previsão

A primeira base do trabalho é a literatura de avaliação de previsão. Hyndman e Athanassopoulos (2021) sistematizam conceitos de previsão, métricas e validação fora da amostra; Tashman (2000) discutem testes fora da amostra como parte central da avaliação preditiva; e Bergmeir e Benitez (2012) analisam cuidados na validação cruzada para séries temporais. Essas referências sustentam a decisão de usar teste cronológico externo, validação temporal interna para seleção de hiperparâmetros e teste final reservado.

A segunda base é a literatura de aprendizado profundo para séries temporais. Lim e Zohren (2021) revisam desenhos de codificador e decodificador para previsão um-passo e multi-horizonte. Benidis et al. (2022) caracterizam modelos profundos como “*methods of choice*” em várias aplicações de séries temporais, especialmente quando há muitos dados, covariáveis e relações não lineares. Já Hewamalage, Bergmeir e Bandara (2021) revisam RNNs para previsão e alertam que não há “*no silver bullets*”. Esse conjunto de referências é importante para equilibrar a defesa: redes recorrentes e Seq2Seq são opções bem fundamentadas, mas sua superioridade depende do protocolo, do conjunto de dados e do objetivo.

No contexto deste TCC, essas referências funcionam como base transversal. Elas justificam a formulação supervisionada por janelas, a comparação entre estratégias direta, recursiva e codificador-decodificador, o uso de covariáveis conhecidas no futuro e a necessidade de comparar modelos neurais contra linhas de base tabulares fortes.

3.2 Modelos para Previsão de PM2.5

A previsão de PM2.5 tem sido estudada com modelos estatísticos, métodos tabulares e redes neurais. Uma revisão recente de arquiteturas de aprendizado profundo para previsão de PM2.5 destaca a “*lack of unified and standardized frameworks*” na área (ZHOU et al., 2024). Essa limitação é central para este TCC: antes de comparar arquiteturas, é necessário fixar estação, recorte temporal, tarefa, divisão temporal, atributos e critério de seleção.

Modelos clássicos e tabulares continuam relevantes. Trabalhos com SVM, florestas aleatórias e combinações estatísticas mostram que engenharia de atributos e otimização podem produzir resultados competitivos em qualidade do ar (SONG et al., 2018; GUO; YAO; ZHOU, 2021). No Brasil, Chaves et al. (2024) avaliaram Random Forest e LSTM para material particulado em Curitiba usando dados meteorológicos, fluxo veicular e sensores ópticos, reforçando a relevância de modelos tabulares e recorrentes em contextos urbanos nacionais.

Neste trabalho, essa linha é representada pelo XGBoost com saída múltipla. Ele não é tratado como modelo simples de descarte, mas como linha de base forte. Essa escolha é importante porque conclusões sobre aprendizado profundo só são defensáveis quando comparadas com linhas de base tabulares bem ajustadas sob o mesmo teste externo.

Também é necessário cuidado ao comparar diretamente valores de MAE, RMSE ou R2 entre trabalhos de PM2.5. Estudos recentes com desempenho aparentemente superior frequentemente usam horizontes mais curtos, agregação diária ou mensal, múltiplas estações, variáveis meteorológicas completas, copoluentes e até variáveis derivadas de reanálise, GNSS-PWV, sensoriamento remoto ou modelos físico-químicos (AYTURAN et al., 2020; SU et al., 2023; ZHANG et al., 2025; ZENG et al., 2026; CHEN et al., 2024; FENG et al., 2024). Essas condições não são equivalentes ao contrato causal de Sapo, no qual o modelo deve prever 24 horas horárias futuras usando 48 horas históricas e sem conhecer PM10, PTS ou meteorologia reais do futuro.

Assim, a literatura deve ser usada como referência de possibilidades e não como tabela de comparação direta. Trabalhos que reportam R2 próximo de 0,9 ou superior geralmente resolvem uma tarefa diferente ou recebem informação que o protocolo Sapo

não possui. A contribuição deste TCC é justamente explicitar esse limite: sob um contrato causal restrito e multi-horizonte, a meta realista não é reproduzir automaticamente o R2 de estudos com entradas meteorológicas e espaciais completas, mas medir o ganho que cada decisão produz dentro do mesmo teste externo.

3.3 Deep Learning para Qualidade do Ar

Modelos recorrentes são frequentes em previsão de PM2.5 porque conseguem explorar dependências temporais. Zhao et al. (2021) combinaram decomposição por modos empíricos e LSTM para previsão de PM2.5, enquanto Tran et al. (2023) investigaram previsão horária de PM2.5 com LSTM otimizada. Estudos como esses sustentam o uso de LSTM como arquitetura base para previsão de curto prazo.

Arquiteturas híbridas com atenção também aparecem na literatura. Li et al. (2020) propuseram uma abordagem CNN-LSTM com atenção para PM2.5 urbano, combinando extração de padrões e dependência temporal. Yang et al. (2023) avaliaram uma LSTM com mecanismo de atenção para concentração horária de PM2.5, comparando-a com modelos como ARIMA, autoencoder e LSTM padrão. Esses trabalhos motivam a avaliação de atenção no presente TCC, mas não implicam que atenção vencerá em qualquer contrato de dados.

O presente estudo se diferencia por comparar LSTM direta, LSTM recursiva, Seq2Seq básico, Seq2Seq atenção canônica, Seq2Seq atenção com L1 ponderada e XGBoost sob o mesmo teste temporal externo. A contribuição não é propor uma arquitetura inédita, mas medir de forma controlada como escolhas de arquitetura, variáveis causais e função de perda mudam erro médio, erro por horizonte e comportamento em picos.

3.4 Seq2Seq, Previsão Multi-Horizonte e Atenção

Modelos codificador-decodificador com atenção foram inicialmente popularizados em tarefas de tradução e transdução de sequências (SUTSKEVER; VINYALS; LE, 2014; BAH-DANAU; CHO; BENGIO, 2014; LUONG; PHAM; MANNING, 2015). A ideia se transfere naturalmente para séries temporais quando a entrada é uma sequência histórica e a saída

é uma sequência futura. Nesse cenário, a arquitetura Seq2Seq não é escolhida por ser uma novidade isolada, mas porque a tarefa 48 para 24 horas tem estrutura sequência-para-sequência.

Há trabalhos de previsão que reforçam esse enquadramento. Wen et al. (2017) propõem um preditor recorrente multi-horizonte e explicitamente exploram a natureza temporal de “*Sequence-to-Sequence Neural Networks*”. Salinas et al. (2020) usam uma rede recorrente autoregressiva para previsão probabilística em múltiplas séries relacionadas, mostrando a força de decodificadores recorrentes em previsão. Lim et al. (2021) propõem o Temporal Fusion Transformer para previsão multi-horizonte com entradas estáticas, entradas observadas no passado e entradas futuras conhecidas. Embora o TFT use outra família arquitetural, ele reforça a importância de distinguir covariáveis futuras conhecidas de variáveis observáveis apenas no passado.

Arquiteturas baseadas em Transformer também são uma linha moderna importante em séries temporais. Além do TFT, trabalhos como Informer, Autoformer e PatchTST propõem adaptações para previsão de sequências longas e previsão multi-horizonte (ZHOU et al., 2021; WU et al., 2021; NIE et al., 2023). Esses estudos justificam reconhecer Transformers como alternativa relevante ao desenho recorrente. Ao mesmo tempo, a literatura recente também mostra que a superioridade de Transformers em previsão não é automática: Zeng et al. (2023) questionam sua efetividade em algumas referências de longo horizonte e mostram que linhas de base lineares podem ser competitivas. Portanto, neste TCC, a escolha por LSTM, Seq2Seq e XGBoost é tratada como recorte experimental controlado, não como negação da relevância de arquiteturas mais recentes.

Extensões específicas para séries multivariadas também foram estudadas. DARNN, por exemplo, usa atenção de entrada para selecionar variáveis relevantes e atenção temporal para selecionar instantes relevantes da sequência (QIN et al., 2017). Essa linha de pesquisa é relevante para dados ambientais porque diferentes variáveis podem ter importância distinta ao longo do tempo.

Assim, a defesa do Seq2Seq neste TCC deve ser precisa: a literatura justifica incluí-lo como arquitetura natural e competitiva para previsão multi-horizonte, especial-

mente quando há decodificador com covariáveis futuras conhecidas; ela não garante vitória sobre LSTM direta ou XGBoost em uma estação específica. Por isso, o resultado final trata a atenção empiricamente, incluindo o caso em que pesos de atenção ficam quase uniformes ou quando o ganho aparece apenas em regimes de pico/cauda.

3.5 Dados Faltantes em Séries Ambientais

Lacunas são comuns em monitoramento ambiental e podem distorcer treinamento e avaliação. A literatura de dados faltantes mostra que imputação não deve ser confundida com observação real (RUBIN, 1976). Métodos como MICE e MissForest estimam valores faltantes usando relações multivariadas (BUUREN; GROOTHUIS-OUDSHOORN, 2011; STEKHOVEN; BUHLMANN, 2012), enquanto abordagens recentes baseadas em atenção, como SAITS, exploram dependências temporais e entre variáveis (DU et al., 2023).

O protocolo final deste trabalho adota uma posição conservadora: usa imputação linear para manter a série operacionalmente completa, mas preserva uma máscara do alvo observado para impedir que valores imputados de PM_{2.5} entrem como verdade na função de perda e nas métricas. Assim, a imputação resolve a continuidade das janelas, enquanto a avaliação permanece vinculada a medições observadas.

3.6 Protocolos de Avaliação Temporal

Comparações em séries temporais são sensíveis à divisão temporal e ao orçamento experimental. Tashman (2000) discutem testes fora da amostra como base para avaliação de previsão, e Bergmeir e Benitez (2012) analisam cuidados no uso de validação cruzada em séries temporais. Em qualidade do ar, a revisão de Zhou et al. (2024) também aponta a necessidade de padronizar conjunto de dados, método e experimento para tornar resultados mais comparáveis.

Esse problema aparece diretamente no desenvolvimento deste TCC. Resultados antigos, obtidos sem HPO ou com outro conjunto de variáveis, não são comparáveis como se fossem parte da mesma tabela final. Por isso, o relatório final separa a comparação histórica dos resultados consolidados no protocolo final, com teste cronológico externo

70/15/15, HPO *walk-forward*, PM10 causal e tarefa 48 para 24 horas.

3.7 Posicionamento deste TCC

À luz dos trabalhos relacionados, este TCC ocupa uma posição experimental e metodológica. Ele não afirma que uma arquitetura de atenção é universalmente superior, nem que um modelo tabular deve ser descartado. Em vez disso, fixa um protocolo rastreável para a estação Sapo e compara famílias de modelos sob o mesmo contrato causal de entrada.

A diferenciação principal está em quatro pontos. Primeiro, a tarefa é explicitamente de múltiplos passos e horária, com entrada de 48 horas e horizonte de 24 horas. Segundo, a divisão externa é cronológica, a HPO usa validação temporal interna e os artefatos usados nos resultados são rastreáveis. Terceiro, o alvo imputado é excluído da função de perda e das métricas quando a máscara de observado está disponível. Quarto, a análise distingue erro médio global de comportamento por horizonte, suavização visual e resposta a eventos de maior concentração.

Com isso, o trabalho complementa estudos que propõem arquiteturas específicas para PM2.5 ao mostrar que, em um contrato de dados real e fixo, a conclusão depende tanto do protocolo experimental quanto da arquitetura escolhida. Esse posicionamento fortalece a defesa porque evita uma promessa excessiva de estado da arte universal e concentra a contribuição na comparação controlada e reproduzível.

Tabela 3.1: Diferenças de contrato em trabalhos recentes de PM2.5 em relação ao protocolo Sapo.

Grupo de evidência	Exemplos na literatura	Implicação para este TCC
Horizonte mais curto ou diferente	Previsões de curto prazo com RNN/LSTM/GRU (AYTURAN et al., 2020); previsão de 1 hora com RF-LSTM e GNSS-PWV (ZHANG et al., 2025); dados de 15 minutos em LSTM urbano (BALARAMAN et al., 2022); previsão mensal em Dezhou (HE; GUO, 2024).	Métricas de tarefas um-passo, diárias ou mensais tendem a ser menos severas que uma tarefa horária multi-horizonte 48 para 24. Portanto, R2 alto nesses cenários não é diretamente comparável ao R2 de Sapo.
Variáveis exógenas mais ricas	CNN-LSTM com poluentes, ERA5 e PWV em dez cidades (SU et al., 2023); Transformer-LSTM com copoluentes e meteorologia (ZENG et al., 2026); RF-LSTM com PWV, PM10, O3, pressão, temperatura e vento (ZHANG et al., 2025).	Esses trabalhos usam fatores que explicam dispersão, estabilidade atmosférica e formação de PM2.5. Em Sapo, essas variáveis estão ausentes ou esparsas, e não podem ser usadas como futuro real sem vazamento.
Informação espacial explícita	CNN-LSTM e AC-LSTM com correlação entre estações e meteorologia (LI; HUA; WU, 2020; LI et al., 2020; BAI et al., 2024); L-STCN e modelos espaço-temporais (CHEN et al., 2024); ST-GCN com alta resolução espacial (FENG et al., 2024).	Parte da variância horária de PM2.5 decorre de transporte, fontes locais e condições de mistura. Um modelo de uma única estação com PM2.5/PM10 não observa diretamente esse campo espacial.
Arquiteturas híbridas e HPO específico	CNN-LSTM, GRU-LR-TCN, Transformer-LSTM, PSO-Transformer-LSTM e comparações com modelos tradicionais (HU et al., 2024; QAMAR; MUNIR; WASEEM, 2025; LIU; FANG; HU, 2025).	A arquitetura contribui, mas não substitui variáveis explicativas. No protocolo Sapo, ablações e testes oracle indicam que o limite principal está no contrato informacional, não apenas no desenho neural.

4 Materiais e Métodos

Este capítulo descreve o protocolo experimental utilizado na comparação dos modelos. A metodologia foi definida para preservar a ordem temporal dos dados, evitar vazamento de informação futura e permitir comparação direta entre arquiteturas sob o mesmo contrato de entrada, saída e avaliação.

4.1 Fonte de Dados e Escopo

O estudo utiliza medições horárias da estação Sapo, pertencente ao conjunto CMD usado neste trabalho. A variável-alvo é a concentração de PM2.5, e o principal poluente auxiliar mantido no contrato final é PM10. Embora a fonte bruta contenha outras variáveis meteorológicas e gases, essas colunas foram removidas do contrato principal porque apresentavam alta esparsidade na estação Sapo e prejudicavam a coerência do conjunto de dados final.

O conjunto consolidado usado nos resultados principais contém 34.991 registros horários, de 2017-01-04 00:30:00 a 2020-12-31 22:30:00. Esse período corresponde ao recorte efetivamente disponível após preparação, criação das variáveis substitutas causais de PM10 e remoção das primeiras janelas necessárias para a formulação supervisionada.

Tabela 4.1: Resumo do contrato experimental principal.

Item	Definição
Estação	Sapo / CMD
Poluente-alvo	PM2.5 horário
Período do artefato	2017-01-04 00:30:00 a 2020-12-31 22:30:00
Número de linhas	34.991
Tarefa	48 horas passadas para prever as próximas 24 horas
Divisão externa	Cronológica por proporção 70/15/15
Seleção de hiperparâmetros	<i>Walk-forward</i> temporal nos 85% anteriores ao teste
Imputação	Linear no contrato final, com máscaras de valores originalmente ausentes
Variáveis principais	PM2.5, PM10, indicadores de ausência, tempo/Fourier e substitutos causais de PM10
Avaliação final	Teste externo, sem embaralhamento temporal

4.2 Análise Exploratória e Escolha da Estação

A escolha da estação Sapo foi precedida por uma análise exploratória comparativa sobre 38 estações/usinas com PM2.5. Essa etapa combinou critérios de cobertura do alvo, continuidade temporal, presença de PM10 pareado, frequência de eventos altos e equilíbrio das partições cronológicas. O objetivo dessa triagem não foi escolher uma estação apenas por conveniência, mas selecionar um recorte com volume suficiente, variável auxiliar causalmente útil e incidência mínima de eventos de cauda para sustentar a comparação entre modelos.

Nesse diagnóstico, Sapo apareceu como uma das candidatas mais fortes: ficou em segundo lugar na classificação por PM2.5 puro e também em segundo lugar na classificação que inclui contexto de PM10. A estação Rio Doce/Estação Principal obteve pontuação ligeiramente maior, mas teve menor frequência de eventos $PM2.5 \geq 35$ no diagnóstico preliminar (0,19%, contra 1,16% em Sapo) e não pertence ao mesmo foco CMD adotado neste trabalho. Assim, Sapo foi mantida como estação principal por combinar aderência ao escopo, cobertura de PM2.5 de 83,47% no diagnóstico comparativo, cobertura pareada PM10 de 74,27% e correlação absoluta PM10–PM2.5 de 0,58.

A decisão também foi reforçada por testes preliminares de modelagem. Em uma comparação exploratória com a mesma tarefa 48 para 24 horas e um Seq2Seq com atenção, Sapo obteve o menor MAE entre as estações testadas: 3,03 em Sapo, contra 3,13 em Barra Longa/Centro, 3,96 em Aeroporto CMD e 5,17 em Ibirité/Cascata. Esses números não substituem a comparação final, pois pertencem a uma etapa anterior e menos refinada do projeto, mas mostram que a escolha de Sapo não se apoiou apenas em cobertura de dados. Ela também foi a estação com melhor desempenho inicial entre os recortes avaliados. Testes auxiliares posteriores em Rio Doce e Barra Longa foram usados para investigar portabilidade do protocolo e comportamento do PM10 causal, mas não substituem Sapo como eixo principal deste TCC.

Após a escolha da estação, a análise exploratória foi refeita sobre o conjunto final usado na comparação principal. A Figura 4.2 mostra que a série não é integralmente contínua: há meses com cobertura elevada, mas também lacunas longas, principalmente na validação. A maior lacuna original de PM2.5 ocorre de 2019-12-11 13:30 a 2020-01-28




Figura 4.1: Classificação preliminar das estações por previsibilidade de PM2.5 com contexto de PM10.

18:30, com 48,25 dias, seguida por lacunas de 14,38 dias e 10,83 dias no treino. Por outro lado, ainda existem trechos observados contínuos suficientes para análise de janelas; os maiores blocos contínuos identificados têm cerca de 8,54 dias no treino e 8,13 dias no teste. Esse padrão fundamenta duas decisões metodológicas: manter a série em grade horária regular por interpolação e preservar máscaras de ausência para que valores originalmente imputados não sejam tratados como verdade observada na função de perda nem nas métricas.

A Tabela 4.2 resume a cobertura e a distribuição observada por partição. O teste apresenta a maior cobertura observada de PM2.5 (93,37%), enquanto a validação concentra a maior proporção de ausências (31,73%). A distribuição também mostra que os eventos altos são raros em todas as partições: 1,57% dos pontos observados no treino, 1,45% na validação e 0,96% no teste ficam em $PM2.5 \geq 35$. Essa raridade justifica a análise de cauda no Capítulo 5, pois o MAE global sozinho tende a privilegiar o regime mais frequente e pode esconder suavização em eventos de maior concentração.

Tabela 4.2: Resumo exploratório do artefato Sapo por partição.

Partição	Cob. PM2.5	Cob. PM10	Mediana PM2.5	p95	p99	PM2.5 $\geq$ 35
Treino	80,70%	81,33%	9,00	24,00	40,00	1,57%
Validação	68,27%	64,50%	12,00	25,00	37,00	1,45%
Teste	93,37%	92,11%	12,00	24,00	34,00	0,96%




Figura 4.2: Cobertura mensal e maiores lacunas originais de PM2.5 no artefato Sapo.





Figura 4.3: Distribuição observada de PM2.5 e frequência de eventos altos por partição.

4.2.1 Padrões Temporais de PM2.5 e PM10

Além da cobertura e da distribuição marginal, o artefato Sapo foi analisado quanto a tendência, persistência e sazonalidade. Essa análise usa apenas pontos originalmente observados nas métricas agregadas, respeitando as máscaras `PM2.5_miss` e `PM10_miss`. A Figura 4.4 resume visualmente a decomposição descritiva do PM2.5: há uma componente lenta de tendência-ciclo, um perfil horário repetitivo e resíduos com picos abruptos.

A Tabela 4.3 resume os principais sinais temporais de PM2.5 e PM10. Para PM2.5, a persistência de curto prazo é alta, com autocorrelação de 0,813 em 1 hora, e há repetição diária relevante, com autocorrelação de 0,681 em 24 horas. O sinal semanal



Decomposição aditiva descritiva: $PM2.5 = \text{tendência-ciclo} + \text{sazonalidade horária} + \text{resíduo}$. Os componentes não foram usados como entrada direta dos modelos finais.

Figura 4.4: Série temporal de PM2.5 e decomposição descritiva no artefato Sapo. Elaboração própria com base na decomposição aditiva discutida por Hyndman e Athanasopoulos (2021).

existe, mas é mais fraco, com autocorrelação de 0,461 em 168 horas e diferença média entre dias da semana de apenas 0,70. O perfil horário é mais claro: as menores médias de PM2.5 aparecem entre a madrugada e o início da tarde, com mínimo médio próximo de 10,29 às 13h, enquanto o fim da tarde e a noite concentram maiores valores, com máximo médio próximo de 14,77 às 18h.

O PM10 apresenta comportamento compatível com o PM2.5, mas com amplitude horária maior. Suas menores médias ocorrem por volta de 4h, com valor médio próximo de 20,95, e as maiores médias ocorrem por volta de 20h, com valor médio próximo de 32,09. A correlação de Pearson entre PM2.5 e PM10 observados no mesmo horário foi 0,597, e a correlação de Spearman foi 0,421. Portanto, PM10 é uma variável auxiliar informativa, mas não determina completamente a variação horária de PM2.5.

Também há um padrão mensal importante: PM2.5 e PM10 sobem em setembro e outubro, com média de PM2.5 próxima de 17,97 em outubro e p95 de 44 nesse mês. No

Tabela 4.3: Padrões temporais observados de PM2.5 e PM10 no artefato Sapo.

Diagnóstico	PM2.5	PM10	Leitura
Autocorrelação 1h	0,813	0,734	Forte persistência de curto prazo nos dois poluentes.
Autocorrelação 24h	0,681	0,564	Repetição diária relevante, justificando defasagens e substitutos causais baseados em 24h.
Autocorrelação 168h	0,461	0,360	Sinal semanal mais fraco que o diário.
Amplitude média por hora	4,48	11,14	Ciclo horário claro, mais intenso em PM10.
Amplitude média por dia da semana	0,70	3,68	Variação semanal pequena diante da variabilidade total.
Amplitude média por mês	8,52	12,95	Regime sazonal/mensal forte, com elevação em setembro e outubro.

entanto, a interpretação como ciclo anual regular deve ser cautelosa, pois o artefato cobre apenas quatro anos, possui lacunas e apresenta mudanças de regime entre anos. A autocorrelação anual aproximada de PM2.5 foi baixa, cerca de 0,038, indicando que a repetição anual é menos estável que a persistência horária e diária. Assim, no protocolo final, os termos temporais e de Fourier são úteis para fornecer informação cíclica ao modelo, mas os picos e resíduos continuam dependendo de fatores não observados diretamente, como meteorologia local, mistura atmosférica, transporte espacial e fontes de emissão.

4.3 Formulação da Tarefa

A tarefa de previsão é de múltiplos passos: para cada janela válida, os modelos recebem as 48 horas anteriores e produzem uma previsão para as 24 horas seguintes. Formalmente, para um instante inicial t , a entrada contém observações de $t - 47$ até t , e a saída corresponde aos horizontes $t + 1$ até $t + 24$. Essa formulação foi mantida para todos os modelos da comparação principal e está resumida na Figura 4.5.



Figura 4.5: Formulação da tarefa de múltiplos passos do protocolo Sapo.

A divisão externa é cronológica e usa 70% dos horários para treino final, 15% para validação de treinamento e 15% para teste final. A Tabela 4.4 apresenta os limites reais do artefato final, e a Figura 4.6 mostra a mesma divisão na linha do tempo. O conjunto de teste contém os horários mais recentes e só é usado para avaliação final.

Tabela 4.4: Divisão cronológica externa do conjunto final de Sapo.

Partição	Proporção	Timestamps	Intervalo
Treino	70%	24.495	2017-01-04 00:30 a 2019-10-21 14:30
Validação	15%	5.248	2019-10-21 15:30 a 2020-05-27 06:30
Teste	15%	5.248	2020-05-27 07:30 a 2020-12-31 22:30

Neste relatório, portanto, a expressão 70/15/15 se refere à divisão externa de avaliação. A seleção de hiperparâmetros não usa o teste final: ela é feita por *walk-forward* dentro dos 85% anteriores ao teste. Em seguida, os modelos selecionados são treinados no protocolo final usando o trecho de treino e a validação de treinamento para parada antecipada e escolha de ponto de controle. A validação intermediária faz parte do desenvolvimento do modelo; o único conjunto tratado como avaliação independente é o teste final.




Figura 4.6: Linha temporal da divisão cronológica externa usada no artefato Sapo.

4.4 Pré-processamento

O pré-processamento foi desenhado para reduzir vazamento temporal. A imputação é ajustada sobre o trecho de treino e aplicada ao restante do período respeitando a separação temporal. No contrato final, usa-se interpolação linear no bloco de treino; para o bloco posterior ao fim do treino, a transformação não usa âncoras futuras e propaga o último estado imputado disponível. Para cada variável imputada, é mantido um indicador `_miss`, que informa se o valor original estava ausente.

O alvo PM2.5 também possui uma máscara de observação. Quando essa máscara está disponível, pontos do alvo originalmente imputados são excluídos da função de perda e das métricas observadas. Assim, o modelo pode receber uma série regularizada para formar janelas, mas não é recompensado por prever como “verdade” um valor que foi produzido pelo próprio pré-processamento.

A normalização é calculada com estatísticas do conjunto de treino. No treinamento dos modelos neurais, médias e desvios são computados por estação e aplicados às janelas de treino, validação e teste. Essa decisão evita que informação agregada dos períodos de validação e teste entre no ajuste de escala do modelo.

4.5 Engenharia de Atributos

O conjunto final de atributos foi mantido enxuto. O codificador recebe PM2.5, PM10, indicadores de ausência e atributos temporais. O decodificador dos modelos que aceitam entradas futuras recebe apenas variáveis conhecidas causalmente no momento da previsão: termos temporais/Fourier e substitutos derivados de PM10. A Tabela 4.5 resume os

grupos de variáveis.

Tabela 4.5: Variáveis do protocolo final.

Grupo	Variáveis	Uso
Alvo e histórico	PM2.5	Entrada histórica e alvo da previsão
Poluente auxiliar	PM10	Entrada histórica no codificador
Ausência	PM2.5_miss, PM10_miss	Indicar valores originalmente ausentes
Tempo	hour, day_of_week, month	Sazonalidade discreta
Fourier	termos seno/cosseno de 6h, 12h, 24h, 168h e 8760h	Sazonalidade cíclica
Substituto PM10	PM10_proxy_exante	PM10 do mesmo horário no dia anterior, isto é, PM10(t-24)
Tendência PM10	PM10_trend_exante	Diferença causal PM10(t-24) - PM10(t-27)

O uso de PM10 no decodificador não assume conhecimento futuro de PM10 observado. O substituto causal usa o valor defasado em 24 horas, e a tendência causal usa a diferença entre valores também defasados. Portanto, ambas podem ser calculadas no instante de emissão da previsão. Variáveis meteorológicas e gases muito esparsos foram excluídos do contrato principal; sua reintrodução deve ser tratada apenas como nova ablação, não como parte da comparação final.

4.6 Modelos Avaliados

Foram comparadas cinco variantes neurais e uma linha de base tabular. A Tabela 4.6 resume o papel de cada modelo no desenho experimental.

Tabela 4.6: Modelos avaliados na comparação principal.

Modelo	Descrição	Papel na comparação
LSTM recursiva	Prevê passo a passo, realimentando a trajetória prevista	Linha de base sequencial recursiva
LSTM direta	Produz os 24 horizontes de uma vez	Modelo sequencial direto
Seq2Seq básico	Codificador-decodificador recorrente sem atenção explícita	Linha de base codificador-decodificador
Seq2Seq atenção canônica	Codificador-decodificador com mecanismo de atenção e perda Huber	Variante de referência para análise de atenção
Seq2Seq atenção com L1 ponderada	Codificador-decodificador com atenção e perda ponderada para regimes altos	Variante final de Seq2Seq
XGBoost com saída múltipla	Árvores com saída multi-horizonte	Linha de base tabular forte

A escolha dos modelos também delimita o escopo do estudo. Transformers temporais, como TFT, Informer, Autoformer e PatchTST, são alternativas modernas para previsão multi-horizonte (LIM et al., 2021; ZHOU et al., 2021; WU et al., 2021; NIE et al., 2023). Eles não foram incluídos na comparação final porque uma comparação justa exigiria nova família de arquitetura, espaço próprio de hiperparâmetros, orçamento adicional de HPO, avaliação com múltiplas sementes e decisões específicas de regularização para o tamanho e a qualidade do conjunto de dados Sapo. Além disso, a literatura não autoriza assumir que Transformers vencem automaticamente em séries temporais; Zeng

et al. (2023) mostram que linhas de base simples podem superar Transformers em alguns cenários de previsão. Assim, o recorte deste TCC é comparar famílias recorrentes e tabulares sob um contrato causal rastreável, deixando Transformers como extensão natural para trabalhos futuros.

A comparação com XGBoost exige uma ressalva metodológica. A linha de base tabular usa o mesmo contrato causal de entrada e é avaliada no mesmo teste externo, mas seu treinamento com saída múltipla exige janelas com horizonte completo observado. Nos modelos neurais, a máscara de alvo observado permite ignorar pontos imputados da função de perda e das métricas. Assim, a avaliação de teste é comparável, mas o mecanismo de treino não é perfeitamente simétrico.

Além da comparação principal, foram executados experimentos diagnósticos com o Seq2Seq atenção para investigar limites informacionais do problema. O primeiro é o *oracle future auxiliary*: no decodificador, o modelo recebe PM10 e PTS reais do próprio horizonte futuro. Esse cenário não é operacional, pois usa informação indisponível no instante de previsão, mas mede quanto desempenho poderia ser recuperado caso variáveis auxiliares futuras relevantes fossem conhecidas. O segundo é o Seq2Seq multi-alvo, no qual a rede continua prevendo PM2.5 como alvo principal, mas recebe uma cabeça auxiliar para prever PM10 e PTS futuros durante o treinamento. Esse teste avalia se aprender variáveis correlacionadas em conjunto ajuda a representação interna sem introduzir vazamento no teste operacional.

Esses dois experimentos não substituem o protocolo final nem entram como candidatos a vencedor, porque usam contratos diferentes do contrato causal principal. Eles são apresentados nos resultados como análise de limite: o *oracle* mostra o ganho máximo associado a variáveis futuras observadas, enquanto o multi-alvo testa se a própria arquitetura consegue aproximar esse ganho apenas aprendendo as auxiliares.

4.7 Treinamento e Busca de Hiperparâmetros

O resultado principal usa busca de hiperparâmetros com validação temporal *walk-forward* no bloco de desenvolvimento anterior ao teste. A busca é controlada e suficiente para comparação experimental de TCC, mas não deve ser interpretada como busca exaustiva

nem garantia de ótimo global. Para os modelos neurais principais, foram usadas 24 tentativas, três partições temporais por janela expansiva, até 18 épocas por tentativa e treinamento final de até 36 épocas para LSTM direta e LSTM recursiva. Para o Seq2Seq atenção com L1 ponderada, o treinamento final manteve orçamento de até 48 épocas. O XGBoost foi submetido ao mesmo desenho *walk-forward*, mas, por custo computacional das tentativas mais longas, o resultado consolidado usou quatro tentativas completas.

Nas redes neurais, cada tentativa reiniciou o modelo em cada partição e agregou a métrica de validação ao fim das partições. O estudo do Optuna usou o amostrador padrão `TPESampler` e o `HyperbandPruner`, com `min_resource=1`, `max_resource=18` e fator de redução 3. Assim, tentativas pouco promissoras podiam ser interrompidas antes de consumir todo o orçamento de épocas. Essa escolha segue a recomendação da documentação do Optuna para a combinação entre `TPESampler` e `HyperbandPruner` (Optuna Contributors, 2026a; Optuna Contributors, 2026b). Para o XGBoost, a busca minimizou o MAE médio nas partições, com parada antecipada (*early stopping*) nativa do XGBoost e `MedianPruner` (Optuna Contributors, 2026c). A Tabela 4.7 organiza o espaço de busca por grupo de hiperparâmetros; a Tabela 4.8 apresenta a configuração selecionada.

Nos modelos neurais, a taxa de aprendizado apresentada nas tabelas é a taxa nominal $\eta_{\max}$ escolhida pela HPO. As execuções finais usaram AdamW com agenda ativa por época: três épocas de aquecimento linear, saindo de $10^{-5}\eta_{\max}$ até $\eta_{\max}$, seguidas de decaimento cosseno até $0,01\eta_{\max}$ no fim do orçamento. A agenda é reiniciada em cada partição da HPO e em cada treinamento final. A validação ao fim das épocas monitora MAE para poda, parada antecipada e escolha do melhor *checkpoint*, mas não recalcula a taxa de aprendizado com base no valor da métrica.

Tabela 4.7: Espaço de busca de hiperparâmetros na comparação principal.

Grupo	Hiperparâmetro	Valores avaliados
Redes neurais	Taxa nominal de aprendizado	0,0003; 0,0005; 0,0008; 0,0012; 0,0018; 0,0025; 0,0035; 0,005; 0,007
Redes neurais	Decaimento de pesos	0; 10^{-7} ; 5×10^{-7} ; 10^{-6} ; 5×10^{-6} ; 10^{-5} ; 5×10^{-5} ; 10^{-4}
Redes neurais	Taxa de <i>dropout</i>	0,00; 0,05; 0,10; 0,15; 0,20; 0,25; 0,30
Redes neurais	Profundidade e perda	número de camadas 1; 2; 3; δ da Huber em 0,5; 0,75; 1,0; 1,5; 2,0
LSTM direta	Arquitetura	dimensão oculta 96; 128; 192; 256; 320; agregação por último estado, média ou atenção
LSTM recursiva	Arquitetura	dimensão oculta 96; 128; 192; 256; 320
Seq2Seq atenção + L1 ponderada	Arquitetura e perda	codificador/decodificador 64; 96; 128; 160; atenção de entrada 64; 96; 128; 160; representação de horizonte 8; 16; 24; 32; pesos moderado/alto e fator de subestimação 160; 240; 320; 480 árvores; profundidade máxima 2 a 7; <code>max_bin</code> 64; 128; 256
XGBoost com saída múltipla	Árvores e profundidade	taxa de aprendizado logarítmica entre 0,015 e 0,12; <i>subsample</i> e <i>colsample</i> entre 0,60 e 1,0; λ , α , γ , peso mínimo do filho (<i>min child weight</i>); parada antecipada (<i>early stopping</i>) de 10, 15 ou 25 rodadas
XGBoost com saída múltipla	Regularização, amostragem e parada	

Tabela 4.8: Hiperparâmetros selecionados pela busca na comparação principal.

Modelo	Arquitetura selecionada	Treinamento e regularização
LSTM direta	dimensão oculta 256; 3 camadas; agregação por média	taxa nominal de aprendizado 0,007; decaimento de pesos 5×10^{-5} ; <i>dropout</i> 0,20; δ da Huber 2,0
LSTM recursiva	dimensão oculta 128; 2 camadas	taxa nominal de aprendizado 0,0035; decaimento de pesos 0; <i>dropout</i> 0,20; δ da Huber 1,0
Seq2Seq atenção + L1 ponderada	codificador 96; decodificador 96; 1 camada; atenção de entrada 96; representação de horizonte 24	taxa nominal de aprendizado 0,007; decaimento de pesos 10^{-6} ; <i>dropout</i> 0,30; pesos 1,20/1,10; fator de subestimação 1,50
XGBoost com saída múltipla	480 árvores; profundidade máxima 2; <code>max_bin</code> =64	taxa de aprendizado 0,02563; <i>subsample</i> =0,7611; <i>colsample</i> =0,9073; $\lambda = 7,7542$; parada antecipada=10 rodadas

A formulação final do Seq2Seq priorizou a variante com atenção de entrada e perda `weighted_l1`. Essa perda pondera regimes de concentração e tipos de erro, alterando o objetivo de treinamento para reduzir parte da suavização e melhorar o comportamento em concentrações mais altas. Essa variante foi avaliada no protocolo consolidado com *walk-forward* e múltiplas sementes, enquanto defasagens explícitas e combinações de predições permaneceram como análises auxiliares.

As variantes finais de Seq2Seq priorizaram um decodificador semidireto com horizonte explícito e linha de base residual sazonal, reduzindo a dependência de realimentação autoregressiva pura. Ainda assim, a avaliação de agendas de *teacher forcing* foi incluída porque trabalhos recentes em previsão, como Teutsch e Mäder (2022), indicam que currículos crescentes de *teacher forcing* podem melhorar previsões de múltiplos passos em séries temporais contínuas. No relatório, portanto, *teacher forcing* e *scheduled sampling* são tratados como técnicas avaliadas em ablações auxiliares fundamentadas, não como eixo central do resultado final em Sapo. Essa distinção evita atribuir ao *scheduled sampling* um ganho que, nos experimentos consolidados, esteve mais associado ao contrato de dados, ao uso causal de PM10, à seleção por validação e à função de perda.

4.8 Métricas de Avaliação

A avaliação final utiliza métricas no teste externo. As métricas globais principais são MAE, RMSE, MAPE e R2. Também são reportadas métricas por horizonte, especialmente nos horizontes 1, 6, 12 e 24, para observar degradação ao longo da previsão. Como os picos são raros e importantes em qualidade do ar, a análise também considera métricas de cauda, como erro em eventos acima de 35, p99 previsto, razão entre desvio-padrão previsto e observado, viés médio e taxa de subestimação.

A interpretação dos resultados combina métricas agregadas e inspeção visual das séries previstas. Essa combinação é necessária porque modelos que vencem em erro médio podem produzir previsões mais suaves, enquanto variantes voltadas a picos podem preservar mais amplitude ao custo de pequeno aumento no MAE global.

4.9 Reprodutibilidade

A reprodutibilidade foi tratada por meio de scripts determinísticos de geração de figuras, tabelas e diagnósticos, mantendo a separação entre treino, validação e teste. Os experimentos principais foram executados com identificadores de execução, sementes registradas quando aplicável, configuração explícita de HPO e exportação de métricas em formato tabular. No corpo do TCC, os valores reportados são apresentados diretamente nas tabelas e nas figuras; os caminhos técnicos e hashes dos arquivos ficam preservados como material de controle do projeto, sem substituir a descrição metodológica.

5 Resultados e Discussão

Este capítulo apresenta os resultados do protocolo Sapo descrito no Capítulo 4. A discussão separa quatro níveis de evidência: a comparação principal com HPO e validação temporal *walk-forward*, a estabilidade com múltiplas sementes dos modelos selecionados, as linhas de base ingênuas e as ablações usadas para interpretar decisões de modelagem.

5.1 Caracterização da Comparação Principal

A comparação principal usa a estação Sapo, tarefa 48 -> 24, divisão cronológica externa 70/15/15, HPO *walk-forward* no bloco de desenvolvimento e avaliação no teste externo. O conjunto de dados final contém 34.991 registros horários. No conjunto consolidado, a proporção de valores originalmente ausentes é de aproximadamente 19,26% para PM2.5 e 19,58% para PM10. Esses percentuais reforçam a importância de manter indicadores de ausência e de excluir o alvo imputado da função de perda e das métricas observadas.

Os eventos altos são raros no teste. Na avaliação final, pontos acima de 35 representam cerca de 0,81% dos pontos observados, e pontos acima de 50 representam cerca de 0,02%. Portanto, o MAE global é dominado por regimes baixos e moderados. A análise de cauda é apresentada separadamente para evitar que o melhor erro médio seja confundido com melhor resposta a picos.

5.2 Resultado Principal com HPO *Walk-Forward*

A Tabela 5.1 apresenta os resultados principais no teste externo após seleção de hiperparâmetros por validação temporal *walk-forward* com três partições dentro dos 85% anteriores ao teste. O teste final permaneceu reservado e não foi usado na seleção. O melhor desempenho global na semente canônica foi obtido pela LSTM direta, que apresentou menor MAE, menor RMSE e maior R2 entre os modelos individuais com resultados consolidados.

Tabela 5.1: Resultado principal no protocolo final de Sapo com HPO *walk-forward*.

Modelo	MAE	RMSE	MAPE	R2	H1 MAE	H24 MAE
LSTM direta	2,7713	3,8346	23,01	0,5154	2,6725	2,8670
Seq2Seq atenção + L1 ponderada	2,8658	3,9641	23,90	0,4821	2,7631	2,9695
XGBoost com saída múltipla	2,8786	3,9793	23,80	0,4781	2,5618	3,0273
LSTM recursiva	2,8876	3,8380	24,39	0,5146	2,7380	3,1492
Seq2Seq básico	N/A	N/A	N/A	N/A	N/A	N/A
Seq2Seq atenção canônica	N/A	N/A	N/A	N/A	N/A	N/A

O resultado reforça a conclusão obtida com o protocolo mais forte: a LSTM direta permanece vencedora por erro médio após ampliar o espaço de HPO e usar seleção por *walk-forward*. O XGBoost continua sendo uma linha de base tabular forte e manteve o menor erro no primeiro horizonte, mas a busca *walk-forward* executada para ele foi limitada a quatro tentativas completas por custo computacional; portanto, a conclusão tabular deve ser lida como conservadora, não como esgotamento do espaço de árvores.

Entre os modelos neurais com métricas consolidadas, a LSTM direta superou a LSTM recursiva e o Seq2Seq atenção com L1 ponderada no MAE global. A abordagem recursiva apresentou RMSE e R2 muito próximos aos da LSTM direta, mas teve pior MAE e maior erro no horizonte final. O Seq2Seq atenção com L1 ponderada ficou ligeiramente à frente do XGBoost em MAE, mas abaixo da LSTM direta e com RMSE/R2 inferiores.

A Figura 5.1 complementa a tabela principal com a dinâmica de treinamento. O painel (a) mostra que o melhor ponto de controle dos modelos neurais não correspondeu à última época executada: a LSTM direta teve melhor *checkpoint* na época 15 e parou na época 23; a LSTM recursiva teve melhor *checkpoint* na época 14 e parou na época 22; e o Seq2Seq atenção com L1 ponderada teve melhor *checkpoint* na época 18 e parou na época 26. Esse padrão é compatível com a paciência de oito épocas usada na parada antecipada. O painel (b) mostra a agenda de taxa de aprendizado: as três primeiras épocas fazem aquecimento linear e, depois disso, a taxa decai suavemente por cosseno. A perda de validação também foi registrada nos artefatos, mas não é usada como comparação visual principal porque os modelos neurais finais não otimizam exatamente a mesma função de perda.




Figura 5.1: Evolução do MAE de validação e da taxa de aprendizado nos modelos neurais com métricas consolidadas. As estrelas indicam o melhor ponto de controle selecionado por validação; os círculos indicam a última época registrada antes da parada antecipada.

5.3 Estabilidade com Múltiplas Sementes

A Tabela 5.2 resume a sensibilidade à semente aleatória para os modelos selecionados pelo HPO *walk-forward*. A média inclui a semente canônica 42 e três sementes adicionais: 7, 21 e 123.

Tabela 5.2: Estabilidade com múltiplas sementes dos modelos selecionados.

Modelo	MAE médio	Desvio MAE	RMSE médio	R2 médio	MBE médio
LSTM direta	2,8055	0,0540	3,8611	0,5086	0,0435
LSTM recursiva	2,8425	0,0426	3,8006	0,5239	0,4505
Seq2Seq atenção + L1 ponderada	2,8646	0,0201	3,9617	0,4827	0,0567
XGBoost com saída múltipla	2,8852	0,0077	3,9895	0,4755	-0,0344
Seq2Seq básico	N/A	N/A	N/A	N/A	N/A
Seq2Seq atenção canônica	N/A	N/A	N/A	N/A	N/A

A média com múltiplas sementes mantém a LSTM direta como melhor modelo por MAE, mas mostra uma nuance importante: a LSTM recursiva passa a ter melhor RMSE e R2 médios, ao custo de viés positivo consistente. Essa diferença confirma que a escolha do vencedor depende da métrica operacional priorizada. Para o objetivo principal

do TCC, que usa MAE observado como métrica central de erro médio, a LSTM direta continua sendo a escolha principal.

5.4 Linhas de Base Ingênuas

A Tabela 5.3 apresenta linhas de base simples avaliadas no mesmo teste externo. A pontuação de habilidade (*skill score*) usa a persistência $y(t)$ como referência, de forma que valores positivos indicam redução de MAE em relação a essa linha de base.

Tabela 5.3: Linhas de base ingênuas no teste externo.

Linha de base	MAE	RMSE	R2	Habilidade MAE
Persistência $y(t)$	3,8971	5,2834	0,0801	0,0000
Sazonal $y(t - 24)$	3,3739	4,7174	0,2666	0,1342
Sazonal $y(t - 48)$	3,7599	5,2441	0,0937	0,0352
Média móvel 6h	3,3481	4,5533	0,3167	0,1409
Média móvel 24h	3,0377	4,2234	0,4122	0,2205

A melhor linha de base ingênuas foi a média móvel de 24 horas, com MAE 3,0377. A LSTM direta selecionada por *walk-forward* reduz esse erro para 2,7713, uma melhora de aproximadamente 8,8% sobre a melhor linha de base simples e de 28,9% sobre a persistência.

5.5 Erro por Horizonte

A Tabela 5.4 detalha o MAE nos horizontes 1, 6, 12 e 24. O XGBoost teve o melhor primeiro horizonte, mas sua degradação até o horizonte 24 foi maior que a da LSTM direta. A LSTM direta apresentou evolução mais estável ao longo do horizonte, o que ajuda a explicar sua vantagem no MAE agregado.

A estabilidade por horizonte é relevante porque a tarefa é de múltiplos passos. Um modelo pode ser atraente no primeiro passo e ainda perder desempenho agregado quando o horizonte aumenta. Neste experimento, a LSTM direta combinou bom erro inicial com menor degradação, enquanto XGBoost e LSTM recursiva perderam mais desempenho no

Tabela 5.4: MAE por horizonte no teste.

Modelo	H1	H6	H12	H24	H24 - H1
LSTM direta	2,6725	2,7218	2,7773	2,8670	0,1945
Seq2Seq atenção + L1 ponderada	2,7631	2,8133	2,8709	2,9695	0,2063
XGBoost com saída múltipla	2,5618	2,8004	2,9092	3,0273	0,4655
LSTM recursiva	2,7380	2,7338	2,9061	3,1492	0,4112
Seq2Seq básico	N/A	N/A	N/A	N/A	N/A
Seq2Seq atenção canônica	N/A	N/A	N/A	N/A	N/A

fim da janela. A Figura 5.2 apresenta a curva completa de MAE ao longo dos 24 passos para os modelos com métricas consolidadas.




Figura 5.2: Evolução do MAE por horizonte no teste externo para os modelos com métricas consolidadas.

5.6 Picos, Cauda e Suavização

A Tabela 5.5 mostra métricas associadas à amplitude e aos regimes altos. O desvio-padrão observado no teste é aproximadamente 5,51. Valores da razão entre desvios-padrão abaixo de 1 indicam que a série prevista é mais suave que a série observada.

Essas métricas mostram um compromisso importante. A LSTM direta vence em erro médio, mas apresenta razão entre desvios-padrão de 0,7391 e p99 previsto de 28,57, abaixo do p99 observado de 34,00. Isso sugere uma previsão mais suave e com subestimação de parte dos eventos altos. A LSTM recursiva, o XGBoost e o Seq2Seq atenção com L1 ponderada preservam mais amplitude, mas não superam a LSTM direta

Tabela 5.5: Métricas de amplitude e cauda no teste.

Modelo	Peak35 MAE	p99 previsto	p99 observado	Razão DP	MBE
LSTM direta	13,6112	28,57	34,00	0,7391	-0,1366
Seq2Seq atenção + L1 ponderada	12,3697	31,57	34,00	0,8645	0,1869
XGBoost com saída múltipla	12,2583	30,73	34,00	0,8506	0,0066
LSTM recursiva	12,0392	30,49	34,00	0,8751	0,4450
Seq2Seq básico	N/A	N/A	N/A	N/A	N/A
Seq2Seq atenção canônica	N/A	N/A	N/A	N/A	N/A

no MAE global. Portanto, a escolha do modelo depende do objetivo: minimizar erro médio favorece a LSTM direta; priorizar resposta a eventos altos exige olhar para modelos e perdas que preservam mais amplitude. A Figura 5.3 reapresenta uma janela do teste em painéis separados por modelo, com escala vertical comum e interrupções nos trechos sem horários observados. Essa organização evita que as curvas disputem o mesmo eixo visual e deixa explícito que as quebras na linha observada correspondem a lacunas da própria série de teste.




Figura 5.3: Predições agregadas no teste em uma janela com evento de maior concentração, separadas por modelo e com interrupções nas lacunas temporais.

5.6.1 Análise por Evento de Pico

Além das métricas ponto a ponto, os picos foram agregados por horário único e agrupados em eventos contínuos com PM2.5 observado ≥ 35 . Foram encontrados 21 eventos no teste. A Tabela 5.6 resume o erro médio dentro dos eventos, o viés médio nos eventos, a taxa de subestimação e o erro no horário do pico observado.

Tabela 5.6: Métricas por evento contínuo de pico no teste.

Modelo	MAE evento	MBE evento	Subestimação	Erro no pico obs.
LSTM direta	15,4683	-15,4683	1,0000	-16,3894
LSTM recursiva	12,8186	-12,8186	1,0000	-13,6797
Seq2Seq atenção + L1 ponderada	13,6471	-13,3950	0,9471	-14,5321
XGBoost com saída múltipla	13,7253	-13,7253	1,0000	-14,7604
Seq2Seq básico	N/A	N/A	N/A	N/A
Seq2Seq atenção canônica	N/A	N/A	N/A	N/A
Persistência $y(t)$	13,8803	-13,8689	0,9894	-14,9206
Sazonal $y(t - 24)$	14,3677	-14,2487	0,9405	-15,3809

A leitura por evento é mais severa que o MAE global: todos os modelos com métricas consolidadas subestimam fortemente os picos. A LSTM recursiva tem o menor erro médio por evento, enquanto a LSTM direta, apesar de vencer no erro global, é a mais conservadora nos eventos altos. Essa evidência reforça que o TCC deve declarar explicitamente o compromisso entre erro médio e resposta a episódios de maior concentração.

5.7 Seq2Seq com Atenção e Perda L1 Ponderada

A atenção canônica com Huber não foi o melhor caminho durante o desenvolvimento, mas o desenvolvimento do Seq2Seq produziu uma variante relevante com perda L1 ponderada. Essa função de perda pondera regimes moderados/altos e penaliza mais alguns erros de subestimação, mudando explicitamente o objetivo de treinamento. No protocolo consolidado, essa variante foi reexecutada com HPO *walk-forward* e análise com múltiplas sementes.

Tabela 5.7: Seq2Seq com `weighted_l1` após HPO *walk-forward*.

Variante	MAE	RMSE	R2	Peak35 MAE	p99 previsto
Seed 42 selecionado por CV	2,8658	3,9641	0,4821	12,3697	31,57
Média com múltiplas sementes	2,8646	3,9617	0,4827	13,1103	30,49
Desvio com múltiplas sementes	0,0201	0,0266	0,0069	0,7729	0,86

O Seq2Seq atenção com L1 ponderada continua relevante, mas a nova seleção por *walk-forward* torna sua posição mais conservadora que na rodada anterior sem validação temporal interna. Ele fica abaixo da LSTM direta em MAE, RMSE e R2, embora preserve mais amplitude e tenha melhor Peak35 MAE na semente canônica. Esse resultado sustenta a interpretação de compromisso: a perda ponderada melhora parte do comportamento de cauda, mas não torna o Seq2Seq o vencedor global.

5.8 Ablação PM10 Causal

A Tabela 5.8 compara o contrato final contra duas remoções de informação: manter PM10 apenas no histórico, sem substitutos causais no decodificador, e remover PM10 completamente, deixando PM2.5 e atributos temporais. Os hiperparâmetros foram mantidos fixos a partir da seleção *walk-forward*; essas ablações não fizeram novo HPO e foram avaliadas no mesmo teste externo.

Tabela 5.8: Ablação de PM10 causal no contrato final.

Modelo	Contrato	MAE	Δ MAE	RMSE	R2
LSTM direta	PM10 causal completo	2,7713	0,0000	3,8346	0,5154
LSTM direta	PM10 histórico sem substituto no decodificador	2,8575	+0,0862	3,9678	0,4812
LSTM direta	PM2.5 + tempo apenas	2,8456	+0,0743	3,9569	0,4840
XGBoost	PM10 causal completo	2,8786	0,0000	3,9793	0,4781
XGBoost	PM10 histórico sem substituto no decodificador	2,8873	+0,0088	4,0063	0,4710
XGBoost	PM2.5 + tempo apenas	2,8956	+0,0170	4,0194	0,4676

A ablação confirma que os substitutos causais de PM10 foram uma decisão central, sobretudo para a LSTM direta: remover esses atributos aumentou o MAE em 0,0862, e remover PM10 completamente aumentou o MAE em 0,0743. No XGBoost, o ganho global foi menor, mas ainda consistente em MAE, RMSE e R2. Assim, o papel de PM10 causal deve ser apresentado como contribuição metodológica do contrato de dados, não apenas como detalhe de engenharia de atributos.

5.9 Limite Informacional com Variáveis Futuras

Após a ablação causal de PM10, foi executado um diagnóstico adicional com Seq2Seq atenção para responder a uma pergunta diferente: quanto do erro restante parece vir de

informação futura ausente, e não apenas de arquitetura ou hiperparâmetros? Para isso, foi usado um cenário *oracle future auxiliary*, no qual o decodificador recebe PM10 e PTS observados no próprio horizonte futuro. Esse cenário não é operacional e não deve ser tratado como candidato a modelo final, mas funciona como limite superior informacional sob a mesma estação e tarefa.

Na estação Sapo, a tentativa de usar um conjunto mais amplo de variáveis mostrou uma limitação prática: entre as variáveis auxiliares avaliadas, PM10 e PTS foram as únicas com observações úteis de forma consistente; variáveis meteorológicas e gases estavam ausentes ou esparsos demais no recorte analisado. A Tabela 5.9 resume os resultados diagnósticos.

Tabela 5.9: Diagnóstico *oracle future auxiliary* no Seq2Seq atenção em Sapo.

Contrato diagnóstico	MAE	RMSE	R2	Peak35 MAE
PM10 causal no decodificador	2,7777	3,9131	0,4954	10,2406
PM10 + PTS causal no decodificador	2,8758	3,9949	0,4741	10,5980
PM10 futuro real no decodificador (<i>oracle</i>)	2,4201	3,2659	0,6485	7,9835
PM10 + PTS futuro real no decodificador (<i>oracle</i>)	2,4223	3,2654	0,6486	7,1718

O ganho do *oracle* é grande e ajuda a interpretar o problema. Em relação ao controle causal com PM10 e PTS, o uso de variáveis futuras reais reduziu o MAE de 2,8758 para 2,4223 e elevou o R2 de 0,4741 para 0,6486. A melhoria em picos também foi clara: o Peak35 MAE caiu de 10,5980 para 7,1718. Esse resultado mostra que existe informação relevante no futuro de variáveis auxiliares, especialmente em PM10, que o modelo operacional não tem como conhecer no instante da previsão.

Ao mesmo tempo, o próprio *oracle* impõe uma leitura conservadora: mesmo com PM10 e PTS futuros reais, o R2 ficou em torno de 0,65, ainda distante de 1. Portanto, a distância até um R2 quase perfeito não parece ser apenas consequência de HPO insuficiente ou de uma arquitetura Seq2Seq subótima. Parte relevante da variância horária de PM2.5 em Sapo provavelmente depende de fatores não observados no contrato atual, como meteorologia local, estabilidade e mistura atmosférica, transporte espacial, emissões, ressuspensão e episódios súbitos.

5.10 Seq2Seq Multi-Alvo com Variáveis Auxiliares

Também foi testada uma adaptação do Seq2Seq atenção para prever PM2.5 como alvo principal e, durante o treinamento, prever PM10 e PTS futuros como tarefas auxiliares. A hipótese era que a aprendizagem conjunta poderia induzir uma representação interna mais sensível à dinâmica dos poluentes correlacionados, sem usar variáveis futuras reais no decodificador.

Tabela 5.10: Experimentos Seq2Seq multi-alvo com PM10 e PTS como tarefas auxiliares.

Variante diagnóstica	MAE	RMSE	R2	Peak35 MAE
Seq2Seq causal PM10 + PTS, sem multi-alvo	2,8758	3,9949	0,4741	10,5980
Multi-alvo, peso auxiliar 0,03	2,7997	4,0045	0,4715	14,5285
Multi-alvo, peso auxiliar 0,08	2,8876	4,1483	0,4329	10,5677
Multi-alvo, dimensão 128 e peso auxiliar 0,12	2,7689	3,9373	0,4891	11,3975

O melhor multi-alvo reduziu o MAE em relação ao controle causal com PM10 e PTS, de 2,8758 para 2,7689, e elevou o R2 de 0,4741 para 0,4891. Esse é um indício positivo de que a tarefa auxiliar pode regularizar a representação do Seq2Seq. Porém, o ganho não reproduziu o salto observado no *oracle* e ainda piorou a métrica de pico em relação ao controle causal. Em termos práticos, aprender PM10 e PTS futuros não equivale a conhecer PM10 e PTS futuros.

Esses dois diagnósticos convergem para a mesma interpretação. A arquitetura pode extrair algum ganho adicional, mas o principal gargalo para R2 muito alto está na informação disponível. Sem variáveis meteorológicas e espaciais observadas de forma confiável, e sem acesso causal ao futuro dos poluentes auxiliares, o modelo tende a suavizar a variância horária e subestimar parte dos picos.

5.11 Ablação de Máscara e Imputação

A Tabela 5.11 avalia a decisão de manter imputação linear e excluir alvos originalmente imputados da função de perda e das métricas observadas. A linha “linear + máscara” é o contrato principal; as demais linhas alteram somente a política de máscara ou o método de imputação.

O resultado reforça uma decisão metodológica importante do TCC. Tratar valores

Tabela 5.11: Ablação de máscara do alvo e imputação.

Variante	MAE	Δ MAE	RMSE	R2	MBE
Linear + máscara atual	2,7713	0,0000	3,8346	0,5154	-0,1366
Linear sem máscara na função de perda/métricas	2,9911	+0,2197	4,0692	0,4592	0,2998
KNN + máscara	2,9245	+0,1531	4,1430	0,4343	0,1849

imputados do alvo como observações reais piorou o MAE observado em 0,2197 e reduziu o R2. Trocar a imputação linear por KNN mantendo a máscara também piorou o resultado. A combinação linear + máscara, portanto, não é apenas uma escolha conveniente de pré-processamento; ela protege a avaliação contra uma fonte concreta de distorção.

5.12 Análise dos Pesos de Atenção

Para responder se a camada de atenção realmente produziu um mecanismo temporal interpretável, os pesos de atenção foram extraídos diretamente dos pontos de controle finais do Seq2Seq atenção canônica e da melhor variante com L1 ponderada. A extração foi feita sobre 5.177 janelas do conjunto de teste, sem novo treinamento. Em cada janela, a matriz de atenção tem 24 linhas, uma para cada horizonte previsto, e 48 colunas, uma para cada posição histórica do codificador.




Figura 5.4: Perfil médio dos pesos de atenção temporal no codificador para as variantes Seq2Seq avaliadas, após agregação sobre janelas e horizontes previstos.

A Figura 5.4 mostra que a atenção canônica com HPO não é perfeitamente uni-

forme, mas também não concentra massa de forma forte em poucos instantes. Há leve aumento de peso nas bordas da janela histórica, especialmente em posições mais antigas e no trecho recente, enquanto o miolo da janela recebe menor peso médio. Já a variante com L1 ponderada apresenta perfil muito próximo de uniforme. Como a janela tem 48 posições, uma atenção completamente uniforme atribuiria peso médio de $1/48 \approx 0,0208$ a cada hora histórica. Essa figura resume cada posição histórica depois de calcular a média sobre os 24 horizontes; portanto, a curva da L1 ponderada deve ser comparada à média por coluna do mapa de calor, e não a uma célula ou linha isolada.




Figura 5.5: Mapa de calor médio dos pesos de atenção da melhor variante Seq2Seq atenção com L1 ponderada por horizonte previsto e posição do codificador. O painel inferior mostra a média por posição calculada a partir do próprio mapa.

A Figura 5.5 reforça essa leitura para a melhor variante Seq2Seq individual. O painel superior preserva a separação por horizonte, enquanto o painel inferior recompõe a média por posição usada na Figura 5.4. A diferença máxima entre essa recomposição e a curva da L1 ponderada da Figura 5.4 foi de apenas $7,8 \times 10^{-7}$, compatível com arredondamento numérico. A marca $t - 24$ na Figura 5.4 é uma posição histórica fixa; já a diagonal da Figura 5.5 representa a defasagem 24 alinhada ao horizonte previsto. Se a atenção estivesse usando fortemente a correspondência diária, seria esperado observar concentração em torno dessa diagonal. No entanto, os pesos médios próximos de 0,0208 indicam que o modelo não atribuiu massa destacada à defasagem 24, à defasagem 48 ou às últimas horas da entrada.

Tabela 5.12: Diagnósticos agregados dos pesos de atenção no teste.

Modelo	Entropia norm.	Peso máx.	Top-3	Últimas 6h	Lag 24	Lag 48
Seq2Seq atenção canônica	0,9659	0,0517	0,1395	0,1321	0,0209	0,0209
Seq2Seq atenção + L1 ponderada	0,9890	0,0347	0,1009	0,1272	0,0210	0,0207

A Tabela 5.12 resume o mesmo comportamento. Entropia próxima de 1 indica distribuição quase uniforme; massa nas últimas 6 horas perto de $6/48 = 0,125$ também sugere ausência de foco forte em recência. O Seq2Seq atenção canônica ainda apresenta peso máximo e massa Top-3 maiores que a variante com L1 ponderada, mas o padrão continua fraco para sustentar uma interpretação causal ou operacional direta. Essa cautela é coerente com a crítica de Jain e Wallace (2019): pesos de atenção podem ajudar a inspecionar o modelo, mas não devem ser tratados automaticamente como explicação completa da decisão.

Assim, a resposta empírica é dupla. A família Seq2Seq com atenção continua competitiva, especialmente quando combinada à perda L1 ponderada, mas os vetores de atenção extraídos não mostram um seletor temporal forte nem uma ênfase clara em defasagem 24, defasagem 48 ou nas horas mais recentes. O ganho observado parece estar mais associado à função de perda, ao contrato causal de variáveis e à seleção por validação do que a um padrão de atenção altamente concentrado.

5.13 Ablações Auxiliares e Resultados Negativos

As ablações internas do Seq2Seq tiveram papel importante no desenvolvimento do protocolo, mas nem todas pertencem ao mesmo escopo comparável da tabela principal. Estratégias como Luong *dot/general/local*, atenção temporal de múltiplas cabeças (*multi-head*), portões (*gates*), atenção por grupos, atenção guiada (*guided attention*), DA-RNN, viés de recência (*recency bias*) e variantes de *scheduled sampling* foram úteis para testar hipóteses, mas não produziram ganho determinístico suficiente para alterar o vencedor global atual.

O principal achado dessas ablações não é que atenção seja irrelevante em qualquer cenário, mas que, neste conjunto de dados e sob este contrato, mudanças no contrato de dados, no uso causal de PM10 e na função de perda tiveram efeito mais claro que modificações internas sofisticadas no mecanismo de atenção. O resultado negativo também é informativo: arquiteturas mais complexas não compensam automaticamente problemas de dados, suavização ou objetivo de treinamento desalinhado com picos.

A comparação fixa inicial Sapo 70/15/15, executada sem HPO e com outro conjunto de variáveis, deve ser lida como etapa histórica. Ela ajudou a organizar a comparação inicial entre quatro modelos de aprendizado profundo e XGBoost, mas não é a fonte da conclusão final. A conclusão atual se baseia no protocolo final com PM10 causal, HPO *walk-forward*, avaliação com múltiplas sementes dos modelos selecionados e teste no mesmo conjunto final.

5.14 Ameaças à Validade

Há limitações importantes. Primeiro, o eixo principal usa uma estação, Sapo, o que limita a generalização para outras estações e regiões. Segundo, o *walk-forward* foi usado para HPO dentro dos 85% anteriores ao teste, mas o teste final continua sendo um único conjunto cronológico externo; isso preserva o cenário temporal, mas ainda não equivale a repetir todo o estudo em múltiplas estações ou períodos independentes. Terceiro, os modelos neurais apresentam sensibilidade à semente aleatória, embora a análise com múltiplas sementes tenha reduzido a incerteza sobre a classificação por MAE. Quarto, o HPO *walk-*

forward do XGBoost foi limitado a quatro tentativas completas por custo computacional. Quinto, eventos de alta concentração são raros, o que torna métricas de picos instáveis e dependentes de poucos episódios.

Mesmo com essas limitações, o protocolo atual permite uma conclusão mais defensável que a narrativa anterior: no conjunto final de Sapo, a LSTM direta venceu em erro médio; o XGBoost permaneceu uma linha de base tabular forte; e o Seq2Seq atenção com L1 ponderada ficou competitivo, preservando mais amplitude e melhorando parte do comportamento em cauda, sem superar a LSTM direta no resultado global.

6 Conclusão

Este trabalho avaliou modelos de aprendizado de máquina e aprendizado profundo para previsão horária de múltiplos passos de PM2.5 na estação Sapo, usando uma tarefa fixa de 48 horas de entrada e 24 horas de horizonte. A pergunta de pesquisa foi respondida sob um protocolo cronológico comparável, com divisão externa 70/15/15, HPO por validação temporal *walk-forward* dentro do desenvolvimento, variáveis de PM2.5 e PM10, substitutos causais de PM10, imputação linear, máscara de alvo observado e avaliação no teste externo.

O principal resultado é que a LSTM direta com HPO *walk-forward* foi o melhor modelo por MAE no contrato final, com MAE 2,7713, RMSE 3,8346 e R2 0,5154 na semente canônica. Na avaliação com múltiplas sementes, ela manteve o menor MAE médio, 2,8055. O XGBoost com saída múltipla permaneceu uma linha de base tabular forte e teve o melhor primeiro horizonte, mas não foi o vencedor global. O Seq2Seq atenção com L1 ponderada ficou competitivo e ligeiramente à frente do XGBoost em MAE no protocolo consolidado, mas abaixo da LSTM direta.

A análise também mostrou que o erro médio não conta toda a história. A LSTM direta venceu em MAE, mas produziu uma série mais suave em relação à observada, com p99 previsto de 28,57 contra p99 observado de 34,00. A LSTM recursiva e o Seq2Seq atenção com L1 ponderada preservaram mais amplitude e melhoraram parte das métricas de pico, mas com custo em MAE global. Assim, a escolha do modelo depende de priorizar erro médio ou resposta a eventos de maior concentração.

Do ponto de vista metodológico, o trabalho reforça cinco achados. Primeiro, a comparabilidade do contrato experimental é tão importante quanto a arquitetura escolhida. Segundo, tratar valores imputados do alvo como verdade observada pode distorcer a avaliação; na ablação final, remover a máscara piorou o MAE de 2,7713 para 2,9911. Terceiro, variáveis exógenas só devem ser usadas no decodificador quando forem causalmente disponíveis no instante de previsão; remover os substitutos causais de PM10 piorou a LSTM direta para MAE 2,8575. Quarto, mecanismos de atenção e variantes internas

do Seq2Seq não produziram ganho determinístico suficiente sem um contrato de dados e uma função de perda adequados. Quinto, os experimentos *oracle* mostraram que há informação futura relevante fora do contrato causal atual: ao fornecer PM10 e PTS futuros reais ao Seq2Seq, o R2 subiu de 0,4741 para 0,6486 e o Peak35 MAE caiu de 10,5980 para 7,1718, mas mesmo esse cenário com vazamento controlado permaneceu distante de R2 igual a 1.

6.1 Limitações

O estudo tem limitações claras. O eixo principal usa apenas a estação Sapo, o que restringe a generalização espacial. O HPO usa três partições *walk-forward* dentro dos 85% anteriores ao teste, mas o teste final continua sendo um único conjunto cronológico externo. Modelos neurais ainda apresentaram sensibilidade à semente aleatória, embora a avaliação com múltiplas sementes tenha deixado a classificação por MAE mais clara. Além disso, o XGBoost é comparável na avaliação de teste, mas seu treinamento com saída múltipla não é idêntico ao dos modelos neurais com máscara ponto a ponto, e seu HPO *walk-forward* foi limitado a quatro tentativas completas. Por fim, eventos de alta concentração são raros no teste, tornando métricas de cauda mais instáveis que o MAE agregado.

Outra limitação é a comparação com trabalhos externos de PM2.5. A literatura recente frequentemente reporta métricas melhores, mas em tarefas com horizonte mais curto, agregação diária ou mensal, múltiplas estações e variáveis meteorológicas ou espaciais completas. Portanto, esses resultados são úteis para contextualização, mas não são diretamente comparáveis ao protocolo Sapo 48 para 24 horas com poucas variáveis causais observadas.

6.2 Trabalhos Futuros

Trabalhos futuros devem ampliar a validação para múltiplas estações, múltiplos períodos de teste e maior orçamento de HPO para os modelos mais promissores, especialmente XGBoost e variantes voltadas a picos. Também é importante investigar modelos espaço-

temporais capazes de usar relações entre pontos de monitoramento e incorporar variáveis meteorológicas confiáveis, como vento, temperatura, pressão, umidade e precipitação, quando elas estiverem causalmente disponíveis. A inclusão de Transformers temporais, como TFT, Informer, Autoformer e PatchTST, é uma extensão natural desde que acompanhada de orçamento experimental comparável, HPO próprio e análise com múltiplas sementes. Outra extensão natural é aprofundar a avaliação de eventos extremos, com métricas específicas de detecção, subestimação e atraso em picos. Por fim, se a previsão probabilística for retomada, será necessário incluir calibração e avaliação explícita de incerteza antes de discutir uso operacional.

Em síntese, o TCC não demonstra a superioridade universal de uma arquitetura de atenção. A contribuição mais defensável é a consolidação de um protocolo rastreável para previsão horária de PM2.5 em dados reais, mostrando que a LSTM direta venceu o erro médio no contrato atual, que o XGBoost continua sendo uma linha de base forte, que o Seq2Seq com atenção e perda ponderada oferece um compromisso relevante para cauda e picos, e que os testes *oracle* ajudam a separar limitação arquitetural de limitação informacional.

Bibliografia

- AKIBA, T. et al. Optuna: A next-generation hyperparameter optimization framework. In: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.]: ACM, 2019. p. 2623–2631. DOI: 10.1145/3292500.3330701.
- AYTURAN, Y. A. et al. Short-term prediction of PM2.5 pollution with deep learning methods. *Global NEST Journal*, v. 22, n. 1, p. 126–131, 2020. DOI: 10.30955/gnj.003208.
- BAHDANAU, D.; CHO, K.; BENGIO, Y. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014. Published in ICLR 2015. Disponível em: <https://arxiv.org/abs/1409.0473>. DOI: 10.48550/arXiv.1409.0473.
- BAI, X. et al. Prediction of PM2.5 concentration based on a CNN-LSTM neural network algorithm. *PeerJ*, v. 12, p. e17811, 2024. DOI: 10.7717/peerj.17811.
- BALARAMAN, S. et al. Application of LSTM models in predicting particulate matter (PM2.5) levels for urban area. *Journal of Engineering Research*, v. 10, n. 3, p. 71–90, 2022. DOI: 10.36909/jer.11781.
- BENGIO, S. et al. Scheduled sampling for sequence prediction with recurrent neural networks. *arXiv preprint arXiv:1506.03099*, 2015. Published in NIPS 2015. Disponível em: <https://arxiv.org/abs/1506.03099>. DOI: 10.48550/arXiv.1506.03099.
- BENIDIS, K. et al. Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, v. 55, n. 6, p. 1–36, 2022. DOI: 10.1145/3533382.
- BERGMEIR, C.; BENITEZ, J. M. On the use of cross-validation for time series predictor evaluation. *Information Sciences*, v. 191, p. 192–213, 2012. DOI: 10.1016/j.ins.2011.12.028.
- BROOK, R. D. et al. Particulate matter air pollution and cardiovascular disease: An update to the scientific statement from the american heart association. *Circulation*, v. 121, n. 21, p. 2331–2378, 2010. DOI: 10.1161/CIR.0b013e3181d8ece1.
- BUUREN, S. van; GROOTHUIS-OUDSHOORN, K. mice: Multivariate imputation by chained equations in r. *Journal of Statistical Software*, v. 45, n. 3, p. 1–67, 2011. DOI: 10.18637/jss.v045.i03.
- CHAVES, M. G. D. et al. Particulate matter forecast and prediction in Curitiba using machine learning. *Frontiers in Big Data*, v. 7, p. 1412837, 2024. DOI: 10.3389/fdata.2024.1412837.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.]: ACM, 2016. p. 785–794. DOI: 10.1145/2939672.2939785.
- CHEN, Y. et al. Improved prediction of hourly PM2.5 concentrations with a long short-term memory and spatio-temporal causal convolutional network deep learning model. *Science of the Total Environment*, v. 912, p. 168672, 2024. DOI: 10.1016/j.scitotenv.2023.168672.

- COHEN, A. J. et al. Estimates and 25-year trends of the global burden of disease attributable to ambient air pollution: an analysis of data from the global burden of diseases study 2015. *The Lancet*, v. 389, n. 10082, p. 1907–1918, 2017. DOI: 10.1016/S0140-6736(17)30505-6.
- DU, W.-j. et al. SAITS: Self-Attention-based Imputation for Time Series. *Expert Systems with Applications*, v. 219, p. 119619, 2023. DOI: 10.1016/j.eswa.2023.119619.
- FENG, X. et al. A hybrid model for enhanced forecasting of PM2.5 spatiotemporal concentrations with high resolution and accuracy. *Environmental Pollution*, v. 355, p. 124263, 2024. DOI: 10.1016/j.envpol.2024.124263.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>.
- GUO, Q.; YAO, Y.; ZHOU, Y. PM2.5 random forest prediction model incorporating gnss meteorological parameters. *Science of Surveying and Mapping*, v. 46, n. 4, p. 37–42, 2021. DOI: 10.16251/j.cnki.1009-2307.2021.04.006.
- HE, Z.; GUO, Q. Comparative analysis of multiple deep learning models for forecasting monthly ambient PM2.5 concentrations: A case study in dezhou city, china. *Atmosphere*, v. 15, n. 12, p. 1432, 2024. DOI: 10.3390/atmos15121432.
- HEWAMALAGE, H.; BERGMEIR, C.; BANDARA, K. Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, v. 37, n. 1, p. 388–427, 2021. DOI: 10.1016/j.ijforecast.2020.06.008.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. DOI: 10.1162/neco.1997.9.8.1735.
- HU, J. et al. Prediction of PM2.5 concentration based on deep learning for high-dimensional time series. *Applied Sciences*, v. 14, n. 19, p. 8745, 2024. DOI: 10.3390/app14198745.
- HUBER, P. J. Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, v. 35, n. 1, p. 73–101, 1964. DOI: 10.1214/aoms/1177703732.
- HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>.
- JAIN, S.; WALLACE, B. C. Attention is not explanation. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019. p. 3543–3556. DOI: 10.18653/v1/N19-1357.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *arXiv pre-print arXiv:1412.6980*, 2014. Disponível em: <https://arxiv.org/abs/1412.6980>. DOI: 10.48550/arXiv.1412.6980.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539.
- LI, L. et al. Hyperband: A novel bandit-based approach to hyperparameter optimization. *Journal of Machine Learning Research*, v. 18, n. 185, p. 1–52, 2018. Disponível em: <https://www.jmlr.org/papers/v18/16-558.html>. DOI: 10.48550/arXiv.1603.06560.

- LI, T.; HUA, M.; WU, X. A hybrid CNN-LSTM model for forecasting particulate matter (PM_{2.5}). *IEEE Access*, v. 8, p. 26933–26940, 2020. DOI: 10.1109/ACCESS.2020.2971348.
- LI, T. et al. Urban PM_{2.5} concentration prediction via attention-based CNN-LSTM. *Applied Sciences*, v. 10, n. 6, p. 1953, 2020. DOI: 10.3390/app10061953.
- LIM, B. et al. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, v. 37, n. 4, p. 1748–1764, 2021. DOI: 10.1016/j.ijforecast.2021.03.012.
- LIM, B.; ZOHREN, S. Time-series forecasting with deep learning: A survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, v. 379, n. 2194, p. 20200209, 2021. DOI: 10.1098/rsta.2020.0209.
- LIU, H.; FANG, Y.; HU, J. A deep learning-based hybrid method for PM_{2.5} prediction in central and western china. *Scientific Reports*, v. 15, p. 10080, 2025. DOI: 10.1038/s41598-025-95460-6.
- LOSHCHILOV, I.; HUTTER, F. SGDR: Stochastic gradient descent with warm restarts. In: *International Conference on Learning Representations*. [s.n.], 2017. Disponível em: [⟨https://arxiv.org/abs/1608.03983⟩](https://arxiv.org/abs/1608.03983).
- _____. Decoupled weight decay regularization. In: *International Conference on Learning Representations*. [s.n.], 2019. Disponível em: [⟨https://arxiv.org/abs/1711.05101⟩](https://arxiv.org/abs/1711.05101).
- LUONG, M.-T.; PHAM, H.; MANNING, C. D. Effective approaches to attention-based neural machine translation. In: *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. Lisbon, Portugal: Association for Computational Linguistics, 2015. p. 1412–1421. DOI: 10.18653/v1/D15-1166.
- MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, v. 5, p. 115–133, 1943. DOI: 10.1007/BF02478259.
- NAPVASCONCELOS; VASCONCELOS, N. *Neuron pt.svg*. 2008. Wikimedia Commons. Imagem com modificações em português do Brasil, sob licenças CC BY-SA/GFDL. Acesso em: 10 maio 2026. Disponível em: [⟨https://commons.wikimedia.org/wiki/File:Neuron_pt.svg⟩](https://commons.wikimedia.org/wiki/File:Neuron_pt.svg).
- NIE, Y. et al. A time series is worth 64 words: Long-term forecasting with transformers. In: *International Conference on Learning Representations*. [s.n.], 2023. Disponível em: [⟨https://openreview.net/forum?id=Jbdc0vTOcol⟩](https://openreview.net/forum?id=Jbdc0vTOcol). DOI: 10.48550/arXiv.2211.14730.
- Optuna Contributors. *Efficient Optimization Algorithms*. 2026. Optuna 4.8.0 documentation. Acesso em: 10 maio 2026. Disponível em: [⟨https://optuna.readthedocs.io/en/stable/tutorial/10_key_features/003_efficient_optimization_algorithms.html⟩](https://optuna.readthedocs.io/en/stable/tutorial/10_key_features/003_efficient_optimization_algorithms.html).
- _____. *optuna.pruners.HyperbandPruner*. 2026. Optuna 4.8.0 documentation. Acesso em: 10 maio 2026. Disponível em: [⟨https://optuna.readthedocs.io/en/stable/reference/generated/optuna.pruners.HyperbandPruner.html⟩](https://optuna.readthedocs.io/en/stable/reference/generated/optuna.pruners.HyperbandPruner.html).
- _____. *optuna.pruners.MedianPruner*. 2026. Optuna documentation. Acesso em: 10 maio 2026. Disponível em: [⟨https://optuna.readthedocs.io/en/latest/reference/generated/optuna.pruners.MedianPruner.html⟩](https://optuna.readthedocs.io/en/latest/reference/generated/optuna.pruners.MedianPruner.html).

- _____. *optuna.samplers.TPESampler*. 2026. Optuna 4.8.0 documentation. Acesso em: 10 maio 2026. Disponível em: <https://optuna.readthedocs.io/en/stable/reference/samplers/generated/optuna.samplers.TPESampler.html>.
- POPE, C. A.; DOCKERY, D. W. Health effects of fine particulate air pollution: Lines that connect. *Journal of the Air & Waste Management Association*, v. 56, n. 6, p. 709–742, 2006. DOI: 10.1080/10473289.2006.10464485.
- QAMAR, M. S.; MUNIR, M. F.; WASEEM, A. AI for cleaner air: Predictive modeling of PM_{2.5} using deep learning and traditional time-series approaches. *Computer Modeling in Engineering & Sciences*, v. 144, n. 3, p. 3557–3584, 2025. DOI: 10.32604/cmescs.2025.067447.
- QIN, Y. et al. A dual-stage attention-based recurrent neural network for time series prediction. In: *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence*. [S.l.: s.n.], 2017. p. 2627–2633. DOI: 10.24963/ijcai.2017/366.
- REQUIA, W. J. et al. Health impacts of wildfire-related air pollution in brazil: a nationwide study of more than 2 million hospital admissions between 2008 and 2018. *Nature Communications*, v. 12, n. 1, p. 6555, 2021. DOI: 10.1038/s41467-021-26822-7.
- _____. Short-term exposure to wildfire-related pm_{2.5} increases mortality risks and burdens in brazil. *Nature Communications*, v. 13, n. 1, p. 7922, 2022. DOI: 10.1038/s41467-022-35326-x.
- ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, v. 65, n. 6, p. 386–408, 1958. DOI: 10.1037/h0042519.
- RUBIN, D. B. Inference and missing data. *Biometrika*, v. 63, n. 3, p. 581–592, 1976. DOI: 10.1093/biomet/63.3.581.
- SALINAS, D. et al. DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, v. 36, n. 3, p. 1181–1191, 2020. DOI: 10.1016/j.ijforecast.2019.07.001.
- SONG, G. et al. Arima-svm combination prediction of pm_{2.5} concentration in shenyang. *China Environmental Science*, v. 38, n. 11, p. 4031–4039, 2018.
- STEKHOFEN, D. J.; BUHLMANN, P. Missforest: non-parametric missing value imputation for mixed-type data. *Bioinformatics*, v. 28, n. 1, p. 112–118, 2012. DOI: 10.1093/bioinformatics/btr597.
- SU, Y. et al. Application of CNN-LSTM algorithm for PM_{2.5} concentration forecasting in the beijing-tianjin-hebei metropolitan area. *Atmosphere*, v. 14, n. 9, p. 1392, 2023. DOI: 10.3390/atmos14091392.
- SUTSKEVER, I.; VINYALS, O.; LE, Q. V. Sequence to sequence learning with neural networks. *arXiv preprint arXiv:1409.3215*, 2014. Published in NIPS 2014. Disponível em: <https://arxiv.org/abs/1409.3215>. DOI: 10.48550/arXiv.1409.3215.
- TASHMAN, L. J. Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, v. 16, n. 4, p. 437–450, 2000. DOI: 10.1016/S0169-2070(00)00065-0.

- TEUTSCH, P.; MÄDER, P. Flipped classroom: Effective teaching for time series forecasting. *Transactions on Machine Learning Research*, 2022. Disponível em: <https://openreview.net/forum?id=w3x20YEcQK>. DOI: 10.48550/arXiv.2210.08959.
- THOMA, M. *Perceptron-unit.svg*. 2014. Wikimedia Commons. Imagem sob licença CC0 1.0. Acesso em: 10 maio 2026. Disponível em: <https://commons.wikimedia.org/wiki/File:Perceptron-unit.svg>.
- TRAN, H. D. et al. Forecasting hourly PM2.5 concentration with an optimized LSTM model. *Atmospheric Environment*, v. 315, p. 120161, 2023. DOI: 10.1016/j.atmosenv.2023.120161.
- WEN, R. et al. A multi-horizon quantile recurrent forecaster. *arXiv preprint arXiv:1711.11053*, 2017. Disponível em: <https://arxiv.org/abs/1711.11053>. DOI: 10.48550/arXiv.1711.11053.
- World Health Organization. *WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Geneva, 2021. Disponível em: <https://www.who.int/publications/i/item/9789240034228>.
- WU, H. et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2021. v. 34, p. 22419–22430. DOI: 10.48550/arXiv.2106.13008.
- YANG, L. et al. Attention-lstm-based prediction model of pm2.5 hourly concentration. In: *2023 12th International Conference of Information and Communication Technology (ICTech)*. [S.l.: s.n.], 2023. p. 137–141. DOI: 10.1109/ICTech58362.2023.00037.
- ZENG, A. et al. Are transformers effective for time series forecasting? In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2023. v. 37, n. 9, p. 11121–11128. DOI: 10.1609/aaai.v37i9.26317.
- ZENG, L. et al. Evaluating deep learning time series models for PM2.5 forecasting across diverse horizons. *iScience*, v. 29, n. 2, p. 114770, 2026. DOI: 10.1016/j.isci.2026.114770.
- ZHANG, M. et al. PM2.5 concentration prediction model utilizing GNSS-PWV and RF-LSTM fusion algorithms. *Atmosphere*, v. 16, n. 10, p. 1147–1161, 2025. DOI: 10.3390/atmos16101147.
- ZHANG, Z.; MA, X.; YAN, K. A deep learning model for pm2.5 concentration prediction. In: *2021 IEEE Intl Conf on Dependable, Autonomic and Secure Computing, Intl Conf on Pervasive Intelligence and Computing, Intl Conf on Cloud and Big Data Computing, Intl Conf on Cyber Science and Technology Congress (DASC/PiCom/CBDCCom/CyberSciTech)*. [S.l.: s.n.], 2021. p. 428–433. DOI: 10.1109/DASC-PiCom-CBDCCom-CyberSciTech52372.2021.00078.
- ZHAO, J. et al. PM2.5 prediction based on the combined emd-lstm model. In: *2021 International Conference on Computational Science and Computational Intelligence (CSCI)*. [S.l.: s.n.], 2021. p. 193–195. DOI: 10.1109/CSCI54926.2021.00045.
- ZHOU, H. et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2021. v. 35, n. 12, p. 11106–11115. DOI: 10.1609/aaai.v35i12.17325.

ZHOU, S. et al. Deep-learning architecture for PM2.5 concentration prediction: A review. *Environmental Science and Ecotechnology*, v. 21, p. 100400, 2024. DOI: 10.1016/j.es.2024.100400.